



UNIVERSIDADE FEDERAL DE PERNAMBUCO  
CENTRO DE GEOCIÊNCIAS E TECNOLOGIA  
DEPARTAMENTO DE ENGENHARIA MECÂNICA  
PROGRAMA DE PÓSGRADUAÇÃO EM ENGENHARIA MECÂNICA

Jônata Ferreira de Melo

**DESENVOLVIMENTO DE TÉCNICA DE PREDIÇÃO DE DEFEITOS EM  
MÁQUINAS ROTATIVAS POR MEIO DE REDES NEURAS ARTIFICIAIS**

Recife  
2018

Jônata Ferreira de Melo

**DESENVOLVIMENTO DE TÉCNICA DE PREDIÇÃO DE DEFEITOS EM  
MÁQUINAS ROTATIVAS POR MEIO DE REDES NEURAIS ARTIFICIAIS**

Tese apresentada ao Programa de Pós-Graduação em Engenharia Mecânica da Universidade Federal de Pernambuco, como requisito parcial para a obtenção do título de Doutor em Engenharia Mecânica.

**Área de concentração:** Energia.

**Orientador:** Profº Dr José Maria Andrade Barbosa.

Recife  
2018

Catálogo na fonte  
Bibliotecária Margareth Malta, CRB-4 / 1198

M528d    Melo, Jônata Ferreira de.  
Desenvolvimento de técnica de predição de defeitos em máquinas rotativas por meio de redes neurais artificiais / Jônata Ferreira de Melo. - 2018.  
120 folhas, figs., tabs.

Orientador: Prof. Dr. José Maria Andrade Barbosa.  
Tese (Doutorado) – Universidade Federal de Pernambuco. CTG. Programa de Pós-Graduação em Engenharia Mecânica, 2018.  
Inclui Referências e Apêndices.

1. Engenharia Mecânica. 2. Transformada wavelet. 3. Algoritmo. 4. Manutenção preditiva. 5. Máquinas rotativas. 6. Redes neurais artificiais.  
I. Barbosa, José Maria Andrade. (Orientador). II. Título.

UFPE

621 CDD (22. ed.)

BCTG/2018-416

Jônata Ferreira de Melo

**DESENVOLVIMENTO DE TÉCNICA DE PREDIÇÃO DE DEFEITOS EM  
MÁQUINAS ROTATIVAS POR MEIO DE REDES NEURAIS ARTIFICIAIS**

Tese apresentada ao Programa de Pós-Graduação em Engenharia Mecânica da Universidade Federal de Pernambuco, como requisito parcial para a obtenção do título de Doutor em Engenharia Mecânica.

Aprovada em: 13 / 08 / 2018

**BANCA EXAMINADORA**

---

Profº Dr José Maria Andrade Barbosa (Orientador)  
Universidade Federal de Pernambuco

---

Profº Dr Tiago Leite Rolim (Examinador Interno)  
Universidade Federal de Pernambuco

---

Profº Dr José Carlos Charamba Dutra (Examinador Interno)  
Universidade Federal de Pernambuco

---

Profº Dr José Claudino de Lira Júnior (Examinador Externo)  
Universidade Federal de Pernambuco

---

Profº Dr Phillip Luiz de Mendonça (Examinador Externo)  
Centro Universitário Boa Viagem

Dedico este trabalho aos meus pais e a todos que de forma direta ou indireta contribuíram para a minha formação como profissional e acima de tudo como ser humano.

## **AGRADECIMENTOS**

Agradeço primeiramente aos meus pais pela educação e pelo incentivo na infundável busca pelo conhecimento.

Agradeço também a PETROBRÁS que por meio de seu programa de formação de recursos humanos proporcionou todo o aporte financeiro para que o trabalho se iniciasse fazendo com que este trabalho fosse possível.

Agradeço também ao meu orientador professor José Maria Andrade Barbosa, que foi capaz de compreender minhas ausências e me forneceu o suporte quando necessário.

Gostaria de agradecer ao colega José Carlos e ao professor Tiago Rolim que contribuíram imensamente com a coleta de dados e com a disponibilização dos equipamentos necessários. Sem esta ajuda o trabalho jamais seria concluído no prazo.

Agradeço ao pessoal da coordenação e secretaria do programa de pós-graduação em engenharia mecânica, por toda a paciência em fornecer as informações relevantes para a conclusão do curso.

Peço desculpas aqueles que não tiveram seus nomes mencionados, mas que contribuíram para a concretização desta tese.

## RESUMO

Com o desenvolvimento da tecnologia de fabricação e processos com a chegada da indústria 4.0, toda uma série de conceitos precisam ser revistos e avaliados. A manufatura moderna traz paradigmas que impactam diretamente em setores como manutenção. Na direção do esforço de livrar o homem de atividades rotineiras e melhoria na eficiência e segurança na execução de atividades de manutenção preditiva, este trabalho se propõe a desenvolver uma técnica capaz de automatizar o diagnóstico de falhas como desbalanceamento e desalinhamento em máquinas rotativas, por meio da aplicação de redes neurais artificiais do tipo feedforward multicamadas. Os dados utilizados para o treinamento da rede foram dados de vibração obtidos experimentalmente e o padrão dos problemas em estudos foram capturados por meio da decomposição dos sinais mediante aplicação da transformada wavelet. Os resultados obtidos constataram que a rede foi capaz de apreender as características dos problemas analisados e fornecer resultados acima dos 99% de acerto em algumas condições de operação, além de diagnosticar inclusive quando os problemas estão combinados. O algoritmo desenvolvido além de ser aplicável a supervisão de máquinas rotativas em tempo real é capaz também de fornecer análises FFT, STFT, Espectogramas, análises wavelet no domínio tempo x frequência e decomposição de sinais.

Palavras-chave: Transformada wavelet. Algoritmo. Manutenção preditiva. Máquinas rotativas. Redes neurais artificiais.

## **ABSTRACT**

With the development of manufacturing technology and processes with the arrival of industry 4.0, a whole series of concepts need to be reviewed and evaluated. Modern manufacturing brings paradigms that directly impact sectors such as maintenance. In the direction of the effort to rid man of routine activities and improve efficiency and safety in the execution of predictive maintenance activities, this paper proposes to develop a technique capable of automating the diagnosis of faults such as imbalance and misalignment in rotary machines, through the application of artificial neural networks of the feedforward multilayer type. The data used for the training of the network were vibration data obtained experimentally and the pattern of the problems in studies were captured by means of the decomposition of the signals by application of the wavelet transform. The obtained results showed that the network was able to apprehend the characteristics of the problems analyzed and to provide results above the 99% accuracy in some operating conditions, besides diagnosing even when the problems are combined. The algorithm developed besides being applicable to the supervision of rotating machines in real time is also capable of providing FFT, STFT, Spectograms, wavelet analysis in the time x frequency domain and signal decomposition.

Keywords: Wavelet transform. Algorithm. Predictive maintenance. Rotary machines. Artificial neural networks.



## LISTA DE FIGURAS

Figura 1 -	Representação do sistema ciber-físico.....	16
Figura 2 -	Representação da arquitetura 5C.....	17
Figura 3 -	Evolução das filosofias de manutenção.....	22
Figura 4 -	Curva da banheira.....	27
Figura 5 -	Representação de um acelerômetro.....	32
Figura 6 -	Representação de um sismômetro.....	33
Figura 7 -	Esquema de funcionamento de uma sonda de proximidade.....	35
Figura 8 -	Movimento vibratório de rotores desbalanceados.....	36
Figura 9 -	Tipos de desalinhamentos em máquinas rotativas.....	38
Figura 10 -	Redes de camada única.....	45
Figura 11 -	Redes de múltiplas camadas.....	45
Figura 12 -	Redes do tipo Feedforward.....	46
Figura 13 -	Redes Feedback.....	46
Figura 14 -	Esquema geral de um processo de modelagem.....	47
Figura 15 -	Abordagens tradicional e heurística.....	48
Figura 16 -	Fluxograma do algoritmo.....	49
Figura 17 -	Esquema de processamento dos dados.....	49
Figura 18 -	Representação da Wavelet-mãe proposta por Daubechie.....	55
Figura 19 -	Representação do impacto do parâmetro $a$ na largura da janela....	55
Figura 20 -	Algoritmo de decomposição em árvore proposto por Mallat.....	56
Figura 21 -	Representação de uma rede com $n$ entradas e uma saída.....	58
Figura 22 -	Rede de tipologia multicamadas.....	58
Figura 23 -	Representação da bancada experimental e seus componentes.....	63
Figura 24 -	Posições de coleta de dados.....	64
Figura 25 -	Esquema da quantidade de experimentos necessários.....	64
Figura 26 -	Aparato para captura da velocidade de rotação.....	65
Figura 27 -	Alinhador a laser.....	65
Figura 28 -	Procedimento para alinhamento do laser.....	66
Figura 29 -	Alinhador posicionado no eixo.....	66
Figura 30 -	Vista do alinhador montado no eixo.....	67
Figura 31 -	IHM do alinhador à laser.....	67
Figura 32 -	IHM do detector.....	68

Figura 33 - Interface do Trendline 3.6.....	68
Figura 34 - Gráficos gerados pelo Trendline 3.6.....	69
Figura 35 - Sistemática para obtenção dos dados.....	70
Figura 36 - Gráfico gerado pelo Trendline 3.6.....	72
Figura 37 - Gráfico gerado pelo PDFMR.....	73
Figura 38 - FFT gerada pelo Trendline 3.6.....	73
Figura 39 - FFT gerada pelo PDFMR.....	74
Figura 40 - Decomposição dos sinais da condição inicial obtidos a 15 Hz.....	75
Figura 41 - Decomposição dos sinais da situação intermediária 15 Hz.....	76
Figura 42 - Decomposição dos sinais da situação máxima a 15 Hz.....	77
Figura 43 - Tipologia da primeira rede.....	78
Figura 44 - Matriz confusão do caso inicial 15 Hz.....	78
Figura 45 - Performance da rede na condição inicial 15 Hz.....	80
Figura 46 - Matriz confusão condição intermediária 15 Hz.....	80
Figura 47 - Performance da rede condição intermediária 15 Hz.....	81
Figura 48 - Matriz confusão condição máxima 15 Hz.....	82
Figura 49 - Performance da rede condição máxima 15 Hz.....	82
Figura 50 - Evolução do aprendizado com o acréscimo de neurônios.....	84
Figura 51 - Matriz confusão 100 neurônios 3600 rpm/ 7g/ 0,3mm.....	96
Figura 52 - Matriz confusão 100 neurônios 3600 rpm/ 15g/ 0,6mm.....	97
Figura 53 - Matriz confusão 100 neurônios 3600 rpm/ 30g/ 1,0mm.....	97
Figura 54 - Gráficos de performance no treinamento da rede.....	98
Figura 55 - Evolução do aprendizado com o acréscimo de neurônios.....	99

## LISTA DE TABELAS

Tabela 1 -	Vantagens e desvantagens no uso de acelerômetros.....	33
Tabela 2 -	Vantagens e desvantagens no uso de um sismômetro.....	34
Tabela 3 -	Vantagens e desvantagens no uso de sondas de proximidade.....	35
Tabela 4 -	Definição dos vetores alvo.....	60
Tabela 5 -	Níveis de desbalanceamento e desalinhamento considerados na pesquisa.....	70
Tabela 6 -	Resultados das simulações alterando-se a quantidade de neurônios na camada intermediária.....	83

## LISTA DE SÍMBOLOS

$\int$	-	Integral
$\infty$	-	Infinito
$s(\omega)$	-	Sinal no domínio da frequência
$s(t)$	-	Sinal no domínio do tempo
$\omega$	-	Frequência
$e$	-	Número de Euler
$i$	-	Número imaginário
$dt$	-	Derivada no tempo
$T$	-	Período
$\mu_s$	-	Valor médio
$\psi_s^2$	-	Valor médio quadrático
$\sigma_s^2$	-	Variância
$\lim$	-	Limite
$\Delta t$	-	Variação no tempo
$\Delta f$	-	Variação na frequência
$\nabla$	-	Gradiente
$\pi$	-	pi
$\text{sen}$	-	Função seno
$t$	-	Tempo
$\Sigma$	-	Somatório
$\  \quad \ $	-	Norma Euclidiana
$\langle \quad \rangle$	-	Produto interno
$\psi_{j,n}$	-	Função Wavelet mãe
$c_m, d_m$	-	Coeficientes Wavelet
$w$	-	Vetor peso
$b$	-	Limiar do neurônio (bias)

## LISTA DE SIGLAS

CPS -	Sistemas ciber-físicos (Cyber Physical Systems)
FFT -	Transformada rápida de Fourier (Fast Fourier Transform)
STFT -	Transformada de Fourier de tempo curto (Short Time Fourier Transform)
PSD -	Power Spectral Density
SVM -	Support Vector Machine
CV -	Cavalo Vapor
Hh -	Homem Hora
PIB -	Produto Interno Bruto
PZT -	Titanato de Zirconato de Chumbo
CA -	Corrente Alternada
CC -	Corrente Contínua
Com -	Ciclos por Minuto
RMS -	Root Mean Square
Exp -	Exponencial
RNA -	Rede Neural Artificial
LA -	Lado do Acoplamento
IHM -	Interface Homem Máquina
PDFMR-	Programa de Detecção de Falhas em Máquinas Rotativas
RPM -	Rotações Por Minuto
MCP -	Multi Layer Perceptron
DB -	Decibéis
A/D -	Analógico Digital
DFT -	Discrete Fourier Transform

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO E JUSTIFICATIVA.....</b>	<b>15</b>
1.1	ESTADO DA ARTE E CONTRIBUIÇÃO DO TRABALHO.....	17
<b>2</b>	<b>OBJETIVOS.....</b>	<b>20</b>
2.1	OBJETIVO GERAL.....	20
2.2	OBJETIVOS ESPECÍFICOS.....	20
<b>3</b>	<b>REFERENCIAL TEÓRICO.....</b>	<b>21</b>
3.1	TÉCNICAS DE MANUTENÇÃO.....	21
3.1.1	Manutenção corretiva.....	22
3.1.2	Manutenção preventiva.....	23
3.1.3	Manutenção preditiva.....	24
3.1.4	Manutenção proativa.....	25
3.1.5	Técnicas de manutenção usualmente aplicadas a máquinas rotativas.....	26
3.1.5.1	Técnicas preditivas: Termografia.....	28
3.1.5.1.1	<i>Tipos de sistemas de termografia.....</i>	<i>29</i>
3.1.5.2	Técnicas preditivas: Tribologia.....	30
3.1.5.3	Técnicas preditivas: Ultrassom.....	31
3.1.5.4	Técnicas preditivas: Análise de vibração.....	31
3.1.5.4.1	<i>Acelerômetros.....</i>	<i>32</i>
3.1.5.4.2	<i>Sismômetros (Sensores de velocidade).....</i>	<i>33</i>
3.1.5.4.3	<i>Sondas de proximidade.....</i>	<i>34</i>
3.2	PRINCIPAIS DEFEITOS ASSOCIADOS À MÁQUINAS ROTATIVAS	36
3.3	PROCESSAMENTO DE SINAIS DE VIBRAÇÃO.....	38
3.3.1	Análise FFT (fast fourier transform).....	40
3.3.2	Análise PSD.....	41
3.3.3	Análise STFT.....	41
3.3.4	Transformada Wavelet.....	41
3.4	REDES NEURAIS ARTIFICIAIS.....	42
3.4.1	Evolução dos modelos de redes neurais artificiais.....	44
3.4.2	Principais arquiteturas de redes neurais artificiais.....	45
3.4.3	Redes neurais artificiais no diagnóstico de falhas.....	46

<b>4</b>	<b>MODELAGEM.....</b>	<b>47</b>
4.1	MATLAB®.....	50
4.2	TRENDLINE 3.6.....	50
4.3	ANÁLISE FFT.....	50
4.4	ANÁLISE PSD.....	52
4.5	ANÁLISE STFT.....	53
4.6	ANÁLISE WAVELET.....	53
4.7	REDE NEURAL.....	57
4.8	TRATAMENTO DOS DADOS.....	59
<b>5</b>	<b>MATERIAIS E MÉTODOS.....</b>	<b>62</b>
5.1	DEFINIÇÃO DO EXPERIMENTO.....	62
5.2	SEQUÊNCIA DE CAPTURA DOS DADOS.....	70
<b>6</b>	<b>ANÁLISE DOS RESULTADOS.....</b>	<b>72</b>
6.1	VALIDAÇÃO DO ALGORITMO DESENVOLVIDO.....	72
6.2	PRÉ-PROCESSAMENTO DOS DADOS.....	74
6.3	APLICAÇÃO DOS PADRÕES NA REDE NEURAL ARTIFICIAL.....	78
<b>7</b>	<b>CONSIDERAÇÕES FINAIS.....</b>	<b>86</b>
7.1	TRABALHOS FUTUROS.....	88
	<b>REFERÊNCIAS.....</b>	<b>89</b>
	<b>APÊNDICE A – RESULTADOS DAS SIMULAÇÕES.....</b>	<b>96</b>
	<b>APÊNDICE B – ALGORITMO PDFMR.....</b>	<b>100</b>

## 1 INTRODUÇÃO E JUSTIFICATIVA

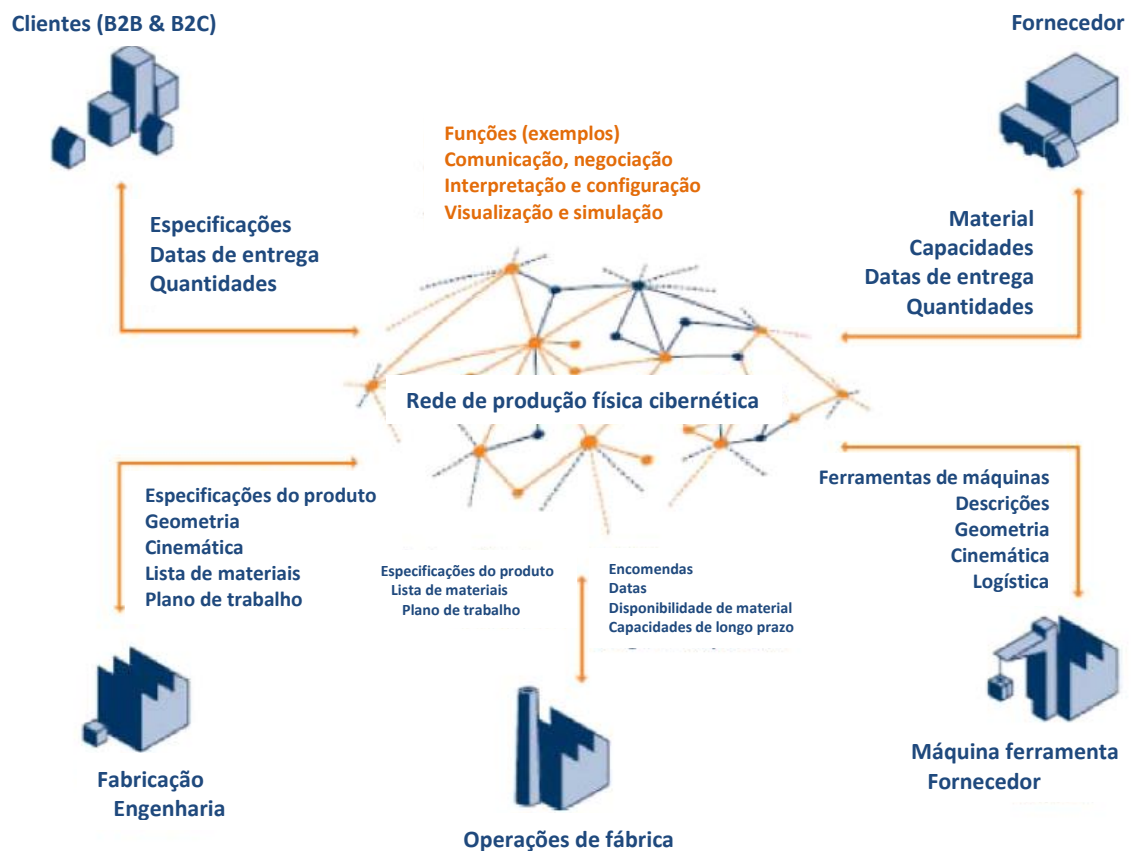
Não há dúvida que a evolução tecnológica vivenciada dos anos 2.000 até os dias atuais, têm tornado cada vez mais frenética a relação do ser humano, tanto com o consumo, quanto com a capacidade de adaptação a um ritmo cada vez mais intenso de atualização de serviços, e o surgimento de novas necessidades inerentes a tal avanço. Tanto a percepção do desenvolvimento tecnológico, como o desenvolvimento de uma nova relação entre a indústria e o consumidor final, foi possível graças o advento e evolução da internet e produtos a ela conectados.

Lasi (2014) explica que a indústria é um ramo da economia normalmente altamente mecanizado e automatizado destinado a produção de bens. Entretanto ao observar seu desenvolvimento, percebe-se que desde o início da industrialização, saltos tecnológicos levam a mudança de paradigmas que hoje temos conhecido como “revolução industrial”. Lasi (2014) ainda afirma que, a primeira mudança de paradigma ocorreu com a mecanização promovida pela primeira revolução industrial. Em seguida com o uso intensivo da energia elétrica foi promovido um novo salto de produtos e equipamentos, esta representa a segunda revolução industrial, e com a evolução da eletrônica e digitalização generalizada causou-se um novo impacto na indústria e no consumo, esta representa a terceira revolução industrial. Baseada nesta migração do analógico para o digital nas fábricas, assim como a combinação com a internet, diversas tecnologias têm sido orientadas para um futuro de tecnologias hoje denominada “objetos inteligentes” (máquinas e produtos) que dão origem a indústria 4.0, termo que faz alusão a versões de um software.

De acordo com Pisching (2017), o conceito de fábricas inteligentes está fundamentado num ambiente capaz de decidir sobre as atitudes a serem tomadas em diversos cenários desde a manutenção de um equipamento até a definição autônoma do processamento de um produto. Para tornar todo o conceito viável surgem os sistemas ciber-físicos (CPS), de acordo com Lee e Seshia (2016), estes sistemas são compostos da união de subsistemas físicos interligados em rede com a computação. A figura 1 exibe de um modo abrangente a amplitude necessária de um sistema ciber-físico.



Figura 1 - Representação do sistema ciber-físico



Fonte: Adaptado de Lasi (2014)

Devido à complexidade envolvida em tais sistemas alguns conceitos importantes apoiam o desenvolvimento deste tipo de indústria:

- Computação na nuvem;
- Big data;
- IoT (internet das coisas);
- Aprendizagem de máquina.

Foram propostas algumas arquiteturas de sistemas ciber-físicos visando integrar os agentes envolvidos no sistema, bem como promover monitoramento, controle e auto-organização. Lee (2015) propôs uma arquitetura conhecida como 5C, estruturada em cinco camadas.

Figura 2 - Representação da arquitetura 5C



Fonte: Pisching (2017)

Em decorrência do aumento da interdependência e nível de eficiência almejado para sistemas industriais modernos, os sistemas de manutenção modernos devem caminhar num ritmo compatível com tecnologias de produção, caso contrário todos estes sistemas sucumbirão ao fracasso, tendo em vista que não há produção eficiente sem uma manutenção eficiente.

A visão principal do trabalho ao tratar deste tema é a apropriação de tais conceitos e sua aplicação especificamente para o setor de manutenção, visando caminhar na direção da aquisição de dados e promover uma determinação da condição do equipamento por meio da aplicação de algoritmo baseado em técnicas do campo da inteligência artificial, tornando mais concreto o conceito de aprendizagem de máquina. Deseja-se com a aplicação de redes neurais artificiais tornar viável, não apenas o monitoramento baseado em alarmes preestabelecidos, deseja-se um monitoramento supervisionado por uma rede neural capaz de agir como um sistema especialista para cada equipamento monitorado.

### 1.1 ESTADO DA ARTE E CONTRIBUIÇÃO DO TRABALHO

As máquinas rotativas estão presentes em praticamente todos os ambientes industriais. De acordo com Liu (2018) a cada evolução tecnológica os equipamentos industriais tornam-se cada vez mais complexos e as máquinas rotativas estão dentre

os equipamentos mais importantes na indústria atual. Em decorrência deste fato, o diagnóstico das falhas em máquinas rotativas passaram a ser o aspecto mais crítico dos sistemas de manutenção.

Com a evolução das técnicas de manutenção preditiva, as técnicas de monitoramento têm evoluído, em decorrência dos estudos desenvolvidos desde então. Mallikarjun (2017) afirma que o monitoramento da condição dos equipamentos é um processo onde é verificada a saúde do equipamento visando prever a capacidade operacional de um sistema num determinado ambiente sob determinada condição de operação, visando reconhecer certos padrões de falha em estágios iniciais.

Existem referências que empregam técnicas baseadas no monitoramento da condição. Walker (1924) propôs um sistema de medição que utilizou dados e análises baseadas em teoria para diagnóstico de falhas de motores. A análise de vibração iniciou-se por volta da década de 1950. Devido ao desenvolvimento dos acelerômetros e outros captadores de vibração e temperatura, as análises espectrais ganharam cada vez mais relevância. Em meados dos anos 1980 Timperley mostrou que a combinação de interferência eletromagnética medida no ponto neutro de uma máquina em operação combinada com análise de espectro de banda larga, é capaz de fornecer informações de diagnóstico significativas com uma boa antecedência, ou seja, antes da falha completa.

Galán (2016) mostra em seu trabalho a importância do monitoramento de máquinas em funcionamento, explicitando os benefícios diários do monitoramento por sensores de radiofrequência advindo de tecnologias adjacentes aos anos 2000 e 2010 na área de sensoriamento. O ramo de aquisição de dados e integração de equipamentos de comunicação tem incrementado a viabilidade crescente de sistemas de monitoramento contínuo.

Em 2003, Han realizou uma pesquisa reportando o desenvolvimento na área de algoritmos de diagnóstico de falhas. Em seu artigo explicitou os pontos potenciais no avanço de técnicas de processamento de sinais e técnicas de inteligência artificial desenvolvidas e em desenvolvimento em esquemas de monitoramento de falhas como, excentricidade em rotor, falhas no rolamento e caixa de engrenagens, dentre diversos outros problemas em motores elétricos. Pesquisas recentes têm sido

desenvolvidas em análise de motores usando técnicas de análise de assinaturas elétricas com ênfase no estudo da corrente do estator.

Diversos artigos relatam o uso de técnicas de processamento de sinais como, análise: FFT, STFT, PSD e transformada wavelet, para captura dos padrões de falha a serem usados em algoritmos baseados em inteligência artificial e métodos estatísticos. Existem métodos como: lógica fuzzy, algoritmos genéticos, mapas de auto-organização, teoria da informação, redes Bayesianas, Support Vector Machine (SVM) dentre outras técnicas. Uma boa vantagem oferecida pelas redes neurais é que essas características podem ser capturadas do sistema, requerendo pouca ou nenhuma informação previa do processo.

Nas últimas décadas diversos trabalhos como o trabalho de Walker (2014) que se propôs a localizar desbalanceamento e não linearidades em máquinas rotativas por meio de redes neurais artificiais, bem como o trabalho de Castejón (2014) que se propôs a identificar fraturas em rotores por meio de análise multiresolução e redes neurais artificiais. Muitos pesquisadores têm se dedicado ao monitoramento e diagnóstico de falhas em máquinas rotativas mediante algoritmos de classificação de problemas que acometem tais equipamentos.

Este trabalho visa contribuir do ponto de vista científico com um estudo baseado em pouca informação obtida em campo, bem como com um algoritmo capaz de fornecer bons resultados a um custo computacional baixo, além de fornecer em paralelo diversas perspectivas para análise dos sinais, considerando condições de falhas em regimes de velocidade distintos, além de uma análise de sensibilidade do sistema considerando níveis, tanto de desbalanceamento quanto desalinhamento relativamente pequenos inicialmente, inclusive no diagnóstico de problemas combinados.

## 2 OBJETIVOS

O sucesso de toda pesquisa científica está diretamente ligado com a clareza com que o pesquisador enxerga tanto o ambiente da pesquisa, quanto os limites exigidos para que se torne viável o estabelecimento de metas e prazos. Visando estabelecer o que se almeja com o desenvolvimento desta pesquisa, foram definidos objetivos.

### 2.1 OBJETIVO GERAL

Desenvolver e sistematizar uma análise autônoma, capaz de classificar e identificar problemas de desalinhamento, desbalanceamento e a combinação dos problemas anteriores, por meio de um algoritmo computacional.

### 2.2 OBJETIVOS ESPECÍFICOS

Visando viabilizar o atingimento do objetivo geral da pesquisa, foram delimitados objetivos específicos responsáveis por nortear a evolução da pesquisa na direção e sentido adequados.

- Estabelecer tipos de problemas a serem investigados;
- Pesquisar e estabelecer melhor metodologia para coleta de dados;
- Desenvolver bancada experimental para coleta das informações necessárias;
- Adquirir equipamento capaz de capturar os dados;
- Aplicar metodologia de coleta de dados e coletar as informações;
- Pesquisar e definir técnica a ser empregada no pré-processamento dos dados;
- Pesquisar e definir topologia e arquitetura de rede capaz de fornecer os resultados esperados;
- Implementar algoritmo para pré-processamento e processamento das informações coletadas;
- Validar análise preliminar do algoritmo com software comercial;
- Organizar dados, importar no algoritmo e obter resultados;
- Analisar saídas e validar os resultados.

### 3 REFERENCIAL TEÓRICO

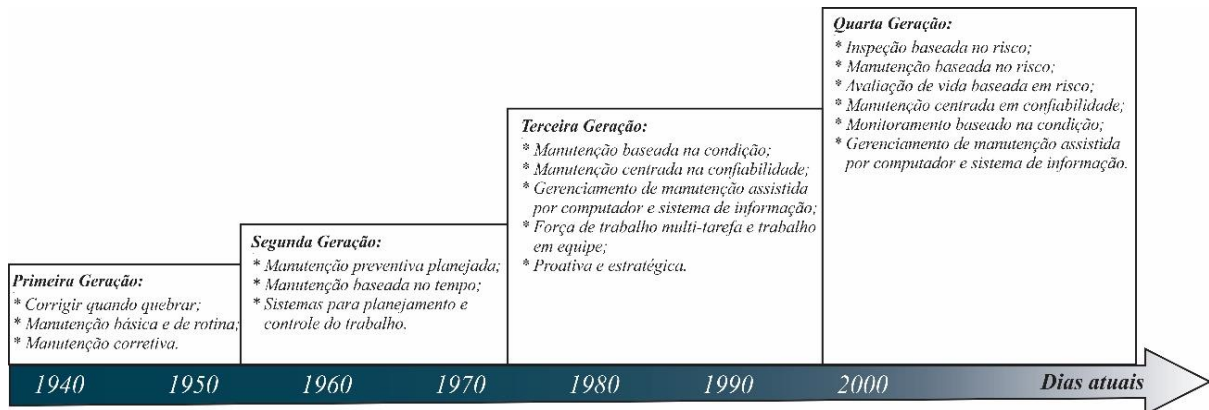
Neste capítulo são definidos e discutidos os principais conceitos relevantes ao completo entendimento de cada etapa desta pesquisa, bem como a evolução de tais conceitos ao longo do tempo.

#### 3.1 TÉCNICAS DE MANUTENÇÃO

Todos os sistemas de um modo geral, seja ele natural ou artificial, sofre alguma alteração com o decorrer da operação e tempo. Em virtude desta realidade, que está associada a fenômenos físicos e/ou químicos, foram desenvolvidos critérios e conceitos afim de manter os sistemas o mais próximo possível de seu nível inicial ou ideal de operação ou funcionamento. Deste pensamento básico surgiu todo um ramo da engenharia denominado manutenção. Desde então todos concordam que manutenção é uma necessidade, no entanto, a manutenção tem uma imagem negativa e as vezes é considerada um mal necessário. Mas, à medida que o paradigma da manufatura se transforma, devemos também começar a reconhecer o papel mutável da manutenção (Takata, 2004).

O desenvolvimento da filosofia por trás dos conceitos da manutenção moderna foram evoluindo com o passar do tempo, Moubray (1997) categorizou a evolução de tal filosofia depois de passados aproximadamente 60 anos desde seu início, início este considerado nos anos 1930. Nestes 60 anos Moubray (1997) considerou tal evolução distribuída em três gerações. Segundo Cooke (2003) e Maiti (2006) a partir dos anos 2000 incorporou-se a filosofia da manutenção, análises e inspeção baseadas no risco, incorporando aos períodos anteriores mais uma geração conforme mostrada na figura 3.

Figura 3 - Evolução das filosofias de manutenção



Fonte: Adaptado de Akhshab (2011)

De acordo com Piotrowski (2006), a indústria de um modo geral, independentemente de seu ramo de atuação, está permeada com alguns estilos específicos de manutenção. Na academia esses estilos são conhecidos como filosofias da manutenção e estão diretamente relacionados a evolução da manutenção. A forma como a operação da manutenção é usualmente organizada dá origem a quatro filosofias distintas ou categorias, que são elas:

- Manutenção corretiva (Breakdown or Run-to-failure maintenance)
- Manutenção preventiva (Preventive or time-based maintenance)
- Manutenção preditiva (Predictive or condition-based maintenance)
- Manutenção proativa (Proactive or prevention maintenance)

### 3.1.1 Manutenção corretiva

A manutenção definida como corretiva marca o início do pensamento do restabelecimento da capacidade de um determinado equipamento desenvolver o trabalho para o qual foi projetado. Este tipo de técnica se baseia em pouca quantidade de informação em relação ao equipamento, o que a torna uma técnica simples de implementar, no entanto não é necessariamente a mais eficaz ou eficiente. Piotrowski (2006) afirma que a filosofia básica deste tipo de manutenção é permitir que o equipamento opere até a ocorrência de um dano óbvio. Somente depois disso o reparo de tal dano deve ser providenciado. Estudos da sociedade norte americana de manutenção (1997) mostraram que o custo de operação nesta categoria de manutenção era por volta de \$18 dólares a cada CV de potência produzida por ano no ano de 2006. Este tipo de forma de exercer a manutenção é vantajoso apenas

quando a parada do equipamento não afeta a produtividade de uma planta, bem como quando os custos tanto de mão de obra quanto de material são insignificantes.

Tratando-se das desvantagens de tal abordagem podem-se citar que a manutenção opera constantemente de forma não planejada, sob condições de gerenciamento de crises com interrupções não planejadas na produção, assim como a exigência de um alto volume de peças em estoque visando uma reação cada vez mais rápida ao ocorrido. Esta é sem dúvida uma das maneiras mais ineficientes de se manter uma instalação industrial. Dentre as tentativas para redução dos custos da manutenção corretiva estão a compra de peças mais baratas e a contratação de mão de obra mais barata, que em sua grande maioria é também desqualificada, podendo até agravar o problema futuramente. Profissionais que atuam sob este tipo de filosofia de manutenção são em sua grande maioria insatisfeitos com o trabalho, pelo fato de comumente estarem sobrecarregados frequentemente com uma longa lista de atividades não finalizadas e com atividades emergenciais que muitas vezes geram convocações em horários de descanso remunerado. Infelizmente, mesmo sendo o primeiro tipo de filosofia na escala evolutiva das filosofias da manutenção, ainda existem inúmeras indústrias que operam sob este sistema.

### **3.1.2 Manutenção preventiva**

A manutenção preventiva vem com uma abordagem baseada no tempo. Tsai (2004) afirma que uma abordagem preventiva é mais eficiente que uma abordagem corretiva pelo fato de propor uma atuação que visa sempre manter o equipamento em operação evitando as perdas associadas as falhas inesperadas. De acordo com Maiti (2007) durante o período pós-segunda guerra até meados dos anos 70 as indústrias se tornaram cada vez mais complexas e cada vez mais dependentes de seu maquinário, em decorrência disso o custo de manutenção começou a crescer em relação ao custo de operação. De um modo geral esta filosofia de manutenção consiste em programar atividades de manutenção em intervalos de tempo predeterminados para cada tipo de componente, onde consertam-se ou substituem-se componentes danificados antes que ocorram problemas óbvios. Estudos da sociedade norte americana de manutenção (1997) mostram que se tal manutenção for realizada corretamente o custo de operação desta forma fica em torno de \$13 dólares por CV de potência produzido por ano (Piotrowsky, 2006). A vantagem deste tipo de abordagem torna-se ainda maior para equipamentos que não funcionam continuamente, principalmente



quando se dispõe de pessoal qualificado e tempo suficiente para executar o trabalho de manutenção preventiva.

As desvantagens deste tipo de manutenção são que a manutenção programada pode ser realizada cedo ou tarde demais, isto dependerá da escala de tempo definida para a intervenção em cada equipamento. Segundo Cassady (2010), o planejamento da manutenção preventiva deve incorporar a percepção de que se realizada muito cedo pode desperdiçar um potencial de produção, bem como se realizada muito tarde pode levar o equipamento a falha. Há também a possibilidade de se remover e descartar componentes em bom estado e instalação incorreta de novas peças, o que pode vir a causar problemas futuros no equipamento antes do tempo programado para a próxima intervenção.

### **3.1.3 Manutenção preditiva**

O desenvolvimento da técnica ou filosofia da manutenção preditiva visa minimizar as ineficiências ou desvantagens da metodologia anterior. Portanto a manutenção preditiva se baseia no monitoramento dos equipamentos, deste modo, atuando apenas se e quando as condições de operação e mecânicas estiverem sob alerta mediante o monitoramento de alguns parâmetros relacionados a saúde do equipamento ou componente, tais como: temperatura, degradação do lubrificante, vibração excessiva, etc. Quando o parâmetro escolhido estiver num nível inaceitável é um indicativo para que haja uma intervenção no equipamento. Contudo, para reparar o dano, o mesmo precisa ser desligado para que as operações possam ser realizadas, visando prevenir uma parada com um tempo maior devido a ocorrência de um problema de maior gravidade. Piotrowsky (2006) afirma que, se este tipo de filosofia for aplicado corretamente o custo cai para \$9 dólares por CV de potência produzido por ano, de acordo com estudos da sociedade americana de manutenção (1997). Este tipo de manutenção também permite que os reparos nos equipamentos possam ser agendados de forma planejada o que permite ganho de tempo para a compra dos materiais e peças necessários, o que reduz a necessidade de um elevado estoque de peças. Outra vantagem muito importante é que o trabalho de manutenção é executado apenas quando há real necessidade, promovendo assim um incremento na capacidade produtiva.

Ainda segundo Piotrowsky (2006) as desvantagens deste tipo de filosofia são que o trabalho de manutenção pode aumentar se o nível de degradação do equipamento for

avaliado incorretamente. Observar as condições inapropriadas de parâmetros como nível de vibração, temperatura ou qualidade da lubrificação requer além de um pessoal apto a tais análises, equipamentos de monitoramento o que torna a aquisição e análise mais fáceis. Portanto esses pré-requisitos demandam um investimento em treinamento para o pessoal interno. Uma alternativa muito empregada é a terceirização deste trabalho para um terceiro experiente em executar análises preditivas ou baseadas em condições. Entretanto, se uma organização aplica uma filosofia corretiva ou preventiva, ou seja, baseada na falha ou no tempo, o gerenciamento de produção deve estar em sintonia com esta nova filosofia, pois pode acabar sendo problemática caso o departamento de manutenção não possa comprar os equipamentos necessários, fornecer o treinamento necessário, ou dispor de capital para contratação de um terceiro, ou até mesmo não dispor de tempo para a coleta de dados necessários bem como não permitir o desligamento dos equipamentos quando identificada tal necessidade.

#### **3.1.4 Manutenção proativa**

Esta filosofia de manutenção utiliza todas as técnicas de manutenção preditiva ou preventiva discutidas nos tópicos anteriores. Essas técnicas são utilizadas em conjunto com a análise de causa raiz da falha, visando não apenas identificar ou indicar o problema, mas também para garantir que técnicas de reparo e instalação avançadas sejam realizadas, incluindo modificações no próprio equipamento, para evitar ou eliminar a ocorrência de problemas. Se aplicado corretamente, este tipo de estratégia de manutenção tem seus custos de manutenção em torno de \$6 dólares por CV de potência gerado por ano de acordo com pesquisa da sociedade americana de manutenção (1997). As vantagens desta abordagem são atingidas principalmente quando o pessoal é suficientemente qualificado para tal, quando se dispõe das ferramentas adequadas e tempo necessário para implementar e desenvolver tais atividades. Uma das principais características deste tipo de estratégia é a implementação de análises visando reduzir ou eliminar ocorrências repetitivas de um mesmo tipo de problema (Piotrowsky, 2006). Portanto, este tipo de estratégia atinge sua melhor performance quando é feito um esforço adicional na investigação da causa da falha sendo assim capaz de implementar maneiras de melhorar a confiabilidade do equipamento, o que de forma direta impacta no aumento da capacidade produtiva

devido ao aumento da disponibilidade do equipamento para que desenvolva sua atividade fim.

A principal desvantagem da aplicação de tal estratégia é que a sua aplicação requer funcionários extremamente experientes em práticas preventivas, preditivas e de manutenção proativa. Em muitos casos há a necessidade de terceirizar tal atividade, para que a equipe se dedique a fase de análise de causa de falha e em seguida possa auxiliar nos reparos ou modificações no projeto do equipamento. O que também requer treinamento adequado. Contudo, para que uma organização adote este tipo de filosofia é necessário prover todo esse aparato técnico e de pessoal, pois sem dispor destes recursos, associados a liberdade de atuar no processo quando necessário, torna-se impraticável a aplicação deste tipo de gestão de manutenção.


### **3.1.5 Técnicas de manutenção preditiva usualmente aplicadas a máquinas rotativas**

A automação moderna inclui principalmente três grandes áreas técnicas: controle, manutenção e gestão técnica. O alvo do controle é basicamente atingir boa qualidade e performance. Para a manutenção as metas são, alta confiabilidade e disponibilidade. No aspecto da gestão técnica os objetivos são, aumento de eficiência, e melhoria dos benefícios econômicos e sociais (Fu et al., 2004).

Visando os objetivos relacionados à manutenção citados no parágrafo anterior, faz-se necessária a aplicação de uma estratégia ou filosofia de manutenção. A filosofia de manutenção corretiva é um método bastante primitivo e potencialmente responsável por grandes perdas econômicas. Este tipo de filosofia é indicado apenas em casos onde não há risco a segurança, a detecção da falha é fácil e rápida, assim como o seu reparo. Infelizmente muitos dos ambientes industriais não se enquadram no perfil de aplicabilidade ideal da manutenção corretiva.

A manutenção baseada no tempo, ou agendada, acaba assumindo indiretamente que os equipamentos possuem um comportamento representado pela curva, mostrada na figura 4.

Figura 4 - Curva da banheira



Fonte: Adaptado de Fu (2004)

Entretanto as teorias mais atuais de confiabilidade mostram que este tipo de estratégia é adequado apenas para falhas que tenham uma característica clara de desgaste. Outro fator importante é que se a manutenção ocorrer na fase de desgaste, reduzirá a taxa de falha, entretanto este é um caso ideal que nem sempre ocorre. De fato, o período de manutenção é menor do que o ideal por questões de segurança. O que faz com que a manutenção ocorra na faixa onde a taxa de falha é constante. Todavia após as atividades de manutenção, a curva da banheira se move horizontalmente para a direita, e o equipamento é forçado a entrar numa nova fase de desgaste e uma maior taxa de falhas incipientes é trazida para o sistema. Vale a pena salientar que existem diversos equipamentos que não seguem este perfil de taxa de falha. Considerando que a manutenção preditiva é baseada na condição real orientada para a tendência, isso faz da filosofia de manutenção preditiva a mais indicada para o que se propõe nesta pesquisa.

Conforme mencionado em capítulos anteriores, esta tese se propõe a tornar mais autônomo o processo de identificação de falhas associadas a máquinas rotativas, usando para tal, técnicas de manutenção preditiva visando a predição de uma possível falha antes que esta ocorra. Esta iniciativa surge num esforço de melhoria tanto na confiabilidade quanto na disponibilidade de máquinas rotativas, visando minimizar a disparidade existente na aplicação de técnicas na direção da automação em ambientes voltados exclusivamente para manutenção.

Existem inúmeras técnicas e parâmetros capazes de fornecer informação acerca da saúde de um determinado equipamento, entretanto algumas técnicas são mais indicadas dependendo do tipo de equipamento e do perfil de operação do mesmo. As técnicas de manutenção preditivas mais empregadas em máquinas rotativas são as seguintes:

- Termografia;
- Tribologia;
- Ultrassom;
- Monitoramento de vibração.

#### 3.1.5.1 Técnicas preditivas: Termografia

Conforme mencionado anteriormente existem muitas técnicas preditivas disponíveis para a engenharia dos dias atuais, no entanto algumas são mais indicadas que outras para determinadas aplicações. É de suma importância ressaltar que tais técnicas não necessariamente precisam ser usadas individualmente para cada aplicação, em muitos casos é até indicado o uso de mais de uma técnica visando obter mais informações sobre mais parâmetros do equipamento. O uso de técnicas combinadas pode fornecer para o especialista um entendimento mais realista acerca da saúde do equipamento.

De acordo com Moblay (2002) a termografia é uma técnica de manutenção preditiva usada para monitorar condições de equipamentos, não apenas equipamentos elétricos. A instrumentação aplicada monitora a energia infravermelho emitida pela superfície do equipamento ou componente para determinar a condição de operação do mesmo. Para detectar anomalias térmicas é necessário um especialista técnico para definir os limiares de problemas incipientes no equipamento.

A tecnologia infravermelho, parte do pressuposto que todo corpo com uma temperatura acima do zero absoluto emite energia ou radiação. Radiação infravermelha é uma forma desta energia emitida. As emissões de infravermelho são emissões em curtos comprimentos de onda invisíveis sem uso de instrumentação específica. A intensidade da radiação emitida pelo corpo é função da temperatura de sua superfície, entretanto o uso deste método pode trazer algumas complicações devido ao fato de poderem ser detectadas três fontes de energia térmica: energia emitida pelo próprio objeto, energia refletida pelo objeto e energia transmitida pelo objeto. No entanto as energias transmitidas e refletidas pelo objeto podem ser filtradas e descartadas dos dados de análise.

Ainda de acordo com Moblay (2002) variações nas condições da superfície do objeto, tintas (inclusive cores) ou outros revestimentos de proteção e muitas outras variáveis podem afetar o fator de emissividade do equipamento. Além das energias transmitidas e refletidas o especialista deve considerar também a atmosfera entre o objeto e o

instrumento de medição. Vapor de água e outros gases absorvem radiação infravermelha. Muitos sistemas de monitoramento ou instrumentos dispõem de filtros que podem ser usados para minimizar ou evitar os efeitos da atenuação atmosférica, entretanto o usuário da ferramenta deve selecionar adequadamente os filtros para cada condição atmosférica para não prejudicar a acurácia dos dados obtidos. Portanto o uso desta técnica exige bastante cuidado, pois pode gerar dados que não necessariamente condizem com a realidade do equipamento.

Coletores ópticos, detectores de radiação, e algum tipo de indicador são os elementos básicos de um instrumento industrial de infravermelho. O funcionamento é relativamente simples, o coletor capta a energia sob forma de radiação e foca em um detector que por sua vez converte em um sinal elétrico, o instrumento eletrônico amplifica o sinal de saída e o processa de uma maneira que possa ser exibido pelo elemento de indicação.

#### *3.1.5.1.1 Tipos de sistemas de termografia*

Três tipos básicos de instrumentos são geralmente usados como partes efetivas de um equipamento de termografia, termômetros de infravermelho, scanners de linha e sistemas de imagens em infravermelho.

- **Termômetros de infravermelho:** termômetros de infravermelho ou radiômetros pontuais são projetados para fornecer a temperatura atual da superfície num único ponto, um ponto relativamente pequeno na superfície do equipamento ou componente. Esta técnica é comumente usada para monitorar temperaturas em capa de rolamento, enrolamento de motores e para checar pontualmente a temperatura em tubulações de processo.
- **Scanners de linha:** Este tipo de instrumento é projetado para fornecer dados de uma varredura unidimensional, ou seja, este instrumento fornece os valores comparativos da radiação ao longo de uma linha. Embora este tipo de instrumento forneça um campo de visão um pouco maior, ele é limitado em aplicações de manutenção preditiva.
- **Imagens em infravermelho:** A técnica de imagem em infravermelho ou imagem termal é capaz de fornecer as emissões de infravermelho de todo o equipamento ou processo analisado rapidamente. A maioria dos sistemas de imagens funcionam como uma câmera de vídeo, o usuário pode visualizar o

perfil de emissão térmica de uma área ampla simplesmente olhando através da tela do instrumento.

### 3.1.5.2 Técnicas preditivas: Tribologia

A tribologia é um termo (ciência) usado para se referir ao projeto e operação da dinâmica da estrutura de suporte do rotor de lubrificação do rolamento das máquinas. Duas técnicas principais são utilizadas em manutenção preditiva.

- **Análise do óleo lubrificante:** Trata-se de uma técnica de análise que determina a condição do óleo lubrificante utilizado em equipamentos elétricos ou mecânicos. Não se trata de uma ferramenta para determinar a condição de operação do maquinário ou para detectar possíveis modos de falha. Em termos simples, a análise do óleo lubrificante deve ser limitada a um programa proativo para conservar e prolongar a vida útil dos lubrificantes. As principais aplicações de tal análise são: controle de qualidade, redução do estoque de óleos lubrificantes e determinação ideal para trocas.
- **Análise de partículas de desgaste:** A análise de partículas de desgaste está relacionada com a análise do óleo pelo fato das partículas serem coletadas por meio de uma amostra de óleo lubrificante. A análise de tais partículas fornece informações diretas sobre as condições do desgaste da máquina. Da análise de tais partículas pode-se derivar informações a partir do estudo da forma, composição, tamanho e quantidade. São usados dois métodos no preparo das amostras de tais partículas:

**Espectroscopia ou análise espectrográfica** – Este método utiliza filtros graduados visando separar as partículas sólidas em tamanhos diferentes.

**Análise ferrográfica** – Este método separa as partículas por meio de um magneto, sendo assim, por este método é possível capturar apenas partículas de materiais magnéticos. Partículas de cobre ou alumínio não seriam capturadas por este método.

O método de análise de desgaste de partículas é uma ferramenta de análise de falhas muito útil e pode ser usada para entender a causa raiz de falhas catastróficas.

#### 3.1.5.3 Técnicas preditivas: ultrassom

Esta técnica é utilizada para analisar ruídos em alta frequência acima de 30.000 Hz, essas frequências mais altas são muito uteis na detecção de vazamentos que em sua grande maioria criam ruídos em alta frequência causado pela expansão ou compressão de fluidos a medida que vazam por um orifício. Esta técnica vem sendo empregada como parte do programa de manutenção preditiva de muitas fábricas, muitas destas fábricas estão tentando substituir a análise de vibração pela técnica de ultrassom, visando redução de custo. Muitas usinas estão usando medidores ultrassônicos para monitorar a integridade de rolamentos, acreditando que esta metodologia fornecerá resultados precisos. Entretanto esta percepção está equivocada, pois essa tecnologia é limitada a uma banda muito larga (30 KHz a 1 MHz) o que torna esta técnica incapaz de diagnosticar falhas incipientes em rolamentos ou máquinas, não podendo, por conta disto, definir causa raiz de níveis anormais de ruídos gerados por rolamentos e outros componentes da máquina. Deste modo, a técnica ultrassônica deve ser usada como uma técnica adicional para detecção de níveis anormais de ruídos no ambiente fabril ou vazamentos.

#### 3.1.5.4 Técnicas preditivas: Análise de vibração

As fábricas atuais em sua grande maioria consistem de sistemas eletromecânicos, por este motivo, o monitoramento da vibração é a principal ferramenta de manutenção preditiva. Assim como na técnica de ultrassom, a análise e monitoramento de vibração se baseia na detecção de ruídos. A análise de vibrações detecta e avalia ruídos na faixa de 1 a 30 KHz, ou seja, ruídos de baixa e média frequência, enquanto a técnica de ultrassom avalia ruídos acima de 30 KHz.

O monitoramento de vibração não se aplica apenas a máquinas rotativas. O sistema baseado em microprocessador usado para análise de vibração pode ser usado efetivamente em todo sistema eletromecânico não importando o quão complexo ele seja. O monitoramento da vibração deve ser focado em equipamentos críticos do sistema de produção. Cada um destes sistemas deve ser avaliado como uma máquina e não como componentes individuais, como engrenagens e rolamentos por exemplo. Esta metodologia permite ao analista detectar comportamentos anormais em sistemas complexos (Mobley, 2002).



Quando usado corretamente, o monitoramento de vibração é a ferramenta mais poderosa de manutenção preditiva disponível. A lógica dos diagnósticos deve ser guiada pela dinâmica de operação das máquinas e não simplificada pelos modos de falha (Piotrowsky, 2006).


Existem basicamente três tipos de sensores usados em análise de vibração:

- Acelerômetros
- Sismômetros (Sensores de velocidade)
- Sondas de proximidade

#### 3.1.5.4.1 Acelerômetros

Os acelerômetros são possivelmente os sensores de vibração mais populares hoje em dia muito usados para capturas em tampa de rolamento ou medições de revestimento. O material normalmente usado para gerar o sinal destes sensores é o quartzo ou uma cerâmica chamada titanato de zirconato de chumbo (PZT). Este tipo de material produz uma carga elétrica proporcional à força aplicada a ele. Existem várias configurações diferentes, mas elas são tipicamente fabricadas para serem sensores de compressão ou de cisalhamento. O material piezoelétrico deve ser colocado sob uma tensão (força pré-carregada) para medir forças de tensão ou compressão (figura 5). A montagem permanente desses sensores deve ser feita com cuidado para evitar distorção da caixa (Piotrowsky, 2006).

Figura 5 - Representação de um acelerômetro



Fonte: Adaptado de Piotrowsky (2006)

Tabela 1 - Vantagens e desvantagens no uso de acelerômetros


VANTAGENS	DESVANTAGENS
Ampla resposta de frequência.	Sensível a tensões induzidas quando montados permanentemente.
Pequeno e leve.	
Boa faixa de temperatura ambiente.	Requer um circuito de fonte de alimentação e amplificação.
Preços moderados.	

Fonte: Adaptado de Piotrowsky (2006)

#### 3.1.5.4.2 Sismômetros (Sensores de velocidade)

Os sismômetros são também conhecidos como sensores de velocidade (figura 6). Eles são geradores de tensão, à medida que o ímã permanente se move para frente e para trás dentro do invólucro, as linhas de fluxo magnético cortam os enrolamentos da bobina em torno do ímã produzindo uma corrente alternada. Quanto mais rápido o ímã se move, mais linhas são cortadas através dos enrolamentos e a tensão aumenta. Estes sensores são excelentes para medir o revestimento ou o movimento da carcaça do mancal.

Figura 6 - Representação de um sismômetro



Fonte: Adaptado de Piotrowsky (2006)

Tabela 2 - Vantagens e desvantagens no uso de um sismômetro


VANTAGENS	DESVANTAGENS
Sinal forte gerado pela bobina que pode ser transmitido por distâncias bem longas.	Fisicamente grandes e pesados em comparação com acelerômetros e sondas de proximidade.
Sinal auto gerado que não requer nenhuma fonte de alimentação especial ou circuitos.	Sinal de saída decai exponencialmente abaixo de 600 cpm.
Construção robusta, pode ser montado virtualmente em qualquer posição.	Relativamente caro e não fabricado por muitas empresas.
Resposta de frequência é boa para 300.000 cpm.	

Fonte: Adaptado de Piotrowsky (2006)

#### 3.1.5.4.3 Sondas de proximidade

Sondas de proximidade podem ser consideradas como indicadores sem contato mecânico, podendo medir deslocamento e distâncias diretamente. Uma pequena bobina achatada localizada na ponta da sonda induz um campo eletromagnético, quando uma superfície condutora é colocada perto deste campo magnético correntes são induzidas na superfície. À medida que a ponta da sonda é movida para a superfície a tensão do circuito cai, à medida que a sonda é afastada da superfície a tensão do circuito aumenta. Essas sondas são excelentes para monitoramento de vibração em eixos, onde o rotor é suportado em rolamentos do tipo deslizante, onde o componente CA (corrente alternada) do sinal mede a vibração radial. Essas sondas também são usadas para monitorar a posição axial de um rotor para determinar o desgaste em um rolamento por meio do componente CC (corrente contínua) do sinal.

Figura 7 - Esquema de funcionamento de uma sonda de proximidade



Fonte: Adaptado de Piotrowsky (2006)

Tabela 3 - Vantagens e desvantagens no uso de sondas de proximidade

<b>VANTAGENS</b>
Pequeno e leve.
Relativamente barato.
As medições não são virtualmente afetadas por lubrificantes ou gases.
Quando usado numa configuração bidimensional de canal duplo pode exibir movimento do eixo orbital dentro do rolamento.
Resposta de frequência varia de 0 a 300.000 cpm, tornando-se muito útil para aplicações em máquinas rotativas.
As sondas de proximidade também podem ser usadas para monitorar a posição física do desgaste do mancal deslizante dentro de um rolamento.
<b>DESVANTAGENS</b>
As sondas são geralmente fixadas permanentemente no mancal, exigindo montagem especial e colocação cuidadosa.
Imperfeições na superfície do eixo também serão observadas pela sonda e podem afetar significativamente o sinal.
As áreas danificadas do eixo que forem retrabalhadas por deposição de cromo são particularmente problemáticas, tendo em vista que a sonda ignora a superfície cromada e considera apenas a superfície áspera sob o cromo.
Requer fonte de alimentação e circuito de impedância correspondente.
Suscetível a tensões induzidas se os condutores da sonda estiverem nos condutos de condutores de alta tensão.

Fonte: Adaptado de Piotrowsky (2006)

Os dois parâmetros mais comumente utilizados em análise de vibração são amplitude e frequência. Da amplitude pode-se extrair uma indicação da severidade da vibração. Da frequência obtém-se uma indicação das fontes da vibração. Se os níveis gerais de amplitude de vibração estiverem altos em qualquer um dos locais do sensor, um teste mais detalhado deve ser feito com um analisador de espectro para auxiliar na

determinação da assinatura de vibração do maquinário. Tais análises costumam ser feitas atualmente utilizando principalmente a transformada rápida de Fourier (FFT).


### 3.2 PRINCIPAIS DEFEITOS ASSOCIADOS À MÁQUINAS ROTATIVAS

Existem inúmeras fontes originárias de vibrações mecânicas em máquinas rotativas, tais como: dissimetria, heterogeneidade no material do rotor, excentricidade, gradientes térmicos, desequilíbrio aerodinâmico, etc., entretanto trataremos de duas de suas principais fontes. Tais fontes são: desbalanceamento e desalinhamento.

Os problemas de desbalanceamento podem ser minimizados frequentemente ainda na etapa de projeto e montagem. Caso contrário, desbalanceamentos em níveis muito elevados podem acarretar um grande incremento nos custos de sua posterior adequação. De acordo com Piersol (2002) se tais adequações envolverem a remoção de material, esta solução pode afetar drasticamente a resistência do componente corrigido. Em caso de adição de matéria os requisitos de espaço físico disponível para os componentes podem ser uma restrição custosa.

Existem basicamente quatro tipos de desbalanceamento associado a rotores de máquinas rotativas, tratam-se do: desbalanceamento estático, acoplado, semi-estático e desbalanceamento dinâmico. A figura 8 exibe de um modo claro a implicação e complexidade do movimento vibratório associado aos tipos principais.

Figura 8 - Movimento vibratório de rotores desbalanceados



Fonte: Adaptado de Piersol (2002)

Nota-se na figura 8 que o desbalanceamento estático surge devido uma distribuição assimétrica da massa em torno do eixo de rotação, fazendo com que o eixo principal de inércia não coincida com o centro de gravidade da peça. No caso de um desbalanceamento estático o eixo principal de inércia, que está diretamente

relacionado com o centro de massa da peça, está paralelo ao eixo geométrico do rotor. Já no caso do desbalanceamento acoplado, o eixo principal de inércia e o eixo geométrico da peça se interceptam no seu centro de gravidade, isto ocorre devido a existência de massas opostas distribuídas nas extremidades do rotor conforme mostrado na figura 8. No caso do desbalanceamento semi-estático, as massas são opostas, porém assimétricas, o que desloca a intersecção dos eixos para um outro ponto não mais coincidindo com o centro de massa da peça. O caso mais comum trata-se do desbalanceamento dinâmico, pois este ocorre quando a distribuição das massas nas extremidades, não estão alinhadas, o que acaba alterando tanto a inclinação quanto a intersecção relativa aos eixos principal de inércia e geométrico da peça. Em nosso estudo consideraremos um desbalanceamento dinâmico.


O desalinhamento ocorre quando as linhas de centro de rotação de dois eixos não estão colineares entre si. Portanto, o desalinhamento é o desvio relativo entre o eixo da peça e o eixo colinear de rotação. Segundo Piotrowsky (2006) o desalinhamento entre eixos pode estar associado a uma ou a várias das seguintes condições:

- Falha do eixo resultante da fadiga
- Quebra nos eixos ou próximo aos acoplamentos e rolamentos
- Aumento do desgaste nos rolamentos, vedações ou acoplamentos
- Perda ou folga de parafusos da fundação
- Parafusos de acoplamento folgados ou quebrados
- Aumento do aquecimento dos acoplamentos
- Aumento da temperatura da carcaça e do óleo perto dos mancais
- Consumo excessivo de energia por parte do equipamento

O objetivo na correção ou predição de problemas de alinhamento está diretamente relacionada com a redução ou eliminação de tais efeitos nocivos ao equipamento, permitindo que sua vida útil seja prolongada.

Existem basicamente três tipos de desalinhamento: o desalinhamento angular, o desalinhamento paralelo e o desalinhamento combinado. A figura 9 exibe de um modo bastante visual e objetivo, a principal diferença entre tais tipos de desalinhamento.

Figura 9 - Tipos de desalinhamentos em máquinas rotativas



Fonte: Piotrowsky (2006)

A representação (A) mostra a configuração de um desalinhamento angular, ou seja, as linhas de centro dos eixos estão além de não colineares formando um certo ângulo entre si. A figura (B) mostra o desalinhamento paralelo. Neste caso as linhas de centro são paralelas, porém não colineares. A figura (C) exibe um caso combinado entre as condições angulares e paralelas. Em nosso estudo consideraremos um desalinhamento paralelo.

### 3.3 PROCESSAMENTO DE SINAIS DE VIBRAÇÃO

O processamento de sinais tanto digitais quanto analógicos tem sua origem nas chamadas transformadas de funções. As transformadas integrais foram desenvolvidas com o intuito de serem ferramentas poderosas na solução de problemas envolvendo certos tipos de equações diferenciais parciais, principalmente em casos onde sua manipulação e solução no domínio original eram difíceis de lidar. Sendo assim, a transformação integral se aplica principalmente a funções cujo domínio original impossibilita análise e solução da mesma, neste novo domínio a manipulação matemática e consequentemente a solução são mais práticas de se trabalhar. Encontrada a solução no domínio transformado deve-se então aplicar uma transformação inversa obtendo-se assim a forma da solução para a versão original do problema, ou seja, no domínio original da função.

De acordo com Deakin (1981), a teoria das transformadas tem uma longa história, se iniciando com Euler que escreveu o primeiro trabalho abordando o assunto em 1737. Vários outros trabalhos de Euler foram citados como relacionados ao tema das transformadas integrais por vários pesquisadores desde então. Lagrange também faz

investigações que avançam a teoria em seu trabalho (*“Recherches sur la nature, et la propagation du son”*) de 1759. Laplace traz sua contribuição acerca do tema no trabalho (*“Mémoire sur les suites”*) de 1779, trazendo um estudo de séries introduzindo a noção de uma função geradora para a sequência. Lacroix era um escritor de livros didáticos por excelência, e no melhor sentido desse rótulo, em 1800 ele publicou seu livro *“Traité des différences et des séries”*. Fourier e Poisson também trouxeram grandes contribuições, no entanto contribuições indiretas. Estas contribuições estão relacionadas a tentativas de resolver a equação de calor sob várias condições de contorno, Fourier começou a esboçar seu trabalho acerca da propagação do calor numa barra linear e em 1822 ele publicou o resultado de seu estudo intitulado *“Théorie analytique de la chaleur”*. Entretanto observou-se que para uma barra finita a solução é possível por meio da série de Fourier, tanto Laplace quanto Poisson consideraram o caso de uma barra infinita e acabaram por deduzir uma expressão integral usando em analogia a série de Fourier e encontraram uma expressão semelhante à de Cauchy. A contribuição dada por Cauchy foi uma matemática moderna da transformada de Laplace. Em primeiro lugar, ele escreveu um trabalho sobre o cálculo dos resíduos, depois escreveu suas análises extensas de aplicações da transformada de Fourier, bem como seu trabalho sobre métodos simbólicos. O primeiro de seus trabalhos publicados com o tema é um livro de memórias de 1823 sobre a integração de equações diferenciais parciais lineares. Em 1832, Liouville publicou três memórias preocupado com a questão dos derivados fracionários, além das integrais de Grunert e fórmula de inversão de Murphy que foram publicados no mesmo ano. Em 1837 Lobatto publica seu segundo trabalho acerca de integrações de equações diferenciais, em 1839 Abel teve seu trabalho publicado pela primeira vez (*“Sur les fonctions génératrices et leurs déterminantes”*). Boole também se interessou pela teoria dos operadores diferenciais e publicou em 1844, entretanto em seus trabalhos ele redescobriu um teorema sobre expansões parciais de frações encontradas anteriormente por Cauchy e Lobatto. Desde então até os anos de 1880 houve contribuições de Riemann, Mellin, Heine, Hankel e Hansen. A partir de 1880 Poincaré inaugura a era moderna ao mesmo tempo em que de forma independente Schlesinger and Mellin, Pincherle e depois Doetsch em 1937 com o trabalho *“Anwendung der Laplace-Transformation”*, livro que foi revisado extensivamente e expandido 1956 (*“Handbuch der Laplace-Transformation”*).



Desde então diversos trabalhos vêm sendo elaborados dando origem a várias aplicações de tais transformadas. As transformadas integrais mais conhecidas e aplicadas por matemáticos e engenheiros até os dias de hoje são as transformadas de Laplace e Fourier. As mais comumente utilizadas em análise de vibrações são as transformadas de Fourier e suas variações.

Segundo Mallat (2009) o trabalho de Fourier afirma que qualquer função periódica pode ser representada como uma série de sinusóides relacionadas harmonicamente. Essa ideia teve um impacto profundo na análise matemática, física e de engenharia, mas levou um século e meio para se entender a convergência das séries de Fourier e completar a teoria das integrais de Fourier. Hoje em dia existem implementações numéricas eficientes da transformada de Fourier como a FFT (Fast Fourier Transform) que permitem a análise de sinais de qualquer gênero sem precisar conhecer sua função.

### 3.3.1 Análise FFT (Fast Fourier Transform)

De acordo com Al-Badour (2011), a análise tradicional de sinais de vibração geralmente baseia-se na análise do espectro por meio da transformada de Fourier (FT – Fourier Transform). A análise de Fourier transforma um sinal  $s(t)$  de um domínio baseado em tempo para um domínio baseado em frequência, gerando assim o espectro  $S(\omega)$  que inclui todas as frequências constituintes do sinal (fundamental e seus harmônicos) e que é definido como:

$$S(\omega) = \int_{-\infty}^{\infty} s(t) e^{-i\omega t} dt \quad (3.1)$$

Portanto a integral que calcula o sinal no domínio da frequência do sinal contínuo no tempo é chamada de transformada contínua de Fourier. Segundo Penha (1999) esta transformada mede a similaridade existente entre o sinal  $s(t)$  e uma série de funções complexas senoidais harmonicamente relacionadas. A função exponencial corresponde a um impulso no domínio da frequência, portanto a transformada de Fourier possui a resolução máxima no domínio da frequência. Deste modo  $S(\omega)$ , projeção do sinal nas funções elementares, descreve precisamente o comportamento do sinal na frequência  $\omega$ .

A transformada rápida de Fourier (FFT) é uma evolução do modelo discreto da transformada de Fourier (DFT), onde o algoritmo FFT reduz a complexidade numérica sendo portanto um método numericamente mais eficiente para o cálculo das DFT's.

### **3.3.2 Análise PSD**

Conforme mencionado em tópico anterior a FFT representa a frequência média ao longo da aquisição dos dados de vibração num dado período de tempo, entretanto para casos onde ocorrem carregamentos estacionário aleatórios, tal análise não representa bem os dados obtidos. Como solução surge a análise PSD (Power Spectral density) que fornece uma relação entre a potência do sinal e sua frequência. A análise PSD leva em consideração o quadrado das amplitudes fornecidas pela análise FFT, e área abaixo da curva PSD é a variância da resposta, ou seja, o quadrado do desvio padrão.

### **3.3.3 Análise STFT**

Ao longo do tempo várias outras análises foram desenvolvidas a medida que a necessidade surgia. Uma análise de importância relevante na análise de dados não estacionários é uma análise que permite a visualização dos dados numa escala tempo-frequência. De acordo com Rioul (1991) a análise STFT (Short Time Fourier Transform) foi desenvolvida para explicitar os diferentes componentes espectrais ao longo do tempo principalmente num sinal não estacionário.

O princípio do método é baseado em janelas de tempo onde uma janela de dados, ou seja, uma função de ponderação num dado período  $T$  pela qual o registro de dados é um coeficiente aplicado antes da transformação dos mesmos pela transformada de Fourier. Frequentemente aplicado por convolução no domínio da frequência, o objetivo de uma janela de dados é minimizar os efeitos da descontinuidade que ocorre quando uma seção de sinal contínuo é unida em um loop por exemplo, bem como permitir a análise em separado de diferentes trechos do sinal.

### **3.3.4 Transformada Wavelet**

Conforme visto no tópico anterior a análise STFT fornece uma nova perspectiva em análise de sinais. Entretanto ainda existem algumas limitações para o uso de tal análise. Visando uma melhor compreensão da aplicabilidade das transformadas Wavelet, recapitular-se-á de um modo resumido a evolução dos métodos de análise

e pré-processamento dos sinais de vibração. De acordo com Debnath (1998) muitas das aplicações em análise de sinais não estacionários e processamento em tempo real são feitas usando a transformada de Fourier padrão, tanto no domínio do tempo quanto no domínio da frequência. A transformada de Fourier decompõe uma função ou sinal em ondas sinusoidais com diferentes amplitudes. Apesar desta técnica ter permitido um certo sucesso em tais análises, a transformada de Fourier convencional parece ser inadequada para o estudo de problemas transientes, ou para identificar fenômenos de curta duração. Uma das características notáveis da transformada de Fourier é que a integração do sinal é realizada sobre todo o domínio da amostragem, de modo que cada ponto do domínio real contribui para a análise da função de transformação. Isso torna difícil recuperar informações locais do sinal original através do uso do sinal transformado. Este é um dos principais motivos pelo qual o uso da transformada de Fourier é inadequada para certos tipos de problemas. Segundo Penha (1999) uma alternativa é dividir o sinal em fatias no tempo e em seguida calcular o conteúdo da frequência para cada fatia ou janela. Entretanto a resolução com a qual os dados podem ser observados está diretamente ligado ao tamanho de tal janela, o que implica na escolha de boa precisão em apenas um dos domínios por análise. A transformada wavelet foi desenvolvida como um mecanismo capaz de decompor um sinal em faixas de frequências relacionando a resolução de cada faixa com a frequência central da faixa por meio de um fator de escala, o que basicamente torna a wavelet capaz de boa localização no domínio do tempo e frequência.

As bases das wavelets, assim como a bases de Fourier, revelam a regularidade do sinal através da amplitude dos coeficientes, e sua estrutura permite uma rápida implementação em algoritmo computacional. As wavelets são bem localizadas e poucos coeficientes são necessários para representar as estruturas transitórias locais. Ao contrário das bases de Fourier, uma base wavelet define uma representação esparsa de sinais regulares por partes, que podem incluir transientes e singularidades. Em processamento de imagens, os grandes coeficientes wavelet estão localizados na vizinhança das bordas e texturas irregulares (Mallat, 2009).

### 3.4 REDES NEURAIS ARTIFICIAIS

O estudo das redes neurais artificiais foi motivado pelo desempenho do cérebro ao computar informações. De acordo com Haykin (1999) o cérebro humano tem a capacidade de computar de um modo diferente dos computadores digitais

convencionais, pois o cérebro é um computador altamente complexo, não linear e paralelizado. É capaz de organizar sua estrutura afim de realizar certos cálculos muitas vezes mais rápido que o computador digital mais rápido.

Haykin (1999) ainda afirma que, as redes neurais derivam seu poder computacional de uma estrutura distribuída massivamente paralela, além de sua capacidade de aprender e generalizar. Esta generalização está relacionada a capacidade de a rede produzir saídas razoáveis para entradas não encontradas durante o treinamento (aprendizagem). Portanto, esses recursos possibilitam que as redes neurais resolvam problemas complexos que são intratáveis. Ainda temos um longo caminho até que possamos desenvolver uma arquitetura tão complexa e potente como o cérebro humano, entretanto as redes neurais artificiais já são capazes de promover as seguintes propriedades e capacidades úteis:

- Não linearidade;
- Mapeamento de entrada-saída;
- Adaptatividade;
- Resposta evidencial;
- Informação contextual;
- Tolerância ao erro;
- Uniformidade de análise e forma.

Os dados obtidos a partir do pré-processamento dos sinais explicitados no capítulo anterior serão usados como entrada para aplicação de uma rede neural artificial. A seleção da rede neural a ser empregada na solução do problema é uma etapa de extrema importância para o sucesso da modelagem, pois nem todos os tipos de redes neurais artificiais são igualmente empregáveis para todas as classes de problemas. Segundo Germano (2007), as redes neurais artificiais são empregáveis em uma extensa gama de problemas. Dentre as aplicações podemos destacar:

- Otimização;
- Controle;
- Reconhecimento de padrões;
- Previsão de séries temporais;
- Processamento de dados;
- Mineração de dados.

Pode-se observar que as aplicações das redes neurais artificiais têm um caráter multidisciplinar podendo também ser aplicável a diversos problemas de engenharia.

### **3.4.1 Evolução dos modelos de redes neurais artificiais**

A primeira publicação que introduziu o primeiro modelo de redes neurais foi publicado em 1943 por McCulloch e Pitts. Neste trabalho eles desenvolveram um estudo sobre o comportamento dos neurônios biológicos. O principal intuito de tal pesquisa foi construir um modelo matemático que melhor aderisse aos fenômenos observados. A partir deste estudo foi possível concluir que a atividade do neurônio é binária, e que a atividade de qualquer sinapse inibitória previne a ativação do neurônio naquele instante. A primeira conclusão significa que um neurônio só estará num estado ativado se sua saída ultrapassar um determinado valor limite, caso isso não ocorra o neurônio não transmitirá a saída para outros neurônios da rede. Da segunda conclusão surgiu o conceito de peso associado aos neurônios, deste modo, na construção formal do neurônio um peso positivo representa a excitação da célula, e um peso negativo representa sua inibição.

O primeiro modelo de rede neural artificial implementado foi o perceptron em 1958 por Frank Rosenblatt. O perceptron é uma rede neural simples composta por uma camada de entrada e uma camada de saída. Neste tipo de rede a cada entrada é associado um peso e as saídas são as somas das entradas pelos respectivos pesos. Rosenblatt também estabeleceu algoritmos de treinamento não supervisionado, como o Kohonen, e supervisionados como o backpropagation. Apesar do perceptron conseguir resolver tudo o que ele consegue representar, viu-se que ele não seria capaz de representar uma simples função XOR e nos anos seguintes constatou-se que ele seria capaz de representar apenas funções linearmente separáveis.

Em 1972 Teuvo Kohonen desenvolveu um modelo conhecido como mapa auto organizável de características. Em 1982 houve outra evolução no campo das redes neurais artificiais devido a criação do modelo desenvolvido pelo físico John Hopfield, este modelo é conhecido como modelo de Hopfield. O modelo de Hopfield é um modelo do tipo feedback, sendo assim, existe uma conexão entre entrada e saída. Isto explica o fato deste modelo convergir para a mesma saída.

O algoritmo perceptron teve sua validade comprovada depois da implementação do modelo backpropagation, que possibilitou o incremento de mais uma camada de neurônios intermediários tornando assim possível a representação do problema XOR.

Com esta técnica de retro propagação, paralelamente com uma função limiar de valores fracionários é possível a representação de funções não lineares.


### 3.4.2 Principais arquiteturas de redes neurais artificiais

A arquitetura das redes neurais é de suma importância, pois estão relacionadas ao tipo do problema a que se aplicam. Conforme mencionado em tópico anterior as redes com camada única do tipo MCP, são aplicáveis apenas aos problemas linearmente separáveis. De acordo com Braga (2000) as redes recorrentes, são redes mais apropriadas na resolução de problemas que envolvem processamento temporal. Parâmetros importantes na definição da arquitetura das redes são: número de camadas, número de nós por camada, tipo de conexão entre os nós e topologia da rede.

Classificação quanto ao número de camadas:

Redes de única camada: neste tipo de rede existe apenas um nó a entrada e a saída.


Figura 10 - Redes de camada única



Fonte: Braga (2000)

Redes de múltiplas camadas: neste tipo de rede existe mais de um neurônio entre uma entrada e uma saída.

Figura 11 - Redes de múltiplas camadas




Fonte: Braga (2000)

Classificação quanto aos tipos de conexões

Feedforward, ou redes acíclicas: Neste tipo de rede a saída da  $i$ -ésima camada não é usada como entrada em neurônios de camadas de índice inferior ou igual a  $i$ .


Figura 12 - Redes do tipo Feedforward



Fonte: Braga (2000)

Feedback, ou cíclica: Neste tipo de rede existe uma conexão entre o neurônio da  $i$ -ésima camada e camadas de índices menores ou igual a  $i$ .

Figura 13 - Redes Feedback



Fonte: Braga (2000)

Classificação quanto a conectividade:

- Rede fracamente conectada
- Rede completamente conectada

### 3.4.3 Redes neurais artificiais no diagnóstico de falhas

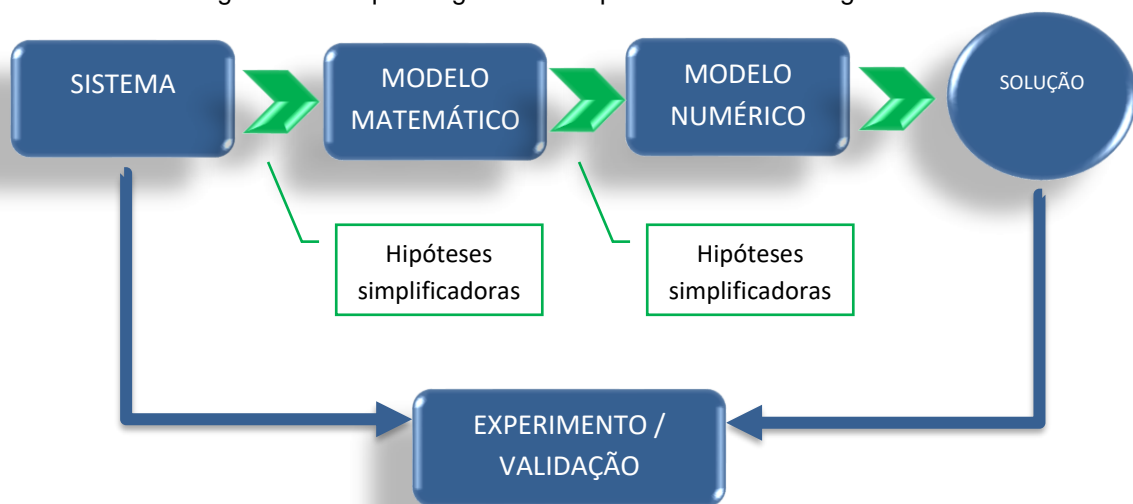
Conforme mencionado em parágrafos anteriores as redes neurais artificiais, devido à sua capacidade de aprender e generalizar relações funcionais não-lineares entre variáveis de entrada e saída, fornecem um mecanismo flexível para aprender e reconhecer falhas do sistema. Entre uma variedade de arquiteturas, notáveis são as redes feedforward e recorrentes. Redes de feedforward são comumente usadas em tarefas de reconhecimento de padrões, enquanto redes recorrentes são usadas para construir um modelo dinâmico do processo. Neste trabalho aplicar-se-ão duas das redes mais utilizadas no diagnóstico de falhas.

Segundo Walker (2014) o uso de redes neurais artificiais feedforward são ferramentas eficientes na detecção de falhas como desbalanceamentos e desalinhamentos em máquinas rotativas, de modo a automatizar o processo de localização destes tipos de falhas. Castejón (2015), complementa em seu trabalho admitindo que as redes neurais artificiais do tipo feedforward com funções de ativação de base radial promovem uma melhor caracterização e captura de padrões dado o modo como cada neurônio é ativado em um padrão diferente do espaço de entrada.

#### 4 MODELAGEM

Os modelos de um modo geral, visam representar as relações existentes entre as entradas do sistema modelado e suas saídas. Tais relações são mediadas pelos fenômenos físicos e/ou químicos envolvidos no sistema em estudo. Os fenômenos podem ser traduzidos em linguagem matemática, o que dá origem aos modelos matemáticos. Tais modelos representam cada parte do sistema físico real por meio de expressões matemáticas. Todavia, muitos dos fenômenos físicos são descritos por equações diferenciais que por sua vez se baseiam no cálculo infinitesimal que admite a premissa dos meios como um contínuo e em muitos casos por equações ainda sem uma solução analítica. Para que tais modelo sejam computacionalmente tratados, faz-se necessária a discretização dos modelos matemáticos, dando origem a um conjunto de expressões matemáticas de resolvidas por meio da solução de simples expressões algébricas, podendo ser empregadas em computadores. Tais expressões recebem o nome de modelo numérico. De um modo geral a modelagem pode ser exemplificada por meio do esquema da figura 14.

Figura 14 - Esquema geral de um processo de modelagem

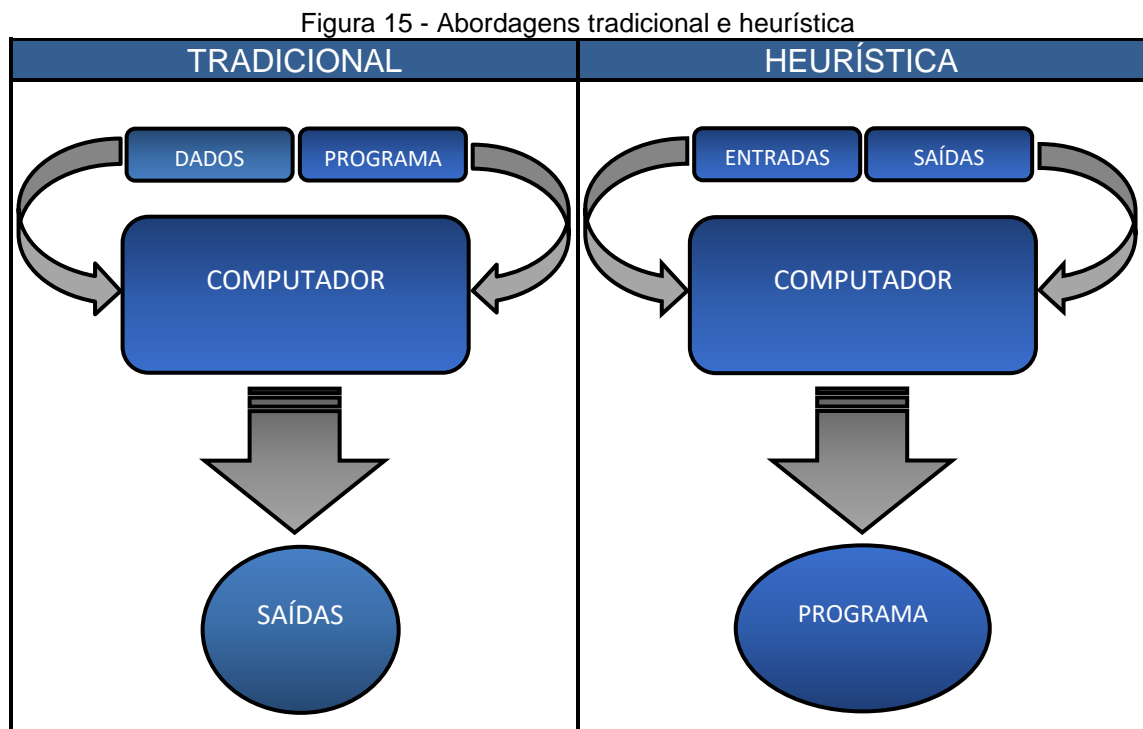


Fonte: O autor, 2018

A modelagem usual aplicada aos sistemas mecânicos, como os abordados neste trabalho, está em sua grande maioria relacionadas a modelagem algorítmica, usando como técnica principal o já estabelecido método dos elementos finitos. Entretanto, a aplicação desta técnica tradicional traz uma série de limitações por conta das simplificações empregadas tanto no modelo matemático quanto no modelo numérico,



bem como a exigência de um maior aparato computacional para a solução de tais problemas. Contudo, este trabalho se propõe a aplicar uma técnica heurística de programação usando redes neurais artificiais afim de correlacionar as entradas do sistema com as saídas, bem como estabelecer um padrão para reconhecimento de falhas incipientes como desbalanceamento e desalinhamento. A figura 15 exemplifica de um modo claro um paralelo entre as duas abordagens.

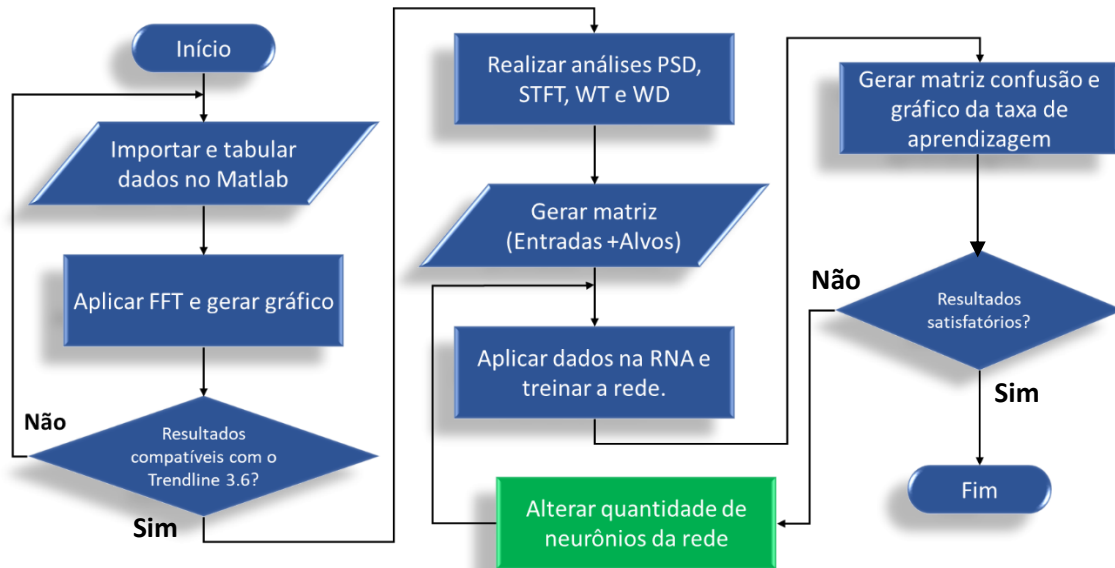


Fonte: O autor, 2018

A abordagem heurística permite ao algoritmo aprender tomando por base os dados de treinamento fornecidos pelos experimentos. Deste modo os pesos das conexões existentes entre os neurônios da rede são atualizados de modo a reproduzir o efeito causado pelo fenômeno físico e/ ou químico em estudo.

Visando permitir um melhor aprendizado da rede e fornecer o maior número de análises relevantes a um analista externo, foi desenvolvido o seguinte algoritmo que representa toda a modelagem empregada neste trabalho.

Figura 16 - Fluxograma do algoritmo




Fonte: O autor, 2018

Conforme mencionado no algoritmo da ferramenta proposta, foram usados os softwares, Matlab® e Trendline 3.6. A motivação para utilização de tais softwares é explicada nos tópicos seguintes deste capítulo.

As análises citadas no algoritmo estão descritas matematicamente ao longo dos tópicos seguintes, sendo um conjunto de técnicas aplicadas no pré-processamento dos sinais e em seguida um modelo de rede neural para captura do padrão para previsão de falhas. A figura 17 exhibe de um modo esquemático a forma como tais tratativas nos dados interagem no programa. O algoritmo computacional desenvolvido neste trabalho encontra-se no apêndice B.

Figura 17 - Esquema de processamento dos dados



Fonte: O autor, 2018

#### 4.1 MATLAB®

O Matlab® é um software muito usado no ramo da engenharia de um modo geral, principalmente por fornecer uma excelente capacidade de tratar dados armazenados como vetores ou matrizes. Além de possuir uma grande quantidade de funções em sua biblioteca, o que torna o processo de construção de um algoritmo mais simples, limpo e direto. Isto sem limitar o usuário, pois tais blocos de funções podem ser editados a depender da necessidade do usuário. Outro fator de suma importância é que muitos pesquisadores constantemente otimizam a programação de tais funções impactando em redução do custo computacional para rodar as aplicações.

#### 4.2 TRENDLINE 3.6

O Trendline 3.6 é o software baseado em servidor para o Detector III da FAG. Tal detector é projetado apenas para gravação dos dados medidos. Toda a rota para a obtenção dos valores de vibração, bem como todas as configurações de monitoramento do sistema a ser medido é criada no Trendline que está em sua versão 3.6. Existem diversos outros softwares analisadores de vibração no mercado, entretanto pelo simples fato do detector usado para a coleta de dados do experimento ser o Detector III da FAG usou-se o Trendline 3.6 como analisador dos dados para efeito de validação inicial do algoritmo desenvolvido no Matlab® conforme consta no algoritmo da ferramenta desenvolvida neste trabalho.

#### 4.3 ANÁLISE FFT

Muitas das análises produzidas para dados de vibração determinísticos e aleatórios requerem o cálculo da transformada finita de Fourier. Em termos computacionais, onde o registro de amostra  $s(t) = s(n\Delta t)$ , esta transformada de Fourier, é chamada de transformada discreta de Fourier (DFT – Discrete Fourier Transform), é dada pela seguinte expressão:

$$S(m\Delta f) = \Delta t \sum_{n=0}^{N-1} s(n\Delta t) \exp[-j2\pi\Delta f n\Delta t]; m = 0, 1, 2, \dots, (N - 1) \quad (4.1)$$

Em 1965 os pesquisadores Cooley e Turkey implementaram um algoritmo que aumentou de forma notável o cálculo das DFT's, este algoritmo foi batizado de FFT (Fast Fourier Transform). Observe que a DFT define  $N$  valores de frequência discreta para  $N$  valores de tempo discretos com uma resolução de frequência definida por:

$$\Delta f = \frac{1}{N\Delta t} \quad (4.2)$$

Os analisadores FFT fazem uso do algoritmo FFT para calcular os espectros de blocos de dados. Conforme mencionado o algoritmo FFT é uma maneira eficiente de calcular a transformada discreta de Fourier, que por sua vez trata-se de uma aproximação finita e discreta da transformada integral de Fourier. As equações dadas para DFT assumem sinais de tempo real. O algoritmo FFT faz uso das seguintes versões, que se aplicam igualmente a séries temporais reais ou complexas:

$$S(m) = \Delta t \sum_{n=0}^{N-1} s(n\Delta t) \exp(-j2\pi\Delta f n\Delta t) \quad (4.3)$$

$$s(n) = \Delta f \sum_{m=0}^{N-1} S(m\Delta f) \exp(j2\pi\Delta f n\Delta t) \quad (4.4)$$

Essas equações fornecem os valores de espectro  $S(m)$  nas  $N$  frequências discretas  $m\Delta f$  e fornecem a série temporal  $s(n)$  nos  $N$  pontos de tempo discretos  $n\Delta t$ .

Enquanto as equações da transformada de Fourier são integrais infinitas de funções contínuas, as equações de DFT são somas finitas, mas tem propriedades semelhantes. A função que está sendo transformada é multiplicada por um vetor unitário rotativo  $\exp(\pm j2\pi\Delta f n\Delta t)$ , que gira (em pulsos discretos para cada incremento do parâmetro do tempo  $n$ ) a uma velocidade proporcional ao parâmetro de frequência  $m$ . O cálculo direto de cada componente de frequência requer multiplicações e adições complexas de  $N$  e, assim, calcula-se todo o espectro.

O algoritmo FFT fatora a equação de tal forma que o mesmo resultado seja alcançado em aproximadamente  $N \log_2 N$  operações em comparação com  $N \times N$  operações. Isso representa um aumento de velocidade enorme. Vale salientar que não há perda de qualidade dos resultados. Este algoritmo vem sendo usado por pesquisadores desde a década de 60, existem algumas variações desenvolvidas posteriormente capazes de melhorar ainda mais o desempenho do método já implementado em muitos softwares comerciais como o Matlab® por exemplo.

Existem algumas propriedades inerentes da DFT e FFT em comparação com a transformada contínua. Pelo fato de o espectro estar disponível apenas em frequências discretas, a função de tempo é implicitamente periódica (assim como para as séries de Fourier). O tempo periódico é:

$$T = n\Delta t = 1/\Delta f \quad (4.5)$$

Onde,

$N$  = Número de amostras na função tempo e espectro de frequência

$T$  = Função de comprimento de registro correspondente de tempo

$\Delta t$  = Espaçamento da amostra de tempo

$\Delta f$  = Espaçamento da linha (eixo) de frequência =  $1/T$

Devido a periodicidade do espectro, a última metade ( $m = N/2$  a  $N$ ) representa, na verdade, os componentes de frequência negativa ( $m = -N/2$  a  $0$ ). Para amostras de tempo com valor real (o caso mais frequente), os componentes de frequência são determinados em relação aos componentes de frequência positiva pela equação ( $S(-m) = S^*(m)$ ) e o espectro é dito como sendo conjugado. Portanto, nos casos mais frequentes onde  $s(n)$  são valores reais, é necessário apenas calcular o espectro em  $m = 0$  a  $N/2$ , e o tamanho da transformação pode ser dividido por um dos dois procedimentos mostrados em sequência:

- As  $N$  amostras reais são transformadas como se representassem valores complexos  $N/2$ , e esse resultado é então manipulado para dar o resultado correto.
- Uma análise de zoom é executada, no meio do intervalo da banda base para obter o mesmo resultado.

Deste modo, a maioria dos analisadores FFT produz um espectro (complexo) com um número de linhas espectrais igual à metade do número de amostras de tempo (real) transformadas. Para evitar os efeitos do aliasing, nem todos os valores do espectro calculados são válidos, e é comum exibir, digamos, 400 linhas para uma transformação de 1024 pontos ou 800 linhas para uma transformação de 2048 pontos.

#### 4.4 ANÁLISE PSD

Conforme mencionado no capítulo anterior a análise PSD leva em consideração o quadrado das amplitudes fornecidas pela análise FFT, e área abaixo da curva PSD é a variância da resposta, ou seja, o quadrado do desvio padrão.

$$\sigma_s^2 = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T [s(t) - \mu_s]^2 dt \quad (4.6)$$

Esta medida está relacionada a densidade da potência do sinal ao longo do tempo.

#### 4.5 ANÁLISE STFT

De acordo com Galvão et al (2001), a STFT visa resolver os problemas citados anteriormente dividindo o sinal em regiões por meio da aplicação de uma função de janelamento que permite tal processamento. Matematicamente a STFT de um sinal  $f(x)$  é dada por:

$$F(p, \omega) = \sum_{x=0}^{N-1} f(x)w(x-p)e^{-i\omega x} \quad (4.7)$$

Onde  $w(x-p)$  é uma função de janelamento, responsável pela limitação do trecho que está sendo analisado no sinal. Sendo o parâmetro  $p$  responsável pela posição da janela dentro do sinal.

#### 4.6 ANÁLISE WAVELET

O desenvolvimento das wavelets se inicia em 1910, quando Haar construiu uma função constante por partes.

$$\psi(t) = \begin{cases} 1 & \text{se } 0 \leq t < 1/2 \\ -1 & \text{se } 1/2 \leq t < 1 \\ 0 & \text{caso contrário} \end{cases} \quad (4.8)$$

As dilatações e translações que geram uma base ortonormal,

$$\left\{ \psi_{j,n}(t) = \frac{1}{\sqrt{2^j}} \psi\left(\frac{t-2^j n}{2^j}\right) \right\}_{(j,n) \in \mathbb{Z}^2} \quad (4.9)$$

Do espaço  $L^2(\mathbb{R})$  de sinais com energia finita,

$$\|f\|^2 = \int_{-\infty}^{+\infty} |f(t)|^2 dt < +\infty \quad (4.10)$$

Escrevamos  $\langle f, g \rangle = \int_{-\infty}^{+\infty} f(t)g^*(t)dt$ , o produto interno em  $L^2(\mathbb{R})$ . Qualquer sinal de energia finita  $f$  pode ser representado por seus coeficientes de produto interno de wavelet.

$$\langle f, \psi_{j,n} \rangle = \int_{-\infty}^{+\infty} f(t)\psi_{j,n}(t)dt \quad (4.11)$$

E recuperado somando-os nesta wavelet de base ortonormal:

$$f = \sum_{j=-\infty}^{+\infty} \sum_{n=-\infty}^{+\infty} \langle f, \psi_{j,n} \rangle \psi_{j,n} \quad (4.12)$$

Ainda de acordo com Mallat (2009), cada wavelet Haar  $\psi_{j,n}(t)$  tem uma média zero sobre o seu suporte  $[2^j n, 2^j(n+1)]$ . Se  $f$  é localmente regular e  $2^j$  é pequeno, então é quase constante durante esse intervalo e o coeficiente wavelet  $\langle f, \psi_{j,n} \rangle$  é próximo de zero. Isso significa que grandes coeficientes wavelet estão localizados apenas em transições nítidas de sinal.

Por volta de 1980, Stromberg encontrou uma função linear por partes  $\psi$  que também gera uma base ortonormal e fornece melhores aproximações de funções suaves. Meyer não estava ciente desse resultado e, motivado pelo trabalho de Morlet e Grossmann sobre a transformada contínua de wavelets, ele tentou provar que não existe uma wavelet regular  $\psi$  que gere uma base ortonormal. Esta tentativa foi um fracasso, uma vez que ele acabou construindo toda uma família de bases de wavelets ortonormais, com funções  $\psi$  que são infinitamente continuamente diferenciáveis. Este foi o impulso fundamental que levou a uma busca generalizada por novas wavelets de bases ortonormais, que culminaram nas célebres wavelets Daubechies de suporte compacto.

Como resultado da evolução dos trabalhos citados em parágrafo anterior a formulação matemática compacta usual de um sinal  $f(x)$  é a seguinte:

$$Wf(a, b) = \int_{-\infty}^{+\infty} f(x) \psi_{a,b}(x) dx \quad (4.13)$$

Que no domínio discreto com  $N$  pontos torna-se


$$Wf(a, b) = \sum_{x=0}^{N-1} f(x) \psi_{a,b}(x) \quad (4.14)$$

A função  $\psi_{a,b}(x)$ , é chamada de wavelet, e é derivada de uma função  $\psi(x)$  através da transformação a seguir:

$$\psi_{a,b}(x) = \frac{1}{\sqrt{a}} \psi\left(\frac{x-b}{a}\right) \quad (4.15)$$

A função  $\psi(x)$  é denominada de wavelet-mãe e existem diversas formas para tal função onde ao longo do tempo os pesquisadores vão implementando novas formas. Neste trabalho a forma usada no pré-processamento dos dados é a wavelet-mãe proposta por Daubechie.


Figura 18 - Representação da Wavelet-mãe proposta por Daubechie



Fonte: Galvão (2001)

De acordo com comparação de Galvão et al (2001), os parâmetros da STFT levam em consideração posição e frequência com uma largura fixa de janela. Já na transformada wavelet  $b$  também representa posição (ou translação da wavelet), mas  $a$  representa um parâmetro de escala e está associado à largura da janela. A figura 19 explicita o impacto do parâmetro  $a$  na largura da janela.

Figura 19 - Representação do impacto do parâmetro  $a$  na largura da janela



Fonte: Galvão (2001)

Na figura 19 pode-se notar o efeito da modificação na escala para uma wavelet 'db4'. Em linha tracejada está representada a wavelet-mãe e em linha contínua a wavelet com escala  $a = 2$ . Desta forma em regiões de maior frequência usando o fator de escala pode-se alterar o tamanho da janela e por meio do fator de translação pode-se percorrer todo o sinal desejado.

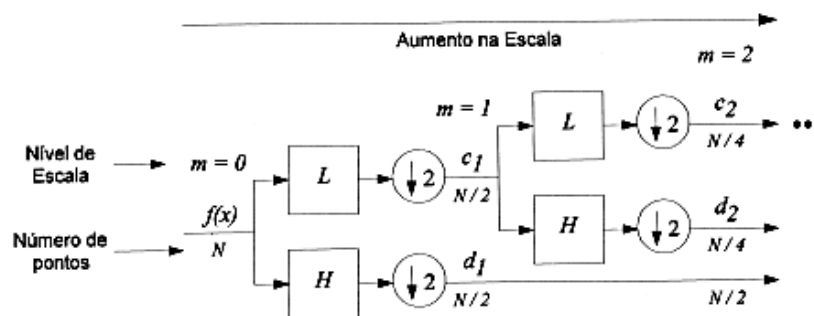


Conforme pode-se notar, existe uma semelhança entre as expressões 4.17 e 4.18. Isto se dá pelo fato de não ser viável calcular a transformada wavelet para todos os valores de  $a$  e  $b$  no conjunto dos números reais. O que tornou o uso corriqueiro da seguinte restrição:

$$a = 2^m, b = n2^m \quad (4.16)$$

Onde  $m$  e  $n$  são números inteiros. Sendo assim, o resultado da aplicação da transformada wavelet sobre um sinal é um conjunto de coeficientes indexados por  $m$  (nível de escala) e  $n$  (índice de translação). O que faz com que a informação do sinal seja preservada e o número de coeficientes seja igual ao número de variáveis. Além de tornar possível a implementação computacional de um modo mais prático do algoritmo de decomposição em árvore proposto por Mallat (Figura 20).

Figura 20 - Algoritmo de decomposição em árvore proposto por Mallat



Fonte: Mallat (2009)

Na figura 20 os blocos  $L$  e  $H$  são uma representação de filtros digitais passa-baixas e passa-altas, respectivamente, que estão associados a wavelet adotada na análise. O símbolo seguido dos blocos dos filtros representa uma operação de sub-amostragem, que consiste em eliminar todos os coeficientes de índice par, isto faz com que o número total de pontos permaneça constante após a aplicação da transformada wavelet.

A cada nível de escala  $m$ , surgem dois conjuntos: um conjunto de coeficientes wavelet  $d_m$  e um conjunto de coeficientes de aproximação  $c_m$ . O conjunto  $c_m$  passa logo em seguida por uma nova divisão, de modo que são gerados os coeficientes  $c_{m+1}$  e  $d_{m+1}$  e assim sucessivamente. Tais operações podem ser explicitadas nas equações 4.17

e 4.18, em que as sequencias  $l(k)$  e  $h(k)$ , de  $K$  pontos cada uma, são responsáveis, respectivamente pela filtragem passa-baixas e passa-altas.

$$c_{m+1}(n) = \sum_{k=0}^{K-1} l(k)c_m(2n - k + 1) \quad (4.17)$$

$$d_{m+1}(n) = \sum_{k=0}^{K-1} h(k)c_m(2n - k + 1) \quad (4.18)$$

É importante notar que a expressão da wavelet-mãe não é usada no algoritmo de decomposição em árvore, a wavelet de Daubechie não apresenta uma formulação matemática explícita, é obtida de forma numérica a partir das sequencias  $l(k)$  e  $h(k)$ . A saída da árvore de decomposição depende do número de níveis de escala empregados (Galvão et al., 2001).


#### 4.7 REDE NEURAL

Redes neurais artificiais são construídas com um certo número de unidades de processamento únicas que são chamadas de neurônios. O modelo de McCulloch-Pitts é o modelo de neurônio clássico e fundamental e é descrito pela equação:

$$y = \sigma(\sum_{i=1}^n w_i u_i + b) \quad (4.19)$$

Onde  $u_i, i = 1, 2, \dots, n$ , denota os neurônios de entrada,  $b$  é o limiar (bias- “threshold”),  $w_i$  denotam os coeficientes de peso sináptico,  $\sigma$  é a função de ativação não linear. Patan (2008) afirma que existem muitas modificações do modelo de neurônios acima. Isso é resultado da aplicação de diferentes funções de ativação. McCulloch e Pitts usaram o degrau unitário como uma função de ativação. Em 1960, Widrow e Hoff aplicaram a função de ativação linear e criaram assim o neurônio Adaline. Nos últimos anos, as funções da tangente sigmóide e hiperbólica têm sido mais frequentemente utilizadas. A escolha de uma função de ativação adequada depende de uma aplicação específica da rede neural. A figura 21 explicita o esquema com  $n$  entradas e uma saída.


Figura 21 - Representação de uma rede com n entradas e uma saída



Fonte: Patan (2008)

Nas redes do tipo perceptron multicamadas os neurônios estão agrupados em camadas. Estas redes estão estruturadas como uma camada de entrada, uma ou mais camadas intermediárias (ocultas) e uma camada de saída. As unidades de entrada são responsáveis pelo processamento preliminar dos dados de entrada e em seguida os transportar para os elementos da camada oculta. Tais redes são projetados de tal modo que cada neurônio da camada anterior está ligado com cada elemento da camada seguinte. A cada conexão possível está associado um peso que são adequados dependendo da tarefa à qual a rede é destinada a resolver, a cada saída é gerado um vetor resposta. A figura 22 exibe a tipologia de uma rede do tipo multicamadas.

Figura 22 - Rede de tipologia multicamadas



Fonte: Patan (2008)

Não há dúvida de que uma das principais vantagens das redes neurais é a capacidade de aprendizado e adaptação. Tal capacidade deriva do treinamento das redes. Do ponto de vista técnico o treinamento das redes é nada mais que a determinação dos pesos entre unidades de processamentos vizinhas. O algoritmo fundamental para

o treinamento de uma rede multicamadas feedforward é o back-propagation. Este algoritmo fornece uma forma sistemática de alterar o valor arbitrário do peso atribuído à conexão entre as unidades de processamentos de unidades vizinhas. Trata-se de um algoritmo iterativo e é baseado na minimização de um erro de soma quadrática utilizando o método de gradiente de otimização. O método para a modificação dos pesos se baseia na seguinte expressão:

$$w(k + 1) = w(k) - \eta \nabla J(w(k)) \quad (4.20)$$

Onde  $w(k)$  indica o vetor de peso no tempo discreto  $k$ , e  $\eta$  é a taxa de aprendizado, e  $\nabla J(w(k))$  é o gradiente do índice de desempenho  $J$  em relação ao vetor de peso  $w$ .

O algoritmo de retropropagação é amplamente utilizado e, nos últimos anos, suas numerosas modificações e extensões foram propostas. Infelizmente, o algoritmo padrão da BP é lentamente convergente. Para superar este inconveniente, técnicas modificadas podem ser usadas. Uma delas usa o fator momentum. Outra maneira de acelerar a convergência do algoritmo de treinamento é usar parâmetros adaptáveis. Patan (2008) afirma que várias outras modificações do algoritmo back-propagation se provaram úteis. Dos quais pode-se destacar, o algoritmo quickprop, retropropagação resiliente ou métodos do gradiente conjugado (método aplicado neste trabalho).

#### 4.8 TRATAMENTO DOS DADOS

A coleta de dados foi realizada por meio do detector III da Fag. Os dados obtidos foram transferidos para o software Trendline 3.6 e puderam ser exportados tanto no formato “.tr3” (Trendline 3.6) que é o formato padrão para ser lido pelo software Trendline 3.6 ou no formato “.csv” (Comma separated values), este tipo de formato de dados é ideal para um tratamento inicial eficaz dos dados pra importação no Matlab®, pelo fato da separação dos dados por meio de vírgulas permitir uma leitura em formato de matriz ou até mesmo podendo ser processado diretamente no Excel.

Os dados podem ser importados com o auxílio do assistente de importação do Matlab® e gravados em matrizes. Vale salientar que apenas os dados de tempo e amplitude foram considerados para gerar todas as análises. Foram importados dados de

deslocamento, velocidade e aceleração das posições radial vertical, radial horizontal e axial das medições do mancal LA (lado do acoplamento).

O processo de geração dos gráficos no domínio da frequência se deu por meio da aplicação da função FFT presente no toolbox do Matlab® e comparadas aos gráficos gerados automaticamente no Trendline 3.6. As análises subsequentes foram análise PSD, STFT e transformada wavelet. As saídas da decomposição wavelet geraram vetores que foram correlacionados com um alvo para fins de treinamento da rede.

Os alvos foram definidos com base nas quantidades de situações possíveis levando em consideração o estado saudável, desbalanceado e a combinação dos dois problemas para os diversos níveis de intensidade e velocidade. Com o objetivo de minimizar os desvios na etapa de treinamento, os alvos foram normalizados num padrão binário podendo assumir os seguintes valores:

Tabela 4 - Definição dos vetores alvo

Vetores alvo					
Velocidade	Saudável	1	0	0	0
	Desbalanceado N	0	1	0	0
	Desalinhado N	0	0	1	0
	Combinado (N/ N)	0	0	0	1

Fonte: O autor, 2018

Tais vetores foram gerados seguindo o mesmo padrão para as demais velocidades considerando os três níveis (N) em que os problemas foram avaliados, deste modo, para cada velocidade existem 10 vetores alvo.

Os dados obtidos foram pré-processados por meio das técnicas anteriormente citadas e as saídas que compuseram os vetores de entrada da rede neural artificial tem uma dimensão igual a 32 dados. As redes foram estruturadas com 32 neurônios de entrada, 4 neurônios de saída variando-se a quantidade de neurônio da camada intermediária de 10 (dez) em 10 (dez) até 100 (cem).

Tendo em vista que o sinal em análise é um sinal considerado estacionário e que os espectros obtidos foram fracionados em entradas de tamanho igual ao tamanho do vetor de entrada (32). Foi avaliado o impacto causado pela quantidade de neurônios na camada oculta, o que está diretamente relacionado com um incremento na

quantidade de ponderações decorrentes da variação do número de possíveis ligações entre os nós de entrada e os neurônios da camada intermediária. A quantidade de neurônios da camada oculta deve fornecer resultados diferentes para a rede. Os nós de saída foram representados pelos vetores alvo definidos na tabela 4.

## 5 MATERIAIS E MÉTODOS

Este capítulo se destina a explicitar os procedimentos metodológicos empregados na pesquisa, visando o atingimento dos objetivos definidos como meta do presente trabalho. Neste texto foram definidos como os parâmetros relevantes à definição e estruturação da pesquisa foram coletados, bem como os equipamentos necessários para efetivação de sua coleta.


### 5.1 DEFINIÇÃO DO EXPERIMENTO

O objetivo geral desta pesquisa é gerar um diagnóstico automático por meio da aplicação de uma RNA visando identificar os seguintes defeitos iminentes:

- Desbalanceamento
- Desalinhamento
- Defeitos combinados (desbalanceamento/ desalinhamento)

O procedimento experimental consiste em coletar dados de vibração de uma máquina rotativa composta por um motor de indução trifásico Weg de potência 0,33 CV de dois pólos e um acoplamento ligado a um eixo sobre uma bancada montada sobre calços amortecedores, conforme mostrado na figura 23.

Figura 23 - Representação da bancada experimental e seus componentes



Fonte: Cavalcante (2017)

Os dados de vibração foram coletados com o auxílio de um conjunto de medição de dados de vibração modelo Detector-III da empresa FAG composto por uma IHM + 1 acelerômetro.

Os dados de vibração foram coletados do lado do acoplamento (LA) em três posições distintas:



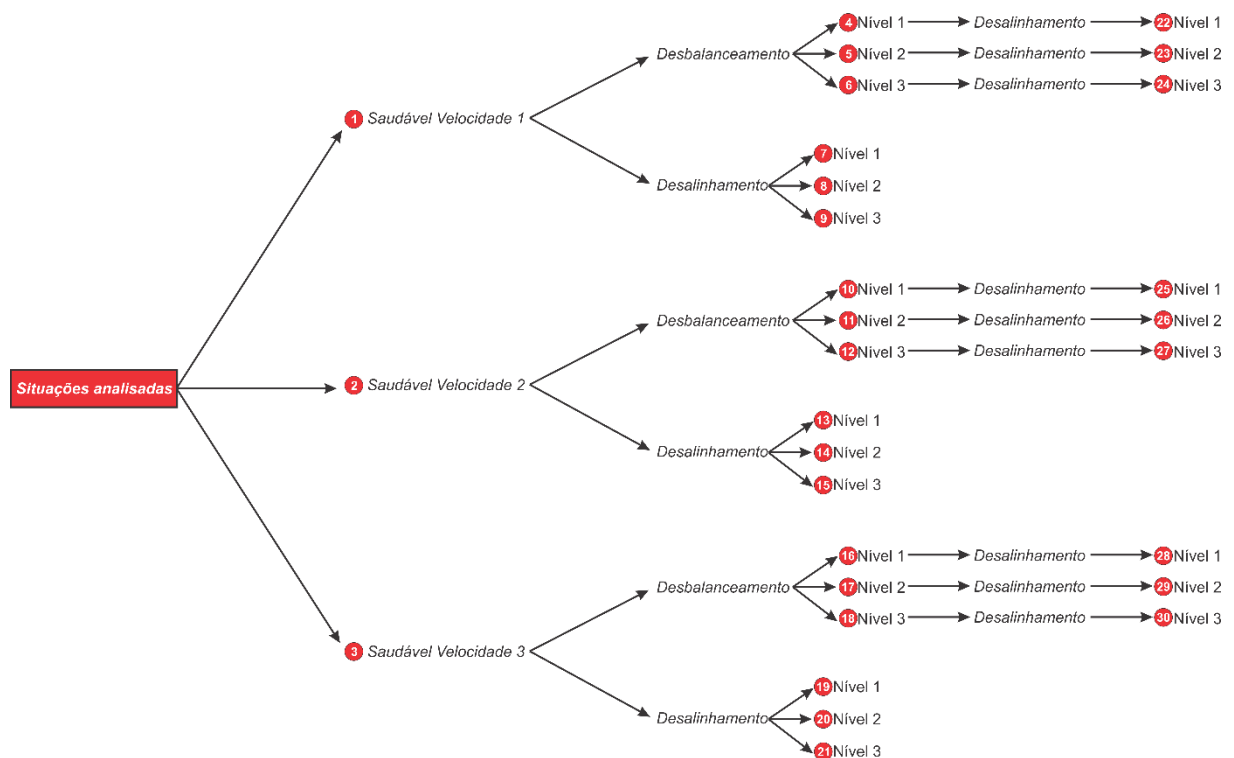
Figura 24 - Posições de coleta de dados



Fonte: O autor, 2018

As coletas foram efetuadas considerando três níveis de velocidade, três níveis de desbalanceamento e três níveis de desalinhamento. O esquema exibido na figura 25 torna mais compreensível a combinação de condições de coleta de dados.

Figura 25 - Esquema da quantidade de experimentos necessários



Fonte: O autor, 2018

O grafo representado na figura 25 representa as falhas possíveis bem como suas combinações, por exemplo, as coletas dos pontos 4, 5 e 6 representam a coleta referente ao sistema desbalanceado nos respectivos níveis para uma tomada de velocidade. Já os pontos 7, 8 e 9 representam a coleta de um sistema desbalanceado em três níveis para uma tomada de velocidade. Os dados obtidos do ponto 22 ao

ponto 24 representam os problemas de desalinhamento e desbalanceamento combinados para uma tomada de velocidade.

A condição ideal para o sistema foi definida com base no seguinte procedimento experimental. Primeiramente foi constatada a condição de velocidade, esta condição foi constatada com o auxílio de uma luz estroboscópica e um inversor de frequência modelo CFW 500 da marca Weg.


Figura 26 - Aparato para captura da velocidade de rotação



Fonte: O autor, 2018

Em seguida foi verificado o nível de desalinhamento do sistema, para tal o equipamento empregado foi um alinhador a laser do modelo Shaftalign da marca Prüftechnik, conforme mostrado na figura 27.


Figura 27 - Alinhador a laser



Fonte: O autor, 2018

Para a realização do procedimento de alinhamento usando o equipamento mencionado foi acoplado em cada lado do acoplamento o emissor do laser e o prisma refletor respectivamente, conforme esquema da figura 28.

Figura 28 - Procedimento para alinhamento do laser



Fonte: Adaptado do manual SHAFTALIGN

Em seguida o conjunto foi nivelado com base nas informações de reflexão do laser mostrado pela IHM após o processamento das informações em sua memória interna. Com o nivelamento completo, o conjunto foi movimentado num ângulo de 180 graus afim de obter a leitura do grau de desalinhamento. As figuras 29 e 30 mostram o sistema montado no equipamento.


Figura 29 - Alinhador posicionado no eixo



Fonte: O autor, 2018

Vale salientar que no sistema em questão a posição do emissor/ prisma refletor foi montada considerando o lado do motor como sendo o lado móvel, tendo em vista que o mesmo foi movimentado para que fossem efetuados eventuais ajustes em sua inclinação nos planos x, y e z, por meio de ajustes de parafusos localizados em sua base.

Figura 30 - Vista do alinhador montado no eixo



Fonte: O autor, 2018

As leituras obtidas deste tipo de equipamentos são bastante intuitivas, de modo que enquanto o ajuste é efetuado a condição exibida na IHM do equipamento é atualizada, até que a condição ideal (definida pelo usuário) seja atingida com uma precisão de 0,01mm. A figura 31, mostra de um modo claro o resultado exibido pelo equipamento.

Figura 31 - IHM do alinhador à laser



Fonte: O autor, 2018



Deste modo podem ser obtidos desalinhamentos programados afim de treinar a rede para reconhece-los posteriormente. Pode-se observar que os valores exibidos já incluem informações quantitativas em escala milimétrica além de uma exibição qualitativa da leitura e aceitabilidade de tais valores, bem como a indicação dos níveis de desalinhamento angular e paralelo em dois planos (vertical e horizontal).

A verificação da condição de desbalanceamento do sistema foi realizada com base nos valores de saída dos espectros de vibração obtidos por meio do uso do detector III da FAG mostrado na figura 32.

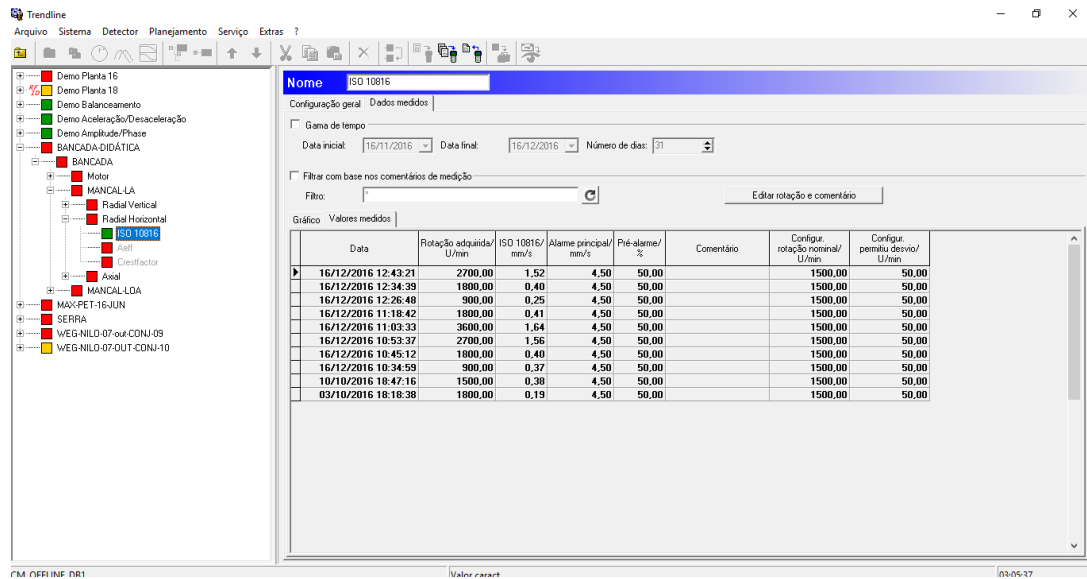
Figura 32 - IHM do detector



Fonte: O autor, 2018

Em seguida foi feito o upload dos dados no software Trendline 3.6, afim de que fossem efetuadas análises dos espectros de dados como posição, velocidade e aceleração. A figura 33 e 34 exibem a interface do software.

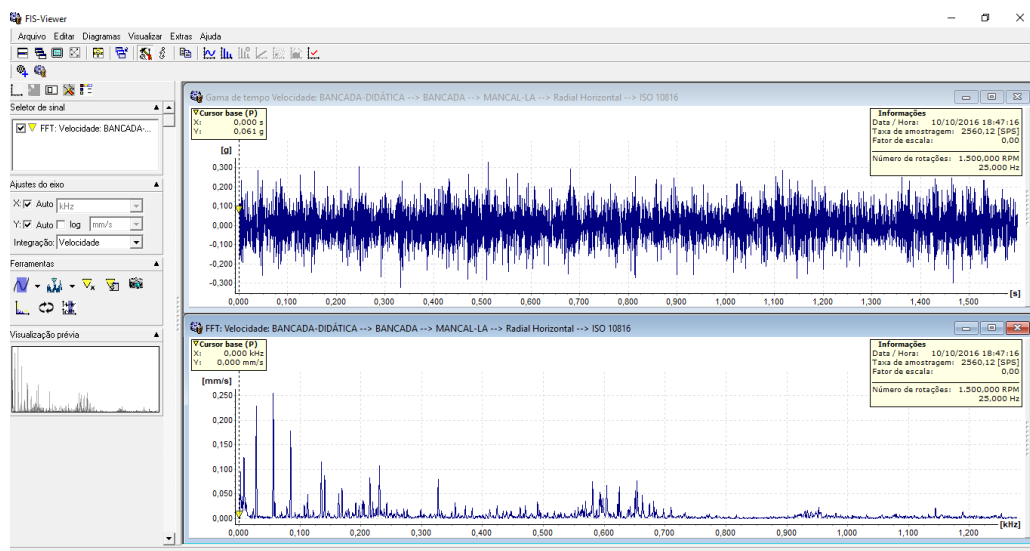
Figura 33 - Interface do Trendline 3.6



Fonte: O autor, 2018

Com base nos registros podem ser gerados gráficos automáticos exibindo os valores das variáveis tanto no domínio do tempo quanto no domínio da frequência oriundos da aplicação da transformada rápida de Fourier (FFT).

Figura 34 - Gráficos gerados pelo Trendline 3.6



Fonte: O autor, 2018

Tomando como base valores referenciais da norma ISO 10816 (valores que dependem da classificação do equipamento analisado), são comparados com os valores medidos definindo a aceitabilidade ou não, dos valores obtidos. Caso os valores estejam em patamares inaceitáveis devem ser adicionadas massas no sistema visando reduzir sejam valores de velocidade ou aceleração.

A bancada experimental é dotada de furos roscados ao longo da circunferência dos dois planos do eixo bi-apoiado afim de permitir que sejam acopladas massas com a facilidade necessária tanto para eliminar o desbalanceamento quanto para gera-lo de forma proposital. Neste estudo foram adicionadas massas desbalanceadoras afim de verificar o impacto no espectro de vibração, tais massas eram devidamente mensuradas por meio do uso de uma balança de precisão.

Os valores dos níveis tanto de desbalanceamento quando desalinhamento e velocidade inseridos no modelo para treinamento da rede estão exibidos na tabela 5.

Tabela 5 - Níveis de desbalanceamento e desalinhamento considerados na pesquisa

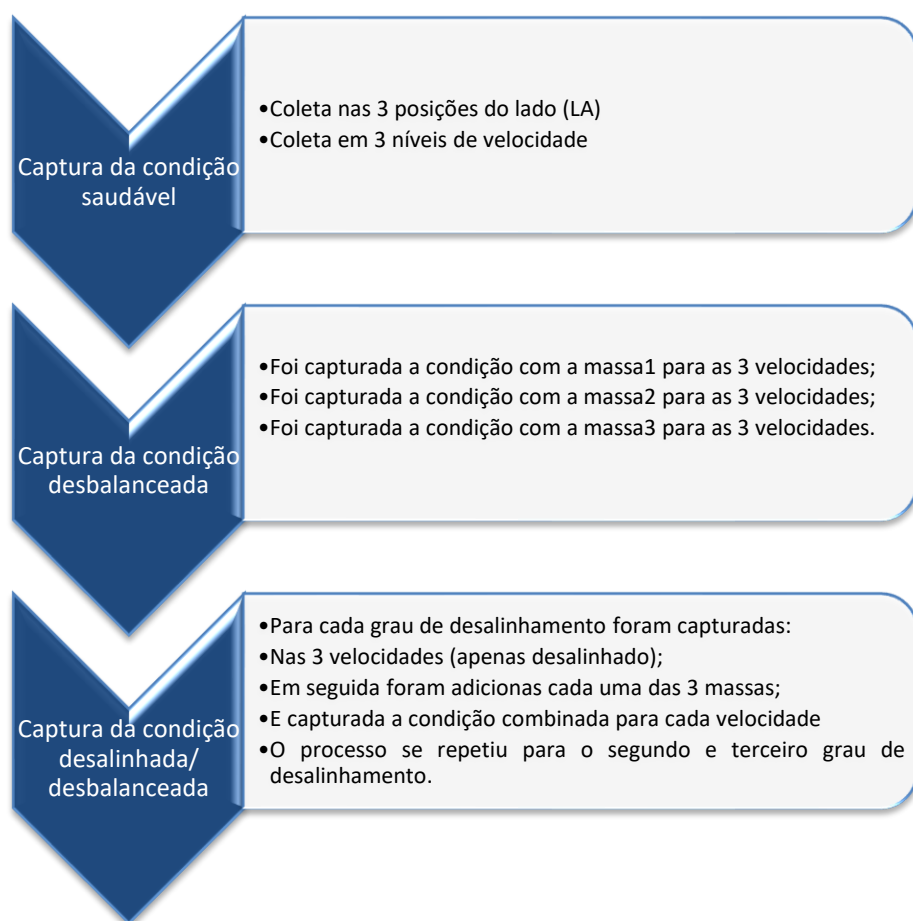
	DESBALANCEAMENTO	DESALINHAMENTO	VELOCIDADE
NÍVEL 1	7 g	0,3 mm	15Hz
NÍVEL 2	15 g	0,6 mm	30Hz
NÍVEL 3	30 g	1,0 mm	60Hz

Fonte: O autor, 2018

## 5.2 SEQUÊNCIA DE CAPTURA DOS DADOS

Na metodologia foram descritos os componentes utilizados na coleta de dados, bem como os dados de relevância para o êxito da pesquisa. Entretanto foi necessária a obtenção dos dados seguindo uma lógica que tornasse possível uma coleta mais eficiente. Para tanto os dados foram obtidos de acordo com a seguinte sistemática:

Figura 35 - Sistemática para obtenção dos dados



Fonte: O autor, 2018

Respeitando esta sequência foram realizados 30 experimentos coletando a cada experimento 4096 pontos de aceleração medidos no tempo de 0 a 1,6 s. Nas posições radial vertical, radial horizontal e axial conforme mencionado na metodologia. Os dados foram importados no Matlab® e tabulados em forma de matrizes em arquivos na extensão “.mat” para posterior processamento pelo algoritmo desenvolvido.



## 6 ANÁLISE DOS RESULTADOS


Em decorrência da aplicação da metodologia descrita no capítulo anterior, foram gerados resultados com o objetivo de capturar, diagnosticar e prever problemas associados a máquinas rotativas. Resultados estes, referentes a bancada experimental apresentada neste trabalho. Os dados foram coletados com base na sequência descrita no tópico 5.2.

De acordo com o fluxograma da figura 16 descrito no capítulo 4, o algoritmo desenvolvido precisou passar por um processo de validação inicial. Tal validação está fundamentada na capacidade do PDFMR fornecer o mesmo resultado em FFT fornecido pelo Trendline 3.6. Este processo de validação encontra-se descrito no tópico seguinte.

### 6.1 VALIDAÇÃO DO ALGORITMO DESENVOLVIDO

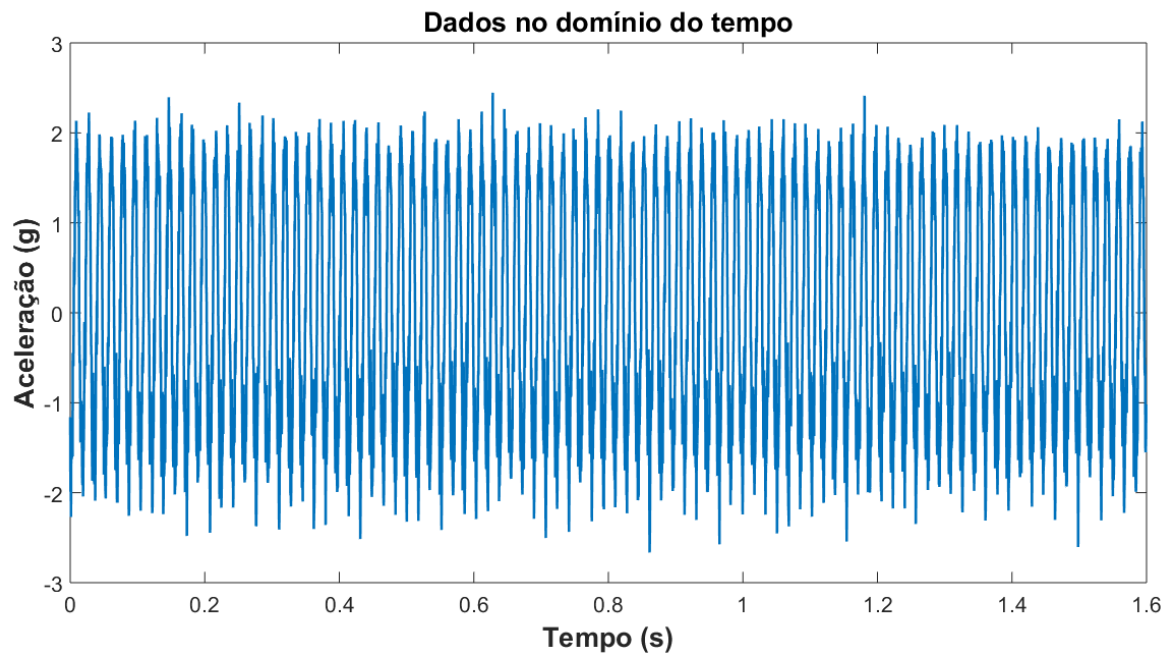
Com o objetivo inicial de validar o algoritmo desenvolvido, além de verificar as escalas e unidades consideradas, os dados importados no Matlab® foram usados para gerar os gráficos FFT fornecidos no programa Trendline 3.6. As figuras 36 e 37 exibem os comportamentos dos dados no tempo, obtidos pelo trendline 3.6 e PDFMR (Programa de detecção de falhas em máquinas rotativas) respectivamente.

Figura 36 - Gráfico gerado pelo Trendline 3.6



Fonte: O autor, 2018


Figura 37 - Gráfico gerado pelo PDFMR



Fonte: O autor, 2018


Nota-se que as representações no domínio do tempo são compatíveis o que justifica a correspondência entre os dados considerados. Os gráficos das figuras 38 e 39 representam as análises de tais dados no domínio da frequência, gráficos obtidos mediante aplicação da transformada rápida de Fourier (FFT).

Figura 38 - FFT gerada pelo Trendline 3.6



Fonte: O autor, 2018

Figura 39 - FFT gerada pelo PDFMR



Fonte: O autor, 2018

Vale salientar que obter a correspondência exata entre os gráficos apresentados demandou minuciosa análise dos dados e conferência no algoritmo FFT. Tal entrave inicial ocorreu por conta de uma inconsistência verificada nos arquivos de exportação do trendline 3.6, pois os arquivos exportados saem com um identificador incompatível com os dados apresentados pelo próprio programa.

O algoritmo PDFMR realiza simultaneamente as análises, FFT, PSD, STFT e Wavelet contínua e discreta. Entretanto, os dados considerados para captura das características da vibração do sistema experimental foram os dados dos coeficientes da decomposição do sinal por meio da transformada wavelet.

## 6.2 PRÉ-PROCESSAMENTO DOS DADOS

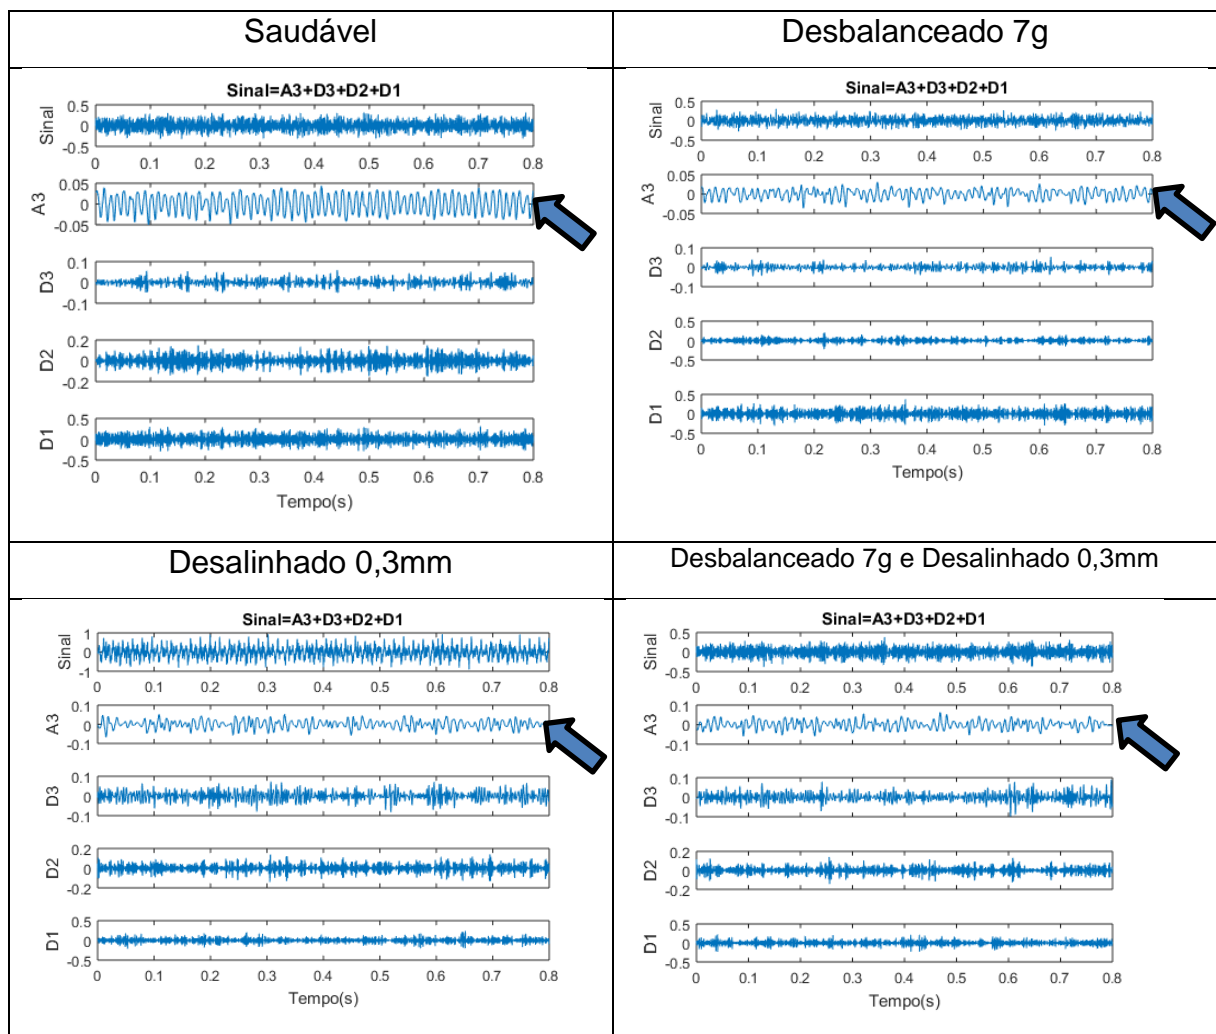
Conforme mencionado em tópico anterior, o sinal coletado por meio do acelerômetro foi devidamente processado afim de tornar a percepção dos padrões de falha melhor apreendido pela rede neural artificial. As figuras (40, 41 e 42) mostram a decomposição dos sinais obtidos para a velocidade de 15 Hz (900 rpm) para as seguintes condições de sinal:

- Condição saudável
- Condição desbalanceado em 7g/ 15g/ 30g

- Condição desalinhado em 0,3mm/ 0,6mm/ 1,0mm
- Condição de problemas combinados, desbalanceado 7g e desalinhado 0,3mm,
- Condição de problemas combinados, desbalanceado 15g e desalinhado 0,6mm
- Condição de problemas combinados, desbalanceado 30g e desalinhado 1,0mm.

Foi aplicada uma decomposição do sinal em três níveis de decomposição mediante aplicação de uma wavelet, que conta com uma wavelet mãe do tipo Daubechie 'db4'. O coeficiente A3 foi considerado como o coeficiente do padrão da vibração para os casos analisados, devido sua notável variação a depender da condição observada, conforme mostrado na figura 40.

Figura 40 - Decomposição dos sinais da condição inicial obtidos a 15 Hz

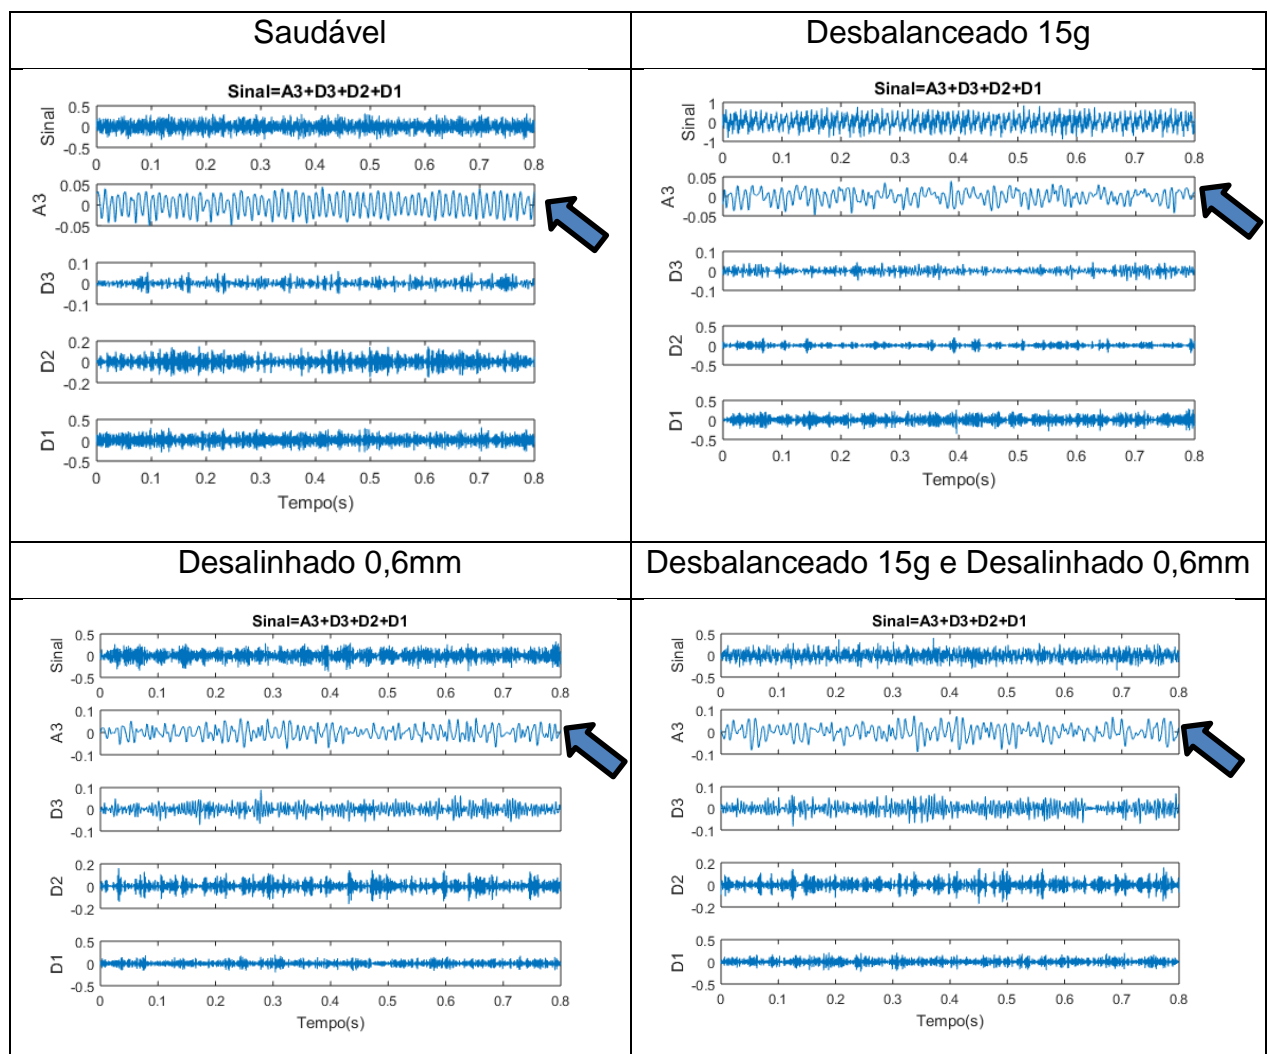


Fonte: O autor, 2018

Observando o padrão do coeficiente A3, nota-se uma distorção visível diferenciando principalmente as condições: saudável, desbalanceado 7g e desalinhado 0,3mm, entretanto, o perfil dos sinais das condições desbalanceado 7g e a condição desbalanceado 7g e desalinhado 0,3mm apresentam semelhança maior, podendo dificultar a diferenciação dos mesmos por parte da rede neural artificial.

A figura 41 exibe as condições para os níveis intermediários de desbalanceamento e desalinhamento 15g e 0,6mm respectivamente.

Figura 41 - Decomposição dos sinais da situação intermediária 15 Hz

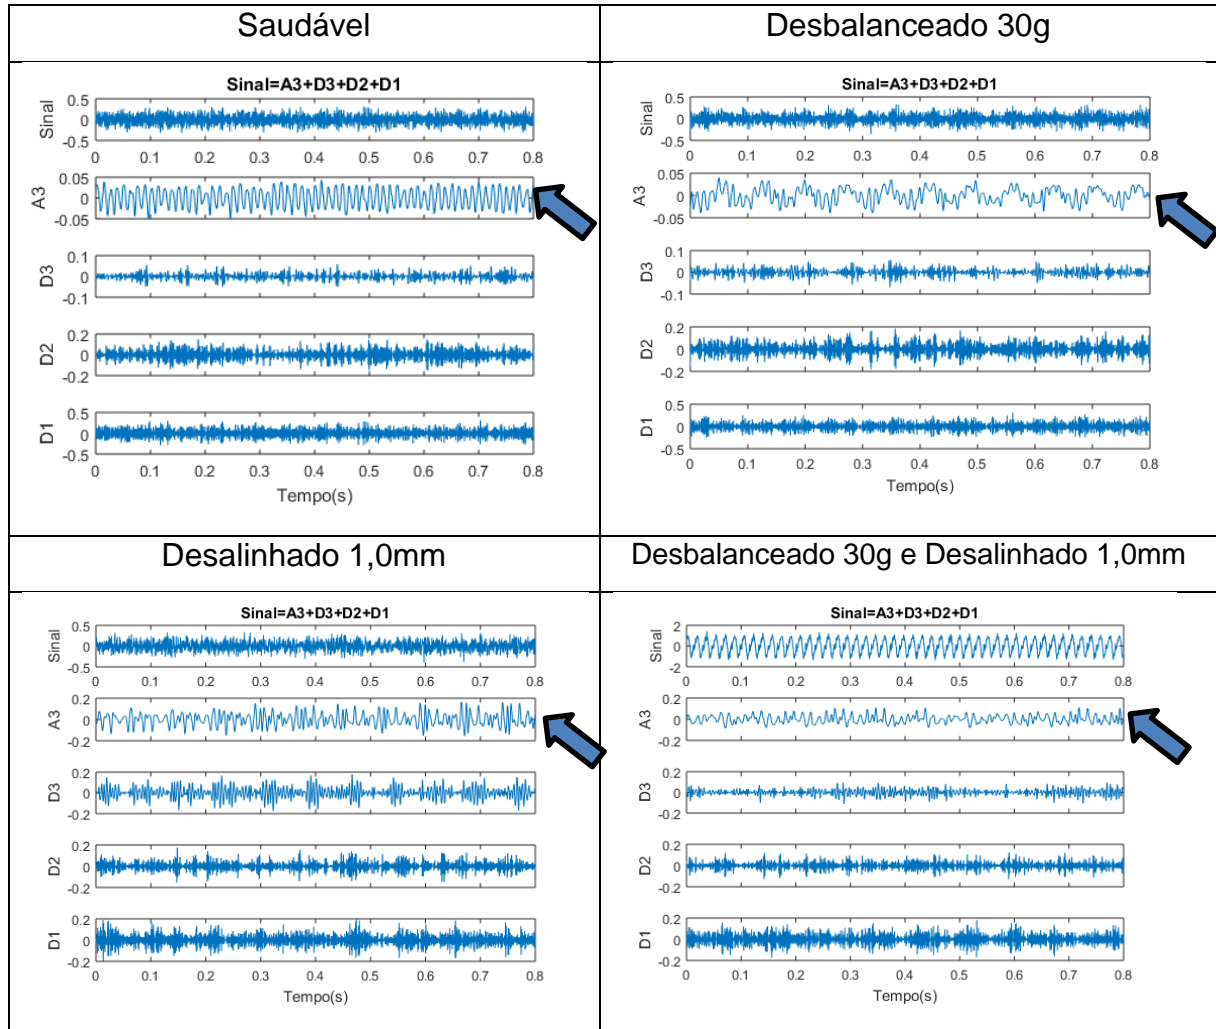


Fonte: O autor, 2018

Para as condições intermediárias o padrão visto entre as condições de desbalanceamento puro e problemas combinados tornam-se mais facilmente diferenciáveis visualmente.

A figura 42 traz a representação da decomposição dos sinais para os níveis superiores das condições consideradas para a velocidade de 900 rpm (15Hz).

Figura 42 - Decomposição dos sinais da situação máxima a 15 Hz



Fonte: O autor, 2018

Levando em consideração a condição onde os níveis de desbalanceamento e desalinhamento são as máximas consideradas, percebe-se que os padrões já se apresentam completamente distintos para todas as situações empregadas.


Foram gerados e analisados os mesmos tipos de sinais considerando as demais velocidades (30 Hz e 60 Hz). Tais dados foram considerados como os dados de entrada para a montagem da matriz de treinamento das redes neurais artificiais e posterior geração das matrizes confusão e gráficos de performance do aprendizado da rede.

## 6.3 APLICAÇÃO DOS PADRÕES NA REDE NEURAL ARTIFICIAL

Os dados provenientes da decomposição do sinal por meio da transformada wavelet 'db4' fornecem as características a serem captadas pela rede neural em seu processo de treinamento. A rede considerada é uma rede do tipo feedforward multi-camadas com uma função de treinamento do tipo gradiente conjugado. Os dados dos coeficientes são usados como matrizes de entrada, entrada esta que foram comparadas com a matriz alvo durante o processo de treinamento. Foi variada a quantidade de neurônios na camada intermediária afim de avaliar a resposta obtida pela rede, foram considerados de 10 a 100 neurônios com incremento de 10 neurônios na camada intermediária a cada simulação.

A figura 44 mostra a matriz confusão para a velocidade de 900 rpm (15 Hz) nos níveis iniciais de desbalanceamento e desalinhamento (7g e 0,3mm). Considerando apenas 10 neurônios na camada intermediária (Figura 43).

Figura 43 - Tipologia da primeira rede



Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Figura 44 - Matriz confusão do caso inicial 15 Hz  
Matriz confusão - 900 rpm/ 7g/ 0,3mm

	1	2	3	4	
1	64 25.0%	5 2.0%	6 2.3%	7 2.7%	78.0% 22.0%
2	0 0.0%	59 23.0%	1 0.4%	2 0.8%	95.2% 4.8%
3	0 0.0%	0 0.0%	24 9.4%	20 7.8%	54.5% 45.5%
4	0 0.0%	0 0.0%	33 12.9%	35 13.7%	51.5% 48.5%
	100% 0.0%	92.2% 7.8%	37.5% 62.5%	54.7% 45.3%	71.1% 28.9%
	1	2	3	4	

A matriz confusão trata-se de uma matriz que correlaciona as classes de saída (Output Class) com as classes alvo (Target Class). Esta correlação expressa a medida em que a rede forneceu uma saída classificando como uma determinada classe em comparação com a classe real definida no alvo. Deste modo, a diagonal da matriz representa a posição onde as classes de saída e alvo coincidem fornecendo assim o volume e percentual de dados identificados corretamente pela rede neural artificial. As demais posições representam os falsos positivos e falsos negativos atribuídos pela rede. Em nosso estudo foram delimitadas quatro classes: 1- Saudável; 2- Desbalanceado; 3- Desalinhado; 4- Problemas combinados.


Com uma taxa de acerto de 71,1% pode-se notar que a maior dificuldade da rede foi na classificação entre as condições desalinhamento puro e desalinhamento combinado com desbalanceamento. Percebe-se um bom resultado (acima de 95 %) na identificação do desbalanceamento puro (95,2%).

O gráfico de performance traz a informação acerca do processo de treinamento da rede. O treinamento ocorre de um modo iterativo e a cada iteração do algoritmo é chamada de uma época de treinamento. São delimitados, critério de parada e número máximo de iterações, bem como um teste de convergência. O número de épocas está relacionado com a disponibilidade de dados para treinamento. Tal fato implica que quanto mais dados estiverem disponíveis por mais épocas uma rede neural pode ser treinada e conseqüentemente pode apresentar uma melhor convergência para o erro mínimo definido no algoritmo.

Avaliando a performance da rede, a figura 45 nos mostra que o melhor valor foi atingido em 14 épocas de treinamento. Vale salientar que este valor pode melhorar bastante, tendo em vista que o conjunto de dados para treinamento foi relativamente baixo, sendo considerado apenas 1,6 segundos de tomada de dados.




Figura 45 - Performance da rede na condição inicial 15 Hz



Fonte: Toolbox do Matlab com dados fornecidos pelo autor

A figura 46 mostra-nos os resultados para a condição de desbalanceamento e desalinhamento nos níveis de 15g e 0,6mm respectivamente.

Figura 46 - Matriz confusão condição intermediária 15 Hz




Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Percebe-se que os resultados apresentaram melhora fornecendo um percentual total de acerto de 85,2%, de modo que todas as classes de problemas foram detectadas com uma taxa de acerto superior a 80%. É importante notar que neste caso

intermediário a rede neural artificial demonstrou confusão entre as situações desalinhado e saudável, fato que observando visualmente os perfis do coeficiente wavelet nota-se significativa diferença entre os perfis. Em contrapartida a rede confundiu igualmente entre as condições desbalanceado e problemas combinados, situação em que os perfis realmente apresentam semelhanças consideráveis. Vale salientar que os vetores de saída são normalizados e devido a este processo são convertidos em valores binários. Fato que associado a quantidade de neurônios, disponibilidade de dados e distribuição randômica dos dados de treinamento, pode acabar favorecendo aleatoriamente um grupo de dados. Tais fatores podem explicar o fato do modelo ter associado a condição de desalinhamento a condição saudável mesmo apresentando as diferenças notadas nos perfis da figura 41. A figura 47 exibe a performance observada nesta rede.

Figura 47 - Performance da rede condição intermediária 15 Hz




Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Percebe-se que neste caso a melhor performance foi alcançada em 30 épocas de treinamento com uma diferença na ordem de  $10^{-1}$  entre o valor real e o valor previsto pela rede.

Avaliemos o caso onde tanto o desbalanceamento quanto o desalinhamento estão em seu nível máximo. A figura 48 corresponde a matriz confusão para este caso.


Figura 48 - Matriz confusão condição máxima 15 Hz



Fonte: Toolbox do Matlab com dados fornecidos pelo autor

A rede apresentou dificuldade em diferenciar os problemas obtendo um resultado de percentual de acerto de 78,9%. Neste caso a condição de problemas combinados apresentou os maiores erros igualmente distribuídos nas outras três classes anteriores. A melhor performance da rede consta na figura 49.

Figura 49 - Performance da rede condição máxima 15 Hz



Fonte: Toolbox do Matlab com dados fornecidos pelo autor

O melhor desempenho foi atingido em 14 épocas conforme observado na figura 49, pode-se notar também na figura um perfil que demonstra uma taxa de convergência pouco acentuada. Lembrando que o algoritmo de treinamento apresenta melhores resultados de convergência conforme a maior disparidade entre a informação e o alvo.

Contudo, todos os perfis foram simulados para as demais condições observadas no experimento, tais informações encontram-se disponíveis sob forma de matriz confusão e gráficos de performance de treinamento no apêndice A. Observemos a tabela 6 onde constam os dados de cada situação simulada levando em consideração o acréscimo no número de neurônios na camada intermediária da rede, afim de notar se há realmente uma relação diretamente proporcional entre o aprendizado da rede com o número de neurônios.

Relembrando as condições em que os dados experimentais foram obtidos temos:

I – Desbalanceamento de 7g e desalinhamento de 0,3mm;

II – Desbalanceamento de 15g e desalinhamento de 0,6mm;


III – Desbalanceamento de 30g e desalinhamento de 1,0mm;

Tabela 6 - Resultados das simulações alterando-se a quantidade de neurônios na camada intermediária

	10	20	30	40	50	60	70	80	90	100
<b>VELOCIDADE 900 rpm (15 Hz)</b>										
<b>I</b>	71,1	68,4	68,4	78,1	69,9	72,3	73,8	73	74,2	75,4
<b>II</b>	85,2	80,1	84	80,5	78,1	79,7	81,6	84,8	73	80,1
<b>III</b>	78,9	94,5	91,4	93,8	94,5	97,7	99,6	93,4	97,3	98,4
<b>VELOCIDADE 1800 rpm (30 Hz)</b>										
<b>I</b>	37,1	27,3	25,8	32,8	29,3	30,5	35,9	50	63,3	69,1
<b>II</b>	30,9	69,9	34	70,7	37,1	61,7	38,7	34	65,2	63,7
<b>III</b>	55,5	62,9	68	84,8	63,7	82,4	73,8	34	71,5	59,8
<b>VELOCIDADE 3600 rpm (60 Hz)</b>										
<b>I</b>	93,4	99,2	100	100	96,5	100	100	98	100	100
<b>II</b>	77,3	80,5	93	82,8	99,6	99,6	87,5	89,5	100	99,6
<b>III</b>	97,7	92,2	96,9	98,8	99,6	93	94,9	98	99,6	99,6

Fonte: O autor, 2018

Os dados da tabela 6 deram origem o gráfico da figura 50 onde pode-se notar a evolução do aprendizado da rede em relação ao incremento no número de neurônios de um modo mais claro (Gráfico aumentado disponível no apêndice A).



Fonte: O autor, 2018

Analisando os dados do gráfico da figura 50 nota-se claramente que não há uma relação explicitamente diretamente proporcional entre os dados de aprendizagem em relação a quantidade de neurônios da rede. Observando os dados da condição a uma velocidade de 1800 rpm, nas situações intermediárias de desbalanceamento e desalinhamento (15g/ 0,6mm), observa-se uma grande oscilação nos resultados a medida em que são acrescentados os neurônios na camada intermediária da rede. Este tipo de comportamento ocorre com menor intensidade em praticamente todas as situações analisadas, em alguns casos fazendo com que a tendência seja levemente negativa com o aumento na quantidade de neurônios. Entretanto na maioria das situações houve uma leve tendência de melhora nos resultados. É de conhecimento da literatura que o desempenho da rede nem sempre melhora com o incremento no número de neurônios na camada intermediária, e isto se dá muitas vezes pelo fato de tratarmos de um método adaptativo onde uma quantidade maior de neurônios implica também numa quantidade maior de pesos associados a cada nó da rede, que a depender da distribuição dos dados e da disponibilidade dos mesmos para treinamento, a rede pode ter o desempenho prejudicado pelo acréscimo de possibilidades das possíveis combinações dos pesos para atingimento do alvo.

Outro fato interessante que pode-se observar no desempenho da rede, é o fato dos resultados a velocidade de 1800 rpm apresentarem uma capacidade de previsão e captura do padrão inferior as condições a 900 rpm, tal efeito merece uma investigação mais específica afim de melhor compreender este fenômeno que pode inclusive estar relacionado a interação das frequências produzidas nestas velocidades com as frequências da estrutura como um todo. Todavia o PDFMR é capaz de fornecer simultaneamente outras análises que podem trazer para o analista uma melhor interpretação do sinal de tais condições. Ou seja, o especialista pode em caso de dúvida solicitar tais registros afim de chegar numa conclusão mais precisa da condição do equipamento.

Apesar da oscilação da taxa de aprendizagem constatada com a alteração do tamanho da camada intermediária, quanto o baixo desempenho inicial na condição na velocidade de 1800 rpm, pode-se notar um resultado superior 95% de eficácia na maioria dos casos simulados a 3600 rpm (rotação nominal do motor). Deste fato pode-se concluir que elevando-se a rotação do motor para a sua condição nominal o diagnóstico da rede será quase em sua totalidade correto para todas as condições simuladas, inclusive no diagnóstico de problemas combinados, que representa um desafio atualmente no diagnóstico destes tipos de problemas.

## 7 CONSIDERAÇÕES FINAIS

O intuito principal desta tese foi atingir o objetivo geral de fornecer um diagnóstico da condição (Desbalanceado/ Desalinhado) de máquinas rotativas, mediante análise de sinais de vibração e aplicação de técnicas como, decomposição de sinais e redes neurais artificiais. Os dados foram obtidos por meio de uma bancada experimental onde foram simuladas condições de problemas como, desalinhamento e desbalanceamento em três níveis distintos. Para a velocidade foram considerados os patamares: 900 rpm (15 Hz), 1800 rpm (30 Hz) e 3600 rpm (60 Hz). Os níveis de desbalanceamento aplicado no experimento consideraram a adição de três elementos com as seguintes massas: 7 g, 15 g e 30 g. Os níveis de desalinhamento foram aplicados com o apoio de um alinhado à laser capaz de garantir medições com uma precisão de 0,01 mm. Os níveis de desalinhamento introduzidos no experimento foram: 0,3 mm, 0,6 mm e 1,0 mm. Os dados de vibração foram obtidos com o apoio de um acelerômetro (Detector III da FAG) e os dados foram carregados e exportados do Trendline 3.6. O PDFMR foi desenvolvido em ambiente do Matlab onde foram considerados os dados exportados pelo Trendline 3.6. O pré-processamento dos dados levaram em consideração as seguintes técnicas:

- Análise FFT
- Análise PSD
- Análise STFT
- Decomposição Wavelet

Os dados usados para a captura dos padrões por meio das redes neurais artificiais foram os dados provenientes da decomposição do sinal realizada com base nas Wavelets. A rede neural empregada foi do tipo feedforward com três camadas sendo uma dessas oculta (intermediária), o algoritmo de treinamento empregado foi o gradiente conjugado pelo fato de apresentar uma boa convergência. Foram simuladas arquiteturas variando-se a quantidade de neurônios na camada intermediária afim de visualizar o impacto de tal alteração na taxa de aprendizagem da rede.

Os resultados se mostraram bastante satisfatórios levando em consideração o volume de dados disponíveis. Os resultados considerados satisfatórios são os que fornecem uma taxa de aprendizagem da rede na ordem de 95%. A rede neural do tipo feedforward multicamadas foi capaz de diagnosticar os problemas em níveis próximos

a 100% em alguns casos, o que torna sua aplicabilidade bastante viável como uma alternativa a técnicas de manutenção preditiva disponíveis no mercado e academia. Como resultado concluiu-se que a rede desenvolvida tem as seguintes capacidades:

- Diagnóstico de condição saudável;
- Diagnóstico da condição de desbalanceamento puro;
- Diagnóstico da condição de desalinhamento puro;
- Diagnóstico da condição onde os problemas estão combinados.

Obviamente que para as diversas situações analisadas alguns, resultados se mostraram mais promissores que os outros, entretanto como os níveis em que os problemas foram analisados foram replicados para condições de velocidade distintas, constatou-se que, em conformidade com a intuição, a rede atinge sua eficiência máxima em condições de velocidades em torno de 3600 rotações por minuto. Outro dado importante notado, foi a relação inversa constatada quando o patamar de velocidade foi alterado de 900 rotações por minuto para 1800 rotações por minuto, indo contra o senso comum os padrões de vibração das condições analisadas tornaram-se mais difusos que nos casos para uma velocidade de rotação menor. Entretanto, com o incremento no número de neurônios na rede, estes resultados foram os que sofreram maior impacto positivo. Dado que reitera a ideia do potencial da rede de fornecer boas previsões para todas as condições consideradas, além de presumir uma capacidade de prever os mesmos problemas para condições diferentes de desbalanceamento/ desalinhamento.

É importante mencionar que para os casos onde as velocidades foram 900 rpm e 1800 rpm os valores de velocidade obtidos nas leituras dos acelerômetros não indicavam um problema de desbalanceamento ou desalinhamento, tomando como base a norma ISO 10816, atingindo um valor máximo de 3,09 mm/s no caso mais severo a 1800 rpm. Levando em consideração que de acordo com a potência do equipamento, o valor de atenção está acima de 4,5 mm/s, faz com que o diagnóstico da rede seja ainda mais conservador e detecta casos de tais problemas ainda em estágio inicial.

Análises posteriores são indicadas com o intuito tanto de fornecer mais dados de treinamento para a rede, bem como obter suas saídas mediante apresentação de dados relativos a condições diferentes das estabelecidas durante o processo de treinamento. Tal análise geraria um incremento maior na validação dos resultados



obtidos pela rede, bem como forneceria dados para um incremento em sua capacidade de generalização mediante disponibilização de novos padrões.

É importante lembrar que o algoritmo (PDFMR) desenvolvido nessa tese, incorpora em sua estrutura, diversas outras análises de suma importância para especialistas da área de análise de vibrações mecânicas (FFT, PSD, STFT, WT), isto faz com que o algoritmo seja um aliado ainda mais eficaz no diagnóstico de falhas, sendo capaz de fornecer relatórios gráficos capazes de gerar análises do sinal sob óticas distintas, capacidade que garante uma maior confiabilidade nas saídas obtidas pela rede.

## 7.1 TRABALHOS FUTUROS

Este trabalho representa o passo inicial para a obtenção de análises mais completas. Faz parte da continuação do trabalho, aplicar redes neurais com funções de ativação de base radial, afim de obter dados de saída não apenas de classificação, mas também proporcionais a intensidade em que os problemas ocorrem. Almeja-se a continuação do desenvolvimento da aplicação incorporando uma interface amigável obtendo de forma tanto qualitativa quanto quantitativa a condição do equipamento analisado. Uma melhoria a ser proposta será a incorporação de acelerômetros dotados de circuitos capazes de comunicação via rádio, o que torna o processo de monitoração mais dinâmico e acima de tudo contínuo, fornecendo uma supervisão em tempo integral do equipamento por parte de uma rede neural artificial eficiente, a ponto de alertar anomalias detectadas, bem como fornecer um diagnóstico do que cada anomalia representa em termos práticos.

## REFERÊNCIAS

- ABRAMAN, A situação da manutenção no Brasil, 28 Congresso Brasileiro de manutenção e gestão de ativos, Salvador, 2013.
- Agnes Muszynska, "Vibrational Diagnostics of Rotating Machinery Malfunctions," *International Journal of Rotating Machinery*, vol. 1, no. 3-4, pp. 237-266, 1995.
- Andrew D. Dimarogonas, *Vibration of cracked structures: A state of the art review*, *Engineering Fracture Mechanics*, Volume 55, Issue 5, 1996, Pages 831-857.
- Andrew K.S. Jardine, Daming Lin, Dragan Banjevic, A review on machinery diagnostics and prognostics implementing condition-based maintenance, *Mechanical Systems and Signal Processing*, Volume 20, Issue 7, 2006, Pages 1483-1510.
- Applied Mathematics, Philadelphia, EUA. CBMS-NSF regional conference series
- B.A. Paya, I.I. Esat, M.N.M. Badi, Artificial neural network based fault diagnostics of rotating machinery using wavelet transforms as a preprocessor, *Mechanical Systems and Signal Processing*, Volume 11, Issue 5, 1997, Pages 751-765.
- Baccarini, L. M. R., *Detecção e Diagnóstico de Falhas em Motores de Indução*, Belo Horizonte, Faculdade de Engenharia Elétrica, Universidade Federal de Minas Gerais, 2005. Tese (Doutorado).
- Bossio, J.M., De Angelo, C.H. & Bossio, G.R. *Neural Comput & Applic* (2013) 23: 41.
- BOTTEGA, William J. *Engineering Vibrations*,. 2nd. ed. FL: Taylor & Francis, 2014. 927 p.
- C. Richard Cassady & Erhan Kutanoglu (2003) Minimizing Job Tardiness Using Integrated Preventive Maintenance Planning and Production Scheduling, *IIE Transactions*, 35:6, 503-513.
- C.W. Bert, Material damping: An introductory review of mathematic measures and experimental technique, *Journal of Sound and Vibration*, Volume 29, Issue 2, 1973, Pages 129-153.
- Castejón, Cristina & GARCIA-PRADA, J.C. & Gómez, M.J. & Meneses, Jesus. (2014). Automatic detection of cracked rotors combining multiresolution analysis and artificial neural networks. *Journal of Vibration and Control*. 21. 1077546313518816. 10.1177/1077546313518816.
- Changqing Shen, Dong Wang, Fanrang Kong, Peter W. Tse, Fault diagnosis of rotating machinery based on the statistical parameters of wavelet packet paving and a generic support vector regressive classifier, *Measurement*, Volume 46, Issue 4, 2013, Pages 1551-1564.
- Changzheng Chen, Changtao Mo, A method for intelligent fault diagnosis of rotating machinery, *Digital Signal Processing*, Volume 14, Issue 3, 2004, Pages 203-217.
- Chin-Sheng Chen, Jian-Shiu Chen, Rotor fault diagnosis system based on sGA-based individual neural networks, *Expert Systems with Applications*, Volume 38, Issue 9, 2011, Pages 10822-10830.

CLINICAL NEUROPHYSIOLOGY, 3RD EDITION, John C. Kincaid, Neurology Feb 2010, 74 (6) 529; DOI: 10.1212/WNL.0b013e3181cef884

DAUBECHIES, "The Wavelet Transform Time-Frequency Localization and Signal Analysis," IEEE Transactions on Information Theory, Vol. 36, No. 5, 1990, pp. 961-1004. doi:10.1109/18.57199

DAUBECHIES, I., 1992, Ten Lectures on Wavelets: Society for Industrial and

Deakin, Michael A. B. "Euler's Invention of Integral Transforms." Archive for History of Exact Sciences, vol. 33, no. 4, 1985, pp. 307–319.

Deakin, Michael A. B. "The Development of the Laplace Transform, 1737-1937: I. Euler to Spitzer, 1737-1880." Archive for History of Exact Sciences, vol. 25, no. 4, 1981, pp. 343–390.

Deakin, Michael A. B. "The Development of the Laplace Transform, 1737-1937 II. Poincaré to Doetsch, 1880-1937." Archive for History of Exact Sciences, vol. 26, no. 4, 1982, pp. 351–381.

Debnath, Lokenath. (1998). Brief historical introduction to wavelet transforms. International Journal of Mathematical Education in Science and Technology. 29. 677-688.

Doebeling, S.W., Farrar, C.R., Prime, M.B., and Shevitz, D.W. Damage identification and health monitoring of structural and mechanical systems from changes in their vibration characteristics: A literature review. United States: N. p., 1996. Web. doi:10.2172/249299.

F. Al-Badour, M. Sunar, L. Cheded, Vibration analysis of rotating machinery using time–frequency analysis and wavelet techniques, Mechanical Systems and Signal Processing, Volume 25, Issue 6, 2011, Pages 2083-2101.

F.I. Khan, M. Haddara, Risk-based maintenance (RBM): a quantitative approach for maintenance/inspection scheduling and planning, J. Loss Prevent. Process Ind. 16 (2003) 561–573.

F.L. Cooke, Plant maintenance strategy: evidence from four British manufacturing firms, J. Qual. Maint. Eng. 9 (3) (2003) 239–249.

Faisal I Khan, S.A Abbasi, Techniques and methodologies for risk analysis in chemical process industries, Journal of Loss Prevention in the Process Industries, Volume 11, Issue 4, 1998, Pages 261-277.

Fang Lee Cooke, (2003),"Plant maintenance strategy: evidence from four British manufacturing firms", Journal of Quality in Maintenance Engineering, Vol. 9 Iss 3 pp. 239 – 249.

Fiete, I. R. Learning and coding in biological neural networks. PhD thesis. Harvard University, Cambridge, Massachusetts. 2003.

Fu, Chuang & Ye, Luqing & Yongqian, Liu & Yu, Ren & lung, Benoît & Cheng, Yuanchu & Zeng, Yuming. (2004). Predictive Maintenance in Intelligent-Control-Maintenance-

Management System for Hydroelectric Generating Unit. *Energy Conversion, IEEE Transactions on*. 19. 179 - 186.

GALVAO, Roberto Kawakami Harrop et al. Estudo comparativo sobre filtragem de sinais instrumentais usando transformadas de Fourier e Wavelet. *Quím. Nova* [online]. 2001, vol.24, n.6, pp.874-884. ISSN 0100-4042.

Gandhare, Balasaheb & Akarte, Milind. (2018). Maintenance Strategy Selection.

Han, Yi & Song, YH. (2002). Condition Monitoring Techniques for Electrical Equipment: A Literature Survey. *Power Engineering Review, IEEE*. 22. 59-59.

Hans Löfsten, Measuring maintenance performance – in search for a maintenance productivity index, *International Journal of Production Economics*, Volume 63, Issue 1, 2000, Pages 47-58.

harris, fred. (1978). On the Use of Windows for Harmonic Analysis With the Discrete Fourier Transform. *Proceedings of the IEEE*. 66. 51 - 83.

Haykin, S. “Redes Neurais: Principio e Pratica”. 2ª ed. Bookman. 2001.

Hill, Tim, et al. “Neural Network Models for Time Series Forecasts.” *Management Science*, vol. 42, no. 7, 1996, pp. 1082–1092.

Hisham Hassan Jasim (2013) “Estimated Outlet Temperatures in Shell-and-Tube Heat Exchanger Using Artificial Neural Network Approach Based on Practical Data” *Al-Khwarizmi Engineering Journal*, Vol. 9, No. 2, P.P. 12- 20.

Hongzhou Wang, A survey of maintenance policies of deteriorating systems, *European Journal of Operational Research*, Volume 139, Issue 3, 2002, Pages 469-489.

Howell, Kenneth B. (2001). Principles of Fourier Analysis. CRC Press. ISBN 978-0-8493-8275-8. in applied mathematics.

industry 4.0-based manufacturing systems, *Manufacturing Letters* 3: 18-23.

Inman, D.J. – “Engineering Vibration”, Pearson Prentice Hall, pp 8, 3th Edition - 2007.

Issam Abu-Mahfouz, Drilling wear detection and classification using vibration signals and artificial neural network, *International Journal of Machine Tools and Manufacture*, Volume 43, Issue 7, 2003, Pages 707-720.

J.M. Moubray, Reliability-Centred Maintenance, Butterworth/Heinemann, Oxford, 1994.

Jafar Zarei, Mohammad Amin Tajeddini, Hamid Reza Karimi, Vibration analysis for bearing fault detection and classification using an intelligent filter, *Mechatronics*, Volume 24, Issue 2, 2014, Pages 151-157.

Jay Lee, Maria Holgado, Hung-An Kao, Marco Macchi, New Thinking Paradigm for Maintenance Innovation Design, *IFAC Proceedings Volumes*, Volume 47, Issue 3, 2014, Pages 7104-7109.

Junhong Zhang, Wenpeng Ma, Jiwei Lin, Liang Ma, Xiaojie Jia, Fault diagnosis approach for rotating machinery based on dynamic model and computational intelligence, *Measurement*, Volume 59, 2015, Pages 73-87.

Kande, Mallikarjun & Isaksson, Alf & Thottappillil, Rajeev & Taylor, Nathaniel. (2017). Rotating Electrical Machine Condition Monitoring Automation—A Review. *Machines*. 5. 24.

Karnas, Grzegorz & Maslowski, Grzegorz & Brański, Piotr. (2016). Power spectrum density analysis of intra-cloud lightning discharge components from electric field recordings in Poland. 1-6.

KELLY, S. Graham. *Mechanical Vibrations: Theory and Applications*, SI Edition. ilustrada. ed. Stanford: Cengage Learning, 2012. 896 p.

Khan, Faisal & Haddara, Mahmoud. (2004). Risk-Based Maintenance (RBM): A new approach for process plant inspection and maintenance. *Process Safety Progress*. 23. 252 - 265.

L. Meirovitch, *Fundamentals of Vibrations*, McGraw-Hill, New York, 2001.

Lasi, Heiner; Fettke, Peter; Feld, Thomas; and Hoffmann, Michael (2014) "Industry 4.0," *Business & Information Systems Engineering*: Vol. 6: Iss. 4, 239-242.

Lee, E. A. and Seshia, S. A. (2016). *Introduction to embedded systems: A cyber-physical systems approach*, MIT Press.

Lee, J., Bagheri, B. and Kao, H.-A. (2015). A cyber-physical systems architecture for

Ling Wang, Jian Chu, Jun Wu, Selection of optimum maintenance strategies based on a fuzzy analytic hierarchy process, *International Journal of Production Economics*, Volume 107, Issue 1, 2007, Pages 151-163.

Lokenath Debnath (2006) Brief historical introduction to wavelet transforms, *International Journal of Mathematical Education in Science and Technology*, 29:5, 677-688, DOI: 10.1080/0020739980290504

M. A. B. Deakin, "Euler's version of the Laplace transform," *Am. Math. Mon.*, vol. 87, no. 4, pp. 264–269, 1980.

M. A. B. Deakin, "The ascendancy of the Laplace transform and how it came about," *Arch. Hist. Exact Sci.*, vol. 44, no. 3, pp. 265–286, 1992.

M. A. B. Deakin, "The development of the Laplace transform, 1737–1937: I. Euler to Spitzer, 1737–1880," *Arch. Hist. Exact Sci.*, vol. 25, no. 4, pp. 345–390, 1981.

M. A. B. Deakin, "The development of the Laplace transform, 1737–1937: II. Poincaré to Doetsch, 1880–1937," *Arch. Hist. Exact Sci.*, vol. 26, no. 4, pp. 351–381, 1982.

M. Hernandez-Vargas, E. Cabal-Yeppez, A. Garcia-Perez, Real-time SVD-based detection of multiple combined faults in induction motors, *Computers & Electrical Engineering*, Volume 40, Issue 7, 2014, Pages 2193-2203.

- M. Saimurugan, K.I. Ramachandran, V. Sugumaran, N.R. Sakthivel, Multi component fault diagnosis of rotational mechanical system based on decision tree and support vector machine, *Expert Systems with Applications*, Volume 38, Issue 4, 2011, Pages 3819-3826.
- M. Xu, R.D. Marangoni, Vibration Analysis Of A Motor-Flexible Coupling-Rotor System Subject To Misalignment And Unbalance, Part I: Theoretical Model And Analysis, *Journal of Sound and Vibration*, Volume 176, Issue 5, 1994, Pages 663-679.
- Mallat Stéphane, *Sparse Representations*, Editor(s): Mallat Stéphane, A Wavelet Tour of Signal Processing (Third Edition), Academic Press, 2009, 824 p,
- Mari Cruz Garcia, Miguel A. Sanz-Bobi, Javier del Pico, SIMAP: Intelligent System for Predictive Maintenance: Application to the health condition monitoring of a windturbine gearbox, *Computers in Industry*, Volume 57, Issue 6, 2006, Pages 552-568.
- MEIROVITCH, Leonard. *Fundamentals of Vibrations*. Virginia: Waveland Press, 2010. 806 p.
- Michael A. B. Deakin. "Euler's Version of the Laplace Transform." *The American Mathematical Monthly*, vol. 87, no. 4, 1980, pp. 264–269.
- Mohammad akhshab, Effect of Performance of Vibration Base Maintenance in Reliability, *Australian Journal of Basic and Applied Sciences*, 2011, Pages 165-169.
- N. F. Rieger, The literature of vibration engineering, *Shock and Vibration Digest*, Vol. 14, No. 1, January 1982, pp. 5 13.
- N.S. Arunraj, J. Maiti, Risk-based maintenance—Techniques and applications, *Journal of Hazardous Materials*, Volume 142, Issue 3, 2007, Pages 653-661.
- Nolfi, Stefano & Parisi, Domenico. (2001). *Evolution of Artificial Neural Networks*. Oct. 1991.
- Oppenheim, A.V. & W Schafer, Ronald & R Buck, John. (1999). *Discrete-Time Signal Processing* (2nd Edition) (Prentice-Hall Signal Processing Series). 775-802.
- PACHECO, M. A. C. Algoritmos Genéticos: Princípios e Aplicações. Disponível em <http://www.ica.ele.puc-rio.br/Downloads/38/CE-Apostila-Comp-Evol.pdf>. Acessado em 01 de abril de 2015.
- PENHA, Rosani Maria. *Análise de sinais em regime transiente aplicando a técnica de wavelet*. 1999. 95 p. Dissertação (Mestre em ciências)- IPEN, USP, São Paulo, 1999.
- Peper, F., & Noda, H. (1996). Hebb Learning of Features based on their Information Content. *NIPS*.
- PIERSOL, Allan G. *Harris' Shock and Vibration Handbook*. 5, ilustrada. ed. Michigan: McGraw-Hill, 2002. 1568 p.
- Piotrowski, John, (2006)-*Shaft alignment handbook* / John Piotrowski. 3rd ed.

Pisching, Marcos & Tasca, Arthur & Pessoa, Marcosiris & Junqueira, Fabrício & Miyagi, Paulo. (2017). Arquitetura para desenvolvimento de sistemas ciber-físicos aplicados na Indústria 4.0.

R. Keyth Mobley, "An introduction to Predictive Maintenance", 2<sup>nd</sup> Edition, 2002, Elsevier Ltd, ISBN: 978-0-7506-7431-4.

R.B. Walker, R. Vayanat, S. Perinpanayagam, I.K. Jennions, Unbalance localization through machine nonlinearities using an artificial neural network approach, Mechanism and Machine Theory, Volume 75, 2014, Pages 54-66.

Randall, R.B.. (2004). State of the Art in Monitoring Rotating Machinery - Part 1. Sound & vibration. 38. 14-21+13.

Randall, R.B.. (2004). State of the art in monitoring rotating machinery - Part 2. Sound and Vibration. 38. 10-17.

RAO, S. S., Mechanical Vibrations, 4th ed., New Jersey: Pearson Education, Inc., Upper Saddle River. 2004.

RAYLEIGH, John William Strutt Baron. The Theory of Sound. 2. ed. Havard: Macmillan,, 1894. 984 p. v. Volume 1.

Reddy M. C. S., Sekhar A. S. Application of artificial neural networks for identification of unbalance and looseness in rotor bearing systems. International Journal of Applied Science and Engineering, Vol. 11, Issue 1, 2013, p. 69-84.

Reyneri, L.M.. (1995). Weighted Radial Basis Functions for improved pattern recognition and signal processing. Neural Processing Letters. 2. 2-6.

RIOUL, O.; VETTERLI , M. Wavelets and Signal Processing. IEEE SP Magazine.

Rioul, Olivier & Vetterli, Martin. (1991). Wavelets and signal processing. Signal Processing Magazine, IEEE. 8. 14 - 38.

ROSAL, M. C. F. Programação não-linear aplicada à otimização de redes pressurizadas de distribuição de água.2007.117p.. Dissertação (Mestrado em Engenharia Civil) - Centro de Tecnologia e Geociências, Universidade Federal de Pernambuco, Recife, 2007.

Ruonan Liu, Boyuan Yang, Enrico Zio, Xuefeng Chen, Artificial intelligence for fault diagnosis of rotating machinery: A review, Mechanical Systems and Signal Processing, Volume 108, 2018, Pages 33-47.

S. Haykin, Neural Networks: A Comprehensive Foundation, Englewood Cliffs, NJ:Prentice Hall, 1994.

S. P. Timoshenko, History of Strength of Materials, McGraw-Hill, New York, 1953.

S. Takata, F. Kirnura, F.J.A.M. van Houten, E. Westkamper, M. Shpitalni, D. Ceglarek, J. Lee, Maintenance: Changing Role in Life Cycle Management, CIRP Annals, Volume 53, Issue 2, 2004, Pages 643-655.

Santiago, D. F. A. “Diagnóstico de Falhas em Máquinas Rotativas Utilizando Transformada de Wavelet e Redes Neurais Artificiais”, Campinas, Faculdade de Engenharia Mecânica, Universidade Estadual de Campinas, 2003. Tese (Doutorado).

Simon Haykin. 1998. *Neural Networks: A Comprehensive Foundation* (2nd ed.). Prentice Hall PTR, Upper Saddle River, NJ, USA.

Specht, Donald. (1991). A general regression neural network. *IEEE transactions on neural networks* / a publication of the IEEE Neural Networks Council. 2. 568-76.

Takata, S., Kimura, F., van Houten, F. J. A. M., Westkämper, E., Shpitalni, M., Ceglarek, D., & Lee, J. (2004). Maintenance: Changing role in life cycle management. *Annals of the CIRP*, 53(2), 643–656.

Titchmarsh, E. C. (1925), A Contribution to the Theory of Fourier Transforms. *Proceedings of the London Mathematical Society*, s2-23: 279-289. doi:10.1112/plms/s2-23.1.279

*Vibration Problems in Engineering* (Third Edition). S. P. Timoshenko (with the collaboration of D. H. Young). D. Van Nostrand, New York, 1955.

Voisin, Alexandre & Levrat, Eric & Cochetoux, Pierre & lung, Benoît. (2010). Generic prognosis model for proactive maintenance decision support: Application to pre-industrial e-maintenance test bed. *Journal of Intelligent Manufacturing*. 21. 10.

W. C. Titchmarsh, “A contribution to the theory of Fourier transforms.” *Proc. Lond. Math. Soc.*, Series 2, vol. 23, pp. 279–289, 1923.

Wolfgang Maass, Networks of spiking neurons: The third generation of neural network models, *Neural Networks*, Volume 10, Issue 9, 1997, Pages 1659-1671.

Wu, Xiaoxia & A. Jargon, Jeffrey & A. Skoog, Ronald & Paraschis, Loukas & E. Willner, Alan. (2009). Applications of Artificial Neural Networks in Optical Performance Monitoring. *Journal of Lightwave Technology*. 27. 3580-3589.

Xiaojun Zhou, Lifeng Xi, Jay Lee, Reliability-centered predictive maintenance scheduling for a continuously monitored system subject to degradation, *Reliability Engineering & System Safety*, Volume 92, Issue 4, 2007, Pages 530-534.

Yaguo Lei, Jing Lin, Zhengjia He, Ming J. Zuo, A review on empirical mode decomposition in fault diagnosis of rotating machinery, *Mechanical Systems and Signal Processing*, Volume 35, Issues 1–2, 2013, Pages 108-126.

Yuo-Tern Tsai, Kuo-Shong Wang, Lin-Chang Tsai, A study of availability-centered preventive maintenance for multi-component systems, *Reliability Engineering & System Safety*, Volume 84, Issue 3, 2004, Pages 261-270.

Zhang YanPing, Huang ShuHong, Hou JingHong, Shen Tao, Liu Wei, Continuous wavelet grey moment approach for vibration analysis of rotating machinery, *Mechanical Systems and Signal Processing*, Volume 20, Issue 5, 2006, Pages 1202-1220.

Zhou, Shiyu & Shi, Jianjun. (2001). Active Balancing and Vibration Control of Rotating Machinery: A Survey. *The Shock and Vibration Digest*. 33. 361-371.



## APÊNDICE A – RESULTADOS DAS SIMULAÇÕES

Os resultados das figuras de todas as simulações foram suprimidos deste apêndice pelo fato de somarem um grande volume de figuras e gráficos. Entretanto caso necessário favor solicitá-las via e-mail. Os resultados exibidos a seguir são referentes a simulação da melhor condição a 3600 rpm.

e-mail: eng.jonatamelo@gmail.com

Figura 51 - Matriz confusão 100 neurônios 3600 rpm/ 7g/ 0,3mm

**Matriz confusão - 3600 rpm/ 7g/ 0,3mm**

Output Class	1	2	3	4	
	64 25.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	0 0.0%	64 25.0%	0 0.0%	0 0.0%	100% 0.0%
	0 0.0%	0 0.0%	64 25.0%	0 0.0%	100% 0.0%
	0 0.0%	0 0.0%	0 0.0%	64 25.0%	100% 0.0%
	1	2	3	4	
Target Class					

Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Figura 52 - Matriz confusão 100 neurônios 3600 rpm/ 15g/ 0,6mm

**Matriz confusão - 3600 rpm/ 15g/ 0,6mm**

Output Class	1	64 25.0%	0 0.0%	1 0.4%	0 0.0%	98.5% 1.5%
	2	0 0.0%	64 25.0%	0 0.0%	0 0.0%	100% 0.0%
	3	0 0.0%	0 0.0%	63 24.6%	0 0.0%	100% 0.0%
	4	0 0.0%	0 0.0%	0 0.0%	64 25.0%	100% 0.0%
		100% 0.0%	100% 0.0%	98.4% 1.6%	100% 0.0%	99.6% 0.4%
		1	2	3	4	
		Target Class				

Fonte: Toolbox do Matlab com dados fornecidos pelo autor

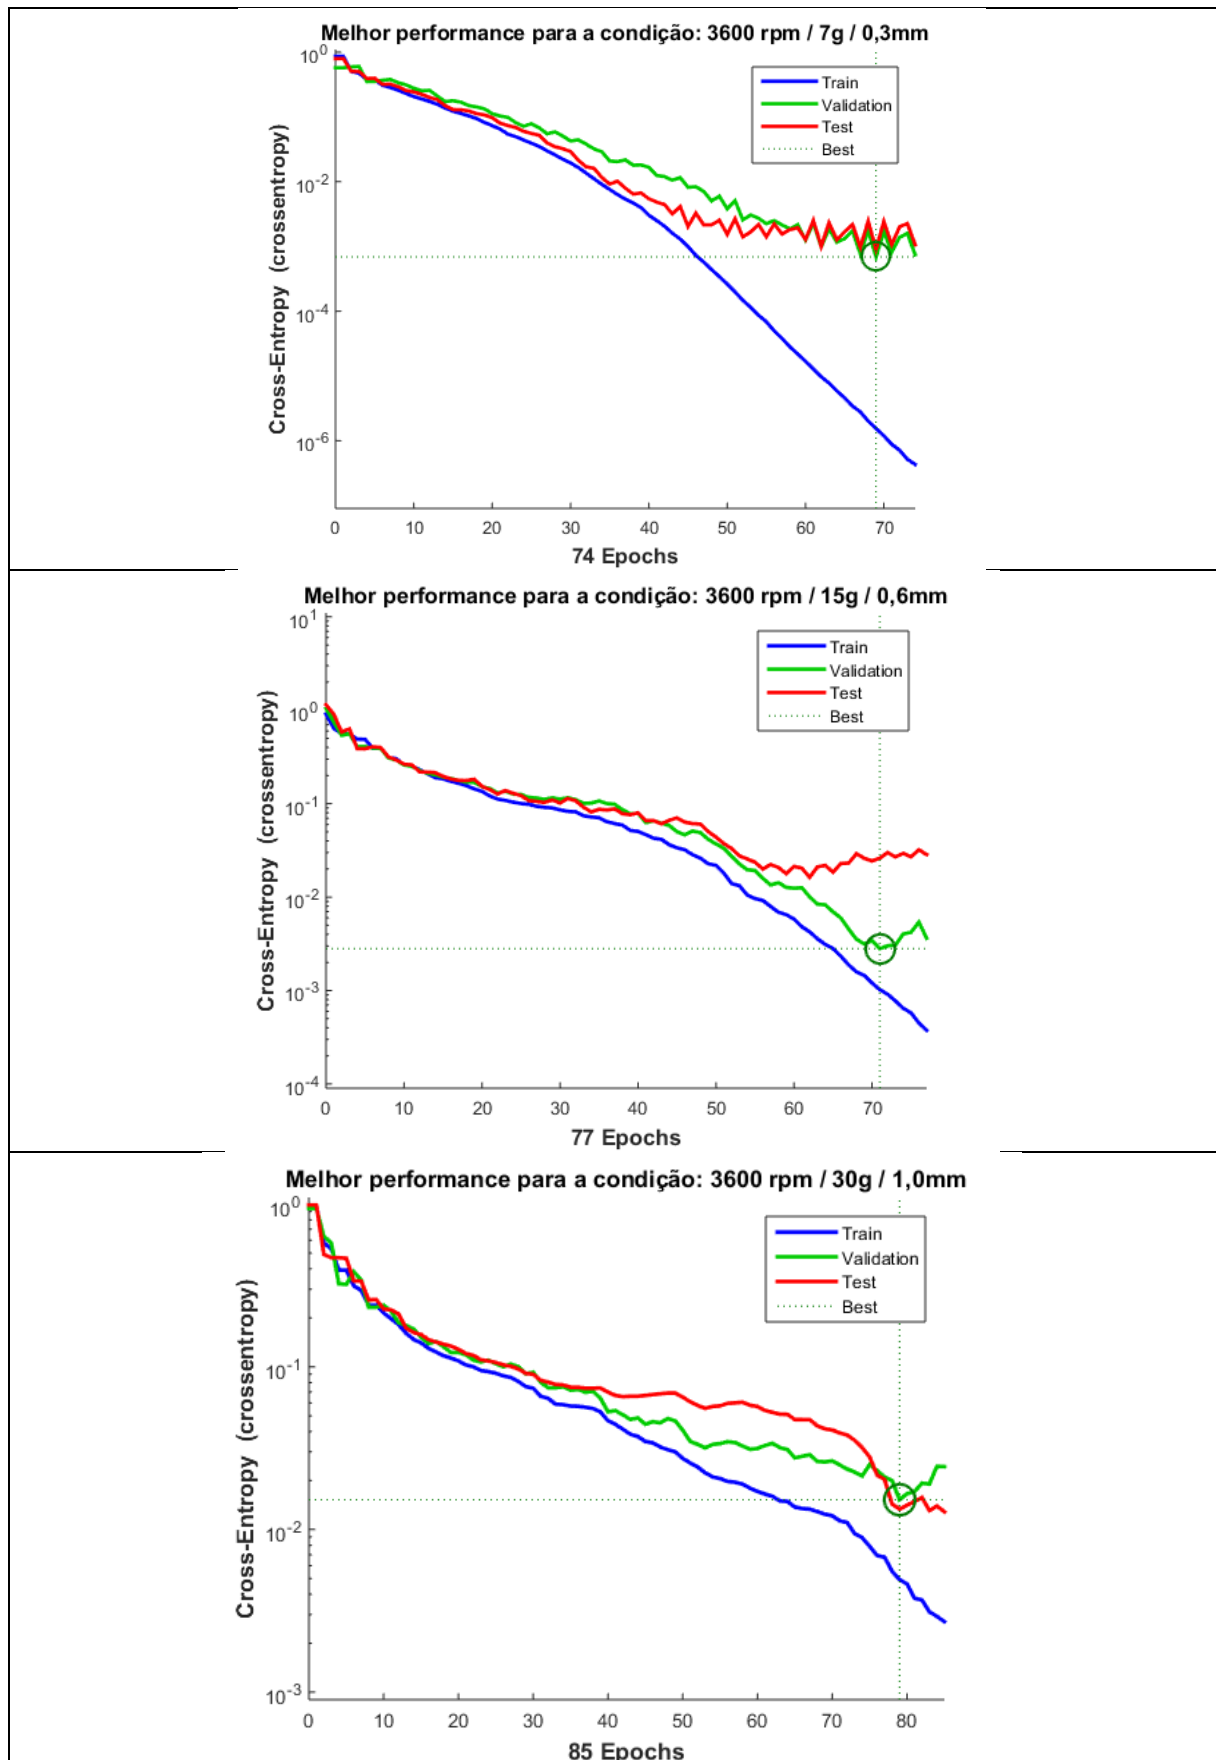
Figura 53 - Matriz confusão 100 neurônios 3600 rpm/ 30g/ 1,0mm

**Matriz confusão - 3600 rpm/ 30g/ 1,0mm**

Output Class	1	64 25.0%	0 0.0%	1 0.4%	0 0.0%	98.5% 1.5%
	2	0 0.0%	64 25.0%	0 0.0%	0 0.0%	100% 0.0%
	3	0 0.0%	0 0.0%	63 24.6%	0 0.0%	100% 0.0%
	4	0 0.0%	0 0.0%	0 0.0%	64 25.0%	100% 0.0%
		100% 0.0%	100% 0.0%	98.4% 1.6%	100% 0.0%	99.6% 0.4%
		1	2	3	4	
		Target Class				


Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Figura 54 - Gráficos de performance no treinamento da rede



Fonte: Toolbox do Matlab com dados fornecidos pelo autor

Figura 55 - Evolução do aprendizado com o acréscimo de neurônios



Fonte: O autor, 2018

## APÊNDICE B – ALGORITMO PDFMR

No algoritmo exibido a seguir constam as funcionalidades utilizadas ao longo do texto. Entretanto as análises de pré-processamento STFT e PSD que não foram aplicadas nas redes neurais artificiais foram suprimidas. Os dados utilizados foram suprimidos por conta de seu extenso volume, entretanto caso necessário favor entrar em contato via e-mail que os mesmos serão disponibilizados.

e-mail: eng.jonatamelo@gmail.com

```
%Esta aplicação tem como objetivo o diagnóstico de falhas como
%desbalanceamento e desalinhamento em máquinas rotativas
clear all;
close all;
clc
load('Dados.mat');
load('Alvo.mat');
load('Alvos.mat');
neuronios=90;
m=48;
t=Dados(:,1);
N=length(t);
x(N,m)=zeros;
v(N,m)=zeros;
fs=length(t)/t(N);
k=1:N;
C=N/2;
corte=ceil(C);
freq=k*(fs/N);
tamanho_janela=512;
janela=hanning(tamanho_janela);
nfft=tamanho_janela;
noverlap=tamanho_janela-1;

for i=1:m
    x(:,i)=Dados(:,2*i);
    X(:,i)=fft(x(:,i))/C;
    X_mag(1:corte,i)=abs(X(1:corte,i));
    Xnovo(:,i)=(X_mag(1:corte,i))/(norm(X_mag(1:corte,i)));

    %           % Gráficos da transformada FFT
    %           figure;
    %           plot(freq(1:corte),X_mag(1:corte,i),'LineWidth',2.0);
    %           title('Análise FFT','FontSize',20,'FontWeight','bold');
    %           xlabel('Frequência (Hz)','FontSize',20,'FontWeight','bold');
    %           ylabel('Amplitude','FontSize',20,'FontWeight','bold');
    %           set(gca,'FontSize',16);
    %           %Gráficos no domínio do tempo
    %           figure;
    %           plot(t(:),x(:,i),'LineWidth',2.0);
    %           title('Dados no domínio do
tempo','FontSize',20,'FontWeight','bold');
    %           xlabel('Tempo (s)','FontSize',20,'FontWeight','bold');
    %           ylabel('Aceleração (g)','FontSize',20,'FontWeight','bold');
```

```
% set(gca,'FontSize',16);
```

```
%Decomposição Wavelet
```

```
wavelet='db4';
[c(:,i), l(:,i)]=wavedec(x(:,i), 3, wavelet);
A3(:,i)=wrcoef('a', c(:,i), l(:,i), wavelet, 3);
D3(:,i)=wrcoef('d', c(:,i), l(:,i), wavelet, 3);
D2(:,i)=wrcoef('d', c(:,i), l(:,i), wavelet, 2);
D1(:,i)=wrcoef('d', c(:,i), l(:,i), wavelet, 1);

A_3(:,i)=A3(1:corde,i);
D_3(:,i)=D3(1:corde,i);
D_2(:,i)=D2(1:corde,i);
D_1(:,i)=D1(1:corde,i);
D_3n(:,i)=(D_3(1:corde,i))/(norm(D_3(1:corde,i)));
```

```
level=8;
wpt(:,i)=wpdec(x(:,i),level,'db4');
varargout(:,i)=read(wpt(:,i),'data');
Z(:,i)=varargout(1:corde,i);
```

```
end
```

```
RA3=cat(2,A_3(:,1),A_3(:,4),A_3(:,13),A_3(:,22),A_3(:,1),A_3(:,7),A_3(:,16),
,A_3(:,26),A_3(:,1),A_3(:,10),A_3(:,19),A_3(:,30),A_3(:,2),A_3(:,5),A_3(:,14),
,A_3(:,31),A_3(:,2),A_3(:,8),A_3(:,17),A_3(:,35),A_3(:,2),A_3(:,11),A_3(:,20),
,A_3(:,39),A_3(:,3),A_3(:,6),A_3(:,15),A_3(:,40),A_3(:,3),A_3(:,9),A_3(:,18),
,A_3(:,44),A_3(:,3),A_3(:,12),A_3(:,21),A_3(:,48)));
RD3=cat(2,D_3(:,1),D_3(:,4),D_3(:,13),D_3(:,22),D_3(:,1),D_3(:,7),D_3(:,16),
,D_3(:,26),D_3(:,1),D_3(:,10),D_3(:,19),D_3(:,30),D_3(:,2),D_3(:,5),D_3(:,14),
,D_3(:,31),D_3(:,2),D_3(:,8),D_3(:,17),D_3(:,35),D_3(:,2),D_3(:,11),D_3(:,20),
,D_3(:,39),D_3(:,3),D_3(:,6),D_3(:,15),D_3(:,40),D_3(:,3),D_3(:,9),D_3(:,18),
,D_3(:,44),D_3(:,3),D_3(:,12),D_3(:,21),D_3(:,48)));
RD2=cat(2,D_2(:,1),D_2(:,4),D_2(:,13),D_2(:,22),D_2(:,1),D_2(:,7),D_2(:,16),
,D_2(:,26),D_2(:,1),D_2(:,10),D_2(:,19),D_2(:,30),D_2(:,2),D_2(:,5),D_2(:,14),
,D_2(:,31),D_2(:,2),D_2(:,8),D_2(:,17),D_2(:,35),D_2(:,2),D_2(:,11),D_2(:,20),
,D_2(:,39),D_2(:,3),D_2(:,6),D_2(:,15),D_2(:,40),D_2(:,3),D_2(:,9),D_2(:,18),
,D_2(:,44),D_2(:,3),D_2(:,12),D_2(:,21),D_2(:,48)));
RD1=cat(2,D_1(:,1),D_1(:,4),D_1(:,13),D_1(:,22),D_1(:,1),D_1(:,7),D_1(:,16),
,D_1(:,26),D_1(:,1),D_1(:,10),D_1(:,19),D_1(:,30),D_1(:,2),D_1(:,5),D_1(:,14),
,D_1(:,31),D_1(:,2),D_1(:,8),D_1(:,17),D_1(:,35),D_1(:,2),D_1(:,11),D_1(:,20),
,D_1(:,39),D_1(:,3),D_1(:,6),D_1(:,15),D_1(:,40),D_1(:,3),D_1(:,9),D_1(:,18),
,D_1(:,44),D_1(:,3),D_1(:,12),D_1(:,21),D_1(:,48)));
Rx=cat(2,x(:,1),x(:,4),x(:,13),x(:,22),x(:,1),x(:,7),x(:,16),x(:,26),x(:,1),
,x(:,10),x(:,19),x(:,30),x(:,2),x(:,5),x(:,14),x(:,31),x(:,2),x(:,8),x(:,17),
,x(:,35),x(:,2),x(:,11),x(:,20),x(:,39),x(:,3),x(:,6),x(:,15),x(:,40),x(:,3),
,x(:,9),x(:,18),x(:,44),x(:,3),x(:,12),x(:,21),x(:,48)));
```

```
% % Gráficos decomposição Wavelet
% for j=1:36;
% figure,
% subplot(5,1,1)
% plot(t(1:corde),x(1:corde,j));
% title('Sinal=A3+D3+D2+D1');
% ylabel('Sinal');
```



```

X900_7g_03mm_novo27=X900_7g_03mm(833:864,:);
X900_7g_03mm_novo28=X900_7g_03mm(865:896,:);
X900_7g_03mm_novo29=X900_7g_03mm(897:928,:);
X900_7g_03mm_novo30=X900_7g_03mm(929:960,:);
X900_7g_03mm_novo31=X900_7g_03mm(961:992,:);
X900_7g_03mm_novo32=X900_7g_03mm(993:1024,:);
X900_7g_03mm_novo33=X900_7g_03mm(1025:1056,:);
X900_7g_03mm_novo34=X900_7g_03mm(1057:1088,:);
X900_7g_03mm_novo35=X900_7g_03mm(1089:1120,:);
X900_7g_03mm_novo36=X900_7g_03mm(1121:1152,:);
X900_7g_03mm_novo37=X900_7g_03mm(1153:1184,:);
X900_7g_03mm_novo38=X900_7g_03mm(1185:1216,:);
X900_7g_03mm_novo39=X900_7g_03mm(1217:1248,:);
X900_7g_03mm_novo40=X900_7g_03mm(1249:1280,:);
X900_7g_03mm_novo41=X900_7g_03mm(1281:1312,:);
X900_7g_03mm_novo42=X900_7g_03mm(1313:1344,:);
X900_7g_03mm_novo43=X900_7g_03mm(1345:1376,:);
X900_7g_03mm_novo44=X900_7g_03mm(1377:1408,:);
X900_7g_03mm_novo45=X900_7g_03mm(1409:1440,:);
X900_7g_03mm_novo46=X900_7g_03mm(1441:1472,:);
X900_7g_03mm_novo47=X900_7g_03mm(1473:1504,:);
X900_7g_03mm_novo48=X900_7g_03mm(1505:1536,:);
X900_7g_03mm_novo49=X900_7g_03mm(1537:1568,:);
X900_7g_03mm_novo50=X900_7g_03mm(1569:1600,:);
X900_7g_03mm_novo51=X900_7g_03mm(1601:1632,:);
X900_7g_03mm_novo52=X900_7g_03mm(1633:1664,:);
X900_7g_03mm_novo53=X900_7g_03mm(1665:1696,:);
X900_7g_03mm_novo54=X900_7g_03mm(1697:1728,:);
X900_7g_03mm_novo55=X900_7g_03mm(1729:1760,:);
X900_7g_03mm_novo56=X900_7g_03mm(1761:1792,:);
X900_7g_03mm_novo57=X900_7g_03mm(1793:1824,:);
X900_7g_03mm_novo58=X900_7g_03mm(1825:1856,:);
X900_7g_03mm_novo59=X900_7g_03mm(1857:1888,:);
X900_7g_03mm_novo60=X900_7g_03mm(1889:1920,:);
X900_7g_03mm_novo61=X900_7g_03mm(1921:1952,:);
X900_7g_03mm_novo62=X900_7g_03mm(1953:1984,:);
X900_7g_03mm_novo63=X900_7g_03mm(1985:2016,:);
X900_7g_03mm_novo64=X900_7g_03mm(2017:2048,:);

```

```

X_900_7g_03mm_novo=cat(2,X900_7g_03mm_novo1,X900_7g_03mm_novo2,X900_7g_03mm_novo3,X900_7g_03mm_novo4,X900_7g_03mm_novo5,X900_7g_03mm_novo6,X900_7g_03mm_novo7,X900_7g_03mm_novo8,X900_7g_03mm_novo9,X900_7g_03mm_novo10,X900_7g_03mm_novo11,X900_7g_03mm_novo12,X900_7g_03mm_novo13,X900_7g_03mm_novo14,X900_7g_03mm_novo15,X900_7g_03mm_novo16,X900_7g_03mm_novo17,X900_7g_03mm_novo18,X900_7g_03mm_novo19,X900_7g_03mm_novo20,X900_7g_03mm_novo21,X900_7g_03mm_novo22,X900_7g_03mm_novo23,X900_7g_03mm_novo24,X900_7g_03mm_novo25,X900_7g_03mm_novo26,X900_7g_03mm_novo27,X900_7g_03mm_novo28,X900_7g_03mm_novo29,X900_7g_03mm_novo30,X900_7g_03mm_novo31,X900_7g_03mm_novo32,X900_7g_03mm_novo33,X900_7g_03mm_novo34,X900_7g_03mm_novo35,X900_7g_03mm_novo36,X900_7g_03mm_novo37,X900_7g_03mm_novo38,X900_7g_03mm_novo39,X900_7g_03mm_novo40,X900_7g_03mm_novo41,X900_7g_03mm_novo42,X900_7g_03mm_novo43,X900_7g_03mm_novo44,X900_7g_03mm_novo45,X900_7g_03mm_novo46,X900_7g_03mm_novo47,X900_7g_03mm_novo48,X900_7g_03mm_novo49,X900_7g_03mm_novo50,X900_7g_03mm_novo51,X900_7g_03mm_novo52,X900_7g_03mm_novo53,X900_7g_03mm_novo54,X900_7g_03mm_novo55,X900_7g_03mm_novo56,X900_7g_03mm_novo57,X900_7g_03mm_novo58,X900_7g_03mm_novo59,X900_7g_03mm_novo60,X900_7g_03mm_novo61,X900_7g_03mm_novo62,X900_7g_03mm_novo63,X900_7g_03mm_novo64);
inputs1=X_900_7g_03mm_novo;
targets1=Alvo_novo;

```





```

X900_15g_06mm_novo27=X900_15g_06mm(833:864,:);
X900_15g_06mm_novo28=X900_15g_06mm(865:896,:);
X900_15g_06mm_novo29=X900_15g_06mm(897:928,:);
X900_15g_06mm_novo30=X900_15g_06mm(929:960,:);
X900_15g_06mm_novo31=X900_15g_06mm(961:992,:);
X900_15g_06mm_novo32=X900_15g_06mm(993:1024,:);
X900_15g_06mm_novo33=X900_15g_06mm(1025:1056,:);
X900_15g_06mm_novo34=X900_15g_06mm(1057:1088,:);
X900_15g_06mm_novo35=X900_15g_06mm(1089:1120,:);
X900_15g_06mm_novo36=X900_15g_06mm(1121:1152,:);
X900_15g_06mm_novo37=X900_15g_06mm(1153:1184,:);
X900_15g_06mm_novo38=X900_15g_06mm(1185:1216,:);
X900_15g_06mm_novo39=X900_15g_06mm(1217:1248,:);
X900_15g_06mm_novo40=X900_15g_06mm(1249:1280,:);
X900_15g_06mm_novo41=X900_15g_06mm(1281:1312,:);
X900_15g_06mm_novo42=X900_15g_06mm(1313:1344,:);
X900_15g_06mm_novo43=X900_15g_06mm(1345:1376,:);
X900_15g_06mm_novo44=X900_15g_06mm(1377:1408,:);
X900_15g_06mm_novo45=X900_15g_06mm(1409:1440,:);
X900_15g_06mm_novo46=X900_15g_06mm(1441:1472,:);
X900_15g_06mm_novo47=X900_15g_06mm(1473:1504,:);
X900_15g_06mm_novo48=X900_15g_06mm(1505:1536,:);
X900_15g_06mm_novo49=X900_15g_06mm(1537:1568,:);
X900_15g_06mm_novo50=X900_15g_06mm(1569:1600,:);
X900_15g_06mm_novo51=X900_15g_06mm(1601:1632,:);
X900_15g_06mm_novo52=X900_15g_06mm(1633:1664,:);
X900_15g_06mm_novo53=X900_15g_06mm(1665:1696,:);
X900_15g_06mm_novo54=X900_15g_06mm(1697:1728,:);
X900_15g_06mm_novo55=X900_15g_06mm(1729:1760,:);
X900_15g_06mm_novo56=X900_15g_06mm(1761:1792,:);
X900_15g_06mm_novo57=X900_15g_06mm(1793:1824,:);
X900_15g_06mm_novo58=X900_15g_06mm(1825:1856,:);
X900_15g_06mm_novo59=X900_15g_06mm(1857:1888,:);
X900_15g_06mm_novo60=X900_15g_06mm(1889:1920,:);
X900_15g_06mm_novo61=X900_15g_06mm(1921:1952,:);
X900_15g_06mm_novo62=X900_15g_06mm(1953:1984,:);
X900_15g_06mm_novo63=X900_15g_06mm(1985:2016,:);
X900_15g_06mm_novo64=X900_15g_06mm(2017:2048,:);

```

```

X_900_15g_06mm_novo=cat(2,X900_15g_06mm_novo1,X900_15g_06mm_novo2,X900_15g_06mm_novo3,X900_15g_06mm_novo4,X900_15g_06mm_novo5,X900_15g_06mm_novo6,X900_15g_06mm_novo7,X900_15g_06mm_novo8,X900_15g_06mm_novo9,X900_15g_06mm_novo10,X900_15g_06mm_novo11,X900_15g_06mm_novo12,X900_15g_06mm_novo13,X900_15g_06mm_novo14,X900_15g_06mm_novo15,X900_15g_06mm_novo16,X900_15g_06mm_novo17,X900_15g_06mm_novo18,X900_15g_06mm_novo19,X900_15g_06mm_novo20,X900_15g_06mm_novo21,X900_15g_06mm_novo22,X900_15g_06mm_novo23,X900_15g_06mm_novo24,X900_15g_06mm_novo25,X900_15g_06mm_novo26,X900_15g_06mm_novo27,X900_15g_06mm_novo28,X900_15g_06mm_novo29,X900_15g_06mm_novo30,X900_15g_06mm_novo31,X900_15g_06mm_novo32,X900_15g_06mm_novo33,X900_15g_06mm_novo34,X900_15g_06mm_novo35,X900_15g_06mm_novo36,X900_15g_06mm_novo37,X900_15g_06mm_novo38,X900_15g_06mm_novo39,X900_15g_06mm_novo40,X900_15g_06mm_novo41,X900_15g_06mm_novo42,X900_15g_06mm_novo43,X900_15g_06mm_novo44,X900_15g_06mm_novo45,X900_15g_06mm_novo46,X900_15g_06mm_novo47,X900_15g_06mm_novo48,X900_15g_06mm_novo49,X900_15g_06mm_novo50,X900_15g_06mm_novo51,X900_15g_06mm_novo52,X900_15g_06mm_novo53,X900_15g_06mm_novo54,X900_15g_06mm_novo55,X900_15g_06mm_novo56,X900_15g_06mm_novo57,X900_15g_06mm_novo58,X900_15g_06mm_novo59,X900_15g_06mm_novo60,X900_15g_06mm_novo61,X900_15g_06mm_novo62,X900_15g_06mm_novo63,X900_15g_06mm_novo64);
inputs2=X_900_15g_06mm_novo;
targets2=Alvo_novo;

```

```
hiddenLayerSize = neuronios;
% Create a Pattern Recognition Network
net2 = patternnet(hiddenLayerSize);
% Set up Division of Data for Training, Validation, Testing
net2.divideParam.trainRatio = 70/100;
net2.divideParam.valRatio   = 15/100;
net2.divideParam.testRatio  = 15/100;
% Train the Network
[net2,tr] = train(net2,inputs2,targets2);
% Test the Network
outputs2 = round(net2(inputs2));
errors2 = gsubtract(targets2,outputs2);
performance2 = perform(net2,targets2,outputs2);
tInd2 = tr.testInd;
tstOutputs2 = net2(inputs2(:,tInd2));
tstPerform2 = perform(net2,targets2(:,tInd2),tstOutputs2);
% View the Network
view(net2)
figure, plotperform(tr); title('Melhor performance para a condição: 900 rpm
/ 15g / 0,6mm')
figure, plotconfusion(targets2,outputs2); title('Matriz confusão - 900 rpm/
15g/ 0,6mm')
```

%Rede neural para reconhecimento de padrões de vibração - Velocidade 15Hz  
%(900rpm), Massa 30g e desalinhamento 1,0 mm

```
X900_30g_1mm=cat(2,(A_3(:,1)),(A_3(:,10)),(A_3(:,19))),(A_3(:,30)));
Alvo_novo=cat(2,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo);
X900_30g_1mm_novo1=X900_30g_1mm(1:32,:);
X900_30g_1mm_novo2=X900_30g_1mm(33:64,:);
X900_30g_1mm_novo3=X900_30g_1mm(65:96,:);
X900_30g_1mm_novo4=X900_30g_1mm(97:128,:);
X900_30g_1mm_novo5=X900_30g_1mm(129:160,:);
X900_30g_1mm_novo6=X900_30g_1mm(161:192,:);
X900_30g_1mm_novo7=X900_30g_1mm(193:224,:);
X900_30g_1mm_novo8=X900_30g_1mm(225:256,:);
X900_30g_1mm_novo9=X900_30g_1mm(257:288,:);
X900_30g_1mm_novo10=X900_30g_1mm(289:320,:);
X900_30g_1mm_novo11=X900_30g_1mm(321:352,:);
X900_30g_1mm_novo12=X900_30g_1mm(353:384,:);
X900_30g_1mm_novo13=X900_30g_1mm(385:416,:);
X900_30g_1mm_novo14=X900_30g_1mm(417:448,:);
X900_30g_1mm_novo15=X900_30g_1mm(449:480,:);
X900_30g_1mm_novo16=X900_30g_1mm(481:512,:);
X900_30g_1mm_novo17=X900_30g_1mm(513:544,:);
X900_30g_1mm_novo18=X900_30g_1mm(545:576,:);
X900_30g_1mm_novo19=X900_30g_1mm(577:608,:);
X900_30g_1mm_novo20=X900_30g_1mm(609:640,:);
X900_30g_1mm_novo21=X900_30g_1mm(641:672,:);
X900_30g_1mm_novo22=X900_30g_1mm(673:704,:);
X900_30g_1mm_novo23=X900_30g_1mm(705:736,:);
X900_30g_1mm_novo24=X900_30g_1mm(737:768,:);
```

```

X900_30g_1mm_novo25=X900_30g_1mm(769:800,:);
X900_30g_1mm_novo26=X900_30g_1mm(801:832,:);
X900_30g_1mm_novo27=X900_30g_1mm(833:864,:);
X900_30g_1mm_novo28=X900_30g_1mm(865:896,:);
X900_30g_1mm_novo29=X900_30g_1mm(897:928,:);
X900_30g_1mm_novo30=X900_30g_1mm(929:960,:);
X900_30g_1mm_novo31=X900_30g_1mm(961:992,:);
X900_30g_1mm_novo32=X900_30g_1mm(993:1024,:);
X900_30g_1mm_novo33=X900_30g_1mm(1025:1056,:);
X900_30g_1mm_novo34=X900_30g_1mm(1057:1088,:);
X900_30g_1mm_novo35=X900_30g_1mm(1089:1120,:);
X900_30g_1mm_novo36=X900_30g_1mm(1121:1152,:);
X900_30g_1mm_novo37=X900_30g_1mm(1153:1184,:);
X900_30g_1mm_novo38=X900_30g_1mm(1185:1216,:);
X900_30g_1mm_novo39=X900_30g_1mm(1217:1248,:);
X900_30g_1mm_novo40=X900_30g_1mm(1249:1280,:);
X900_30g_1mm_novo41=X900_30g_1mm(1281:1312,:);
X900_30g_1mm_novo42=X900_30g_1mm(1313:1344,:);
X900_30g_1mm_novo43=X900_30g_1mm(1345:1376,:);
X900_30g_1mm_novo44=X900_30g_1mm(1377:1408,:);
X900_30g_1mm_novo45=X900_30g_1mm(1409:1440,:);
X900_30g_1mm_novo46=X900_30g_1mm(1441:1472,:);
X900_30g_1mm_novo47=X900_30g_1mm(1473:1504,:);
X900_30g_1mm_novo48=X900_30g_1mm(1505:1536,:);
X900_30g_1mm_novo49=X900_30g_1mm(1537:1568,:);
X900_30g_1mm_novo50=X900_30g_1mm(1569:1600,:);
X900_30g_1mm_novo51=X900_30g_1mm(1601:1632,:);
X900_30g_1mm_novo52=X900_30g_1mm(1633:1664,:);
X900_30g_1mm_novo53=X900_30g_1mm(1665:1696,:);
X900_30g_1mm_novo54=X900_30g_1mm(1697:1728,:);
X900_30g_1mm_novo55=X900_30g_1mm(1729:1760,:);
X900_30g_1mm_novo56=X900_30g_1mm(1761:1792,:);
X900_30g_1mm_novo57=X900_30g_1mm(1793:1824,:);
X900_30g_1mm_novo58=X900_30g_1mm(1825:1856,:);
X900_30g_1mm_novo59=X900_30g_1mm(1857:1888,:);
X900_30g_1mm_novo60=X900_30g_1mm(1889:1920,:);
X900_30g_1mm_novo61=X900_30g_1mm(1921:1952,:);
X900_30g_1mm_novo62=X900_30g_1mm(1953:1984,:);
X900_30g_1mm_novo63=X900_30g_1mm(1985:2016,:);
X900_30g_1mm_novo64=X900_30g_1mm(2017:2048,:);

```

```

X_900_30g_1mm_novo=cat(2,X900_30g_1mm_novo1,X900_30g_1mm_novo2,X900_30g_1mm_novo3,X900_30g_1mm_novo4,X900_30g_1mm_novo5,X900_30g_1mm_novo6,X900_30g_1mm_novo7,X900_30g_1mm_novo8,X900_30g_1mm_novo9,X900_30g_1mm_novo10,X900_30g_1mm_novo11,X900_30g_1mm_novo12,X900_30g_1mm_novo13,X900_30g_1mm_novo14,X900_30g_1mm_novo15,X900_30g_1mm_novo16,X900_30g_1mm_novo17,X900_30g_1mm_novo18,X900_30g_1mm_novo19,X900_30g_1mm_novo20,X900_30g_1mm_novo21,X900_30g_1mm_novo22,X900_30g_1mm_novo23,X900_30g_1mm_novo24,X900_30g_1mm_novo25,X900_30g_1mm_novo26,X900_30g_1mm_novo27,X900_30g_1mm_novo28,X900_30g_1mm_novo29,X900_30g_1mm_novo30,X900_30g_1mm_novo31,X900_30g_1mm_novo32,X900_30g_1mm_novo33,X900_30g_1mm_novo34,X900_30g_1mm_novo35,X900_30g_1mm_novo36,X900_30g_1mm_novo37,X900_30g_1mm_novo38,X900_30g_1mm_novo39,X900_30g_1mm_novo40,X900_30g_1mm_novo41,X900_30g_1mm_novo42,X900_30g_1mm_novo43,X900_30g_1mm_novo44,X900_30g_1mm_novo45,X900_30g_1mm_novo46,X900_30g_1mm_novo47,X900_30g_1mm_novo48,X900_30g_1mm_novo49,X900_30g_1mm_novo50,X900_30g_1mm_novo51,X900_30g_1mm_novo52,X900_30g_1mm_novo53,X900_30g_1mm_novo54,X900_30g_1mm_novo55,X900_30g_1mm_novo56,X900_30g_1mm_novo57,X900_30g_1mm_novo58,X900_30g_1mm_novo59,X900_30g_1mm_novo60,X900_30g_1mm_novo61,X900_30g_1mm_novo62,X900_30g_1mm_novo63,X900_30g_1mm_novo64);
inputs3=X_900_30g_1mm_novo;
targets3=Alvo_novo;

```

```

hiddenLayerSize = neuronios;
% Create a Pattern Recognition Network
net3 = patternnet(hiddenLayerSize);
% Set up Division of Data for Training, Validation, Testing
net3.divideParam.trainRatio = 70/100;
net3.divideParam.valRatio   = 15/100;
net3.divideParam.testRatio  = 15/100;
% Train the Network
[net3,tr] = train(net3,inputs3,targets3);
% Test the Network
outputs3 = round(net3(inputs3));
errors3 = gsubtract(targets3,outputs3);
performance3 = perform(net3,targets3,outputs3);
tInd3 = tr.testInd;
tstOutputs3 = net3(inputs3(:,tInd3));
tstPerform3 = perform(net3,targets3(:,tInd3),tstOutputs3);
% View the Network
view(net3)
figure, plotperform(tr); title('Melhor performance para a condição: 900 rpm
/ 30g / 1,0mm')
figure, plotconfusion(targets3,outputs3); title('Matriz confusão - 900 rpm/
30g/ 1,0mm')

##### VELOCIDADE 30Hz (1800RPM) #####

%Rede neural para reconhecimento de padrões de vibração - Velocidade 30Hz
%(1800rpm), Massa 7g e desalinhamento 0,3 mm

X1800_7g_03mm=cat(2,(A_3(:,2)),(A_3(:,5)),(A_3(:,14)),(A_3(:,31)));
Alvo_novo=cat(2,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo);
X1800_7g_03mm_novo1=X1800_7g_03mm(1:32,:);
X1800_7g_03mm_novo2=X1800_7g_03mm(33:64,:);
X1800_7g_03mm_novo3=X1800_7g_03mm(65:96,:);
X1800_7g_03mm_novo4=X1800_7g_03mm(97:128,:);
X1800_7g_03mm_novo5=X1800_7g_03mm(129:160,:);
X1800_7g_03mm_novo6=X1800_7g_03mm(161:192,:);
X1800_7g_03mm_novo7=X1800_7g_03mm(193:224,:);
X1800_7g_03mm_novo8=X1800_7g_03mm(225:256,:);
X1800_7g_03mm_novo9=X1800_7g_03mm(257:288,:);
X1800_7g_03mm_novo10=X1800_7g_03mm(289:320,:);
X1800_7g_03mm_novo11=X1800_7g_03mm(321:352,:);
X1800_7g_03mm_novo12=X1800_7g_03mm(353:384,:);
X1800_7g_03mm_novo13=X1800_7g_03mm(385:416,:);
X1800_7g_03mm_novo14=X1800_7g_03mm(417:448,:);
X1800_7g_03mm_novo15=X1800_7g_03mm(449:480,:);
X1800_7g_03mm_novo16=X1800_7g_03mm(481:512,:);
X1800_7g_03mm_novo17=X1800_7g_03mm(513:544,:);
X1800_7g_03mm_novo18=X1800_7g_03mm(545:576,:);
X1800_7g_03mm_novo19=X1800_7g_03mm(577:608,:);
X1800_7g_03mm_novo20=X1800_7g_03mm(609:640,:);
X1800_7g_03mm_novo21=X1800_7g_03mm(641:672,:);

```

```

X1800_7g_03mm_novo22=X1800_7g_03mm(673:704,:);
X1800_7g_03mm_novo23=X1800_7g_03mm(705:736,:);
X1800_7g_03mm_novo24=X1800_7g_03mm(737:768,:);
X1800_7g_03mm_novo25=X1800_7g_03mm(769:800,:);
X1800_7g_03mm_novo26=X1800_7g_03mm(801:832,:);
X1800_7g_03mm_novo27=X1800_7g_03mm(833:864,:);
X1800_7g_03mm_novo28=X1800_7g_03mm(865:896,:);
X1800_7g_03mm_novo29=X1800_7g_03mm(897:928,:);
X1800_7g_03mm_novo30=X1800_7g_03mm(929:960,:);
X1800_7g_03mm_novo31=X1800_7g_03mm(961:992,:);
X1800_7g_03mm_novo32=X1800_7g_03mm(993:1024,:);
X1800_7g_03mm_novo33=X1800_7g_03mm(1025:1056,:);
X1800_7g_03mm_novo34=X1800_7g_03mm(1057:1088,:);
X1800_7g_03mm_novo35=X1800_7g_03mm(1089:1120,:);
X1800_7g_03mm_novo36=X1800_7g_03mm(1121:1152,:);
X1800_7g_03mm_novo37=X1800_7g_03mm(1153:1184,:);
X1800_7g_03mm_novo38=X1800_7g_03mm(1185:1216,:);
X1800_7g_03mm_novo39=X1800_7g_03mm(1217:1248,:);
X1800_7g_03mm_novo40=X1800_7g_03mm(1249:1280,:);
X1800_7g_03mm_novo41=X1800_7g_03mm(1281:1312,:);
X1800_7g_03mm_novo42=X1800_7g_03mm(1313:1344,:);
X1800_7g_03mm_novo43=X1800_7g_03mm(1345:1376,:);
X1800_7g_03mm_novo44=X1800_7g_03mm(1377:1408,:);
X1800_7g_03mm_novo45=X1800_7g_03mm(1409:1440,:);
X1800_7g_03mm_novo46=X1800_7g_03mm(1441:1472,:);
X1800_7g_03mm_novo47=X1800_7g_03mm(1473:1504,:);
X1800_7g_03mm_novo48=X1800_7g_03mm(1505:1536,:);
X1800_7g_03mm_novo49=X1800_7g_03mm(1537:1568,:);
X1800_7g_03mm_novo50=X1800_7g_03mm(1569:1600,:);
X1800_7g_03mm_novo51=X1800_7g_03mm(1601:1632,:);
X1800_7g_03mm_novo52=X1800_7g_03mm(1633:1664,:);
X1800_7g_03mm_novo53=X1800_7g_03mm(1665:1696,:);
X1800_7g_03mm_novo54=X1800_7g_03mm(1697:1728,:);
X1800_7g_03mm_novo55=X1800_7g_03mm(1729:1760,:);
X1800_7g_03mm_novo56=X1800_7g_03mm(1761:1792,:);
X1800_7g_03mm_novo57=X1800_7g_03mm(1793:1824,:);
X1800_7g_03mm_novo58=X1800_7g_03mm(1825:1856,:);
X1800_7g_03mm_novo59=X1800_7g_03mm(1857:1888,:);
X1800_7g_03mm_novo60=X1800_7g_03mm(1889:1920,:);
X1800_7g_03mm_novo61=X1800_7g_03mm(1921:1952,:);
X1800_7g_03mm_novo62=X1800_7g_03mm(1953:1984,:);
X1800_7g_03mm_novo63=X1800_7g_03mm(1985:2016,:);
X1800_7g_03mm_novo64=X1800_7g_03mm(2017:2048,:);

```

```

X_1800_7g_03mm_novo=cat(2,X1800_7g_03mm_novo1,X1800_7g_03mm_novo2,X1800_7g_03mm_novo3,X1800_7g_03mm_novo4,X1800_7g_03mm_novo5,X1800_7g_03mm_novo6,X1800_7g_03mm_novo7,X1800_7g_03mm_novo8,X1800_7g_03mm_novo9,X1800_7g_03mm_novo10,X1800_7g_03mm_novo11,X1800_7g_03mm_novo12,X1800_7g_03mm_novo13,X1800_7g_03mm_novo14,X1800_7g_03mm_novo15,X1800_7g_03mm_novo16,X1800_7g_03mm_novo17,X1800_7g_03mm_novo18,X1800_7g_03mm_novo19,X1800_7g_03mm_novo20,X1800_7g_03mm_novo21,X1800_7g_03mm_novo22,X1800_7g_03mm_novo23,X1800_7g_03mm_novo24,X1800_7g_03mm_novo25,X1800_7g_03mm_novo26,X1800_7g_03mm_novo27,X1800_7g_03mm_novo28,X1800_7g_03mm_novo29,X1800_7g_03mm_novo30,X1800_7g_03mm_novo31,X1800_7g_03mm_novo32,X1800_7g_03mm_novo33,X1800_7g_03mm_novo34,X1800_7g_03mm_novo35,X1800_7g_03mm_novo36,X1800_7g_03mm_novo37,X1800_7g_03mm_novo38,X1800_7g_03mm_novo39,X1800_7g_03mm_novo40,X1800_7g_03mm_novo41,X1800_7g_03mm_novo42,X1800_7g_03mm_novo43,X1800_7g_03mm_novo44,X1800_7g_03mm_novo45,X1800_7g_03mm_novo46,X1800_7g_03mm_novo47,X1800_7g_03mm_novo48,X1800_7g_03mm_novo49,X1800_7g_03mm_novo50,X1800_7g_03mm_novo51,X1800_7g_03mm_novo52,X1800_7g_03mm_novo53,X1800_7g_03mm_novo54,X1800_7g_03mm_novo55,X1800_7g_03mm_novo56,X1800_7g_03mm_novo57,X1800_7g_03mm_novo58,X1800_7g_03mm_novo59,X1800_7g_03mm_novo60,X1800_7g_03mm_novo61,X1800_7g_03mm_novo62,X1800_7g_03mm_novo63,X1800_7g_03mm_novo64);

```



```

X1800_15g_06mm_novo21=X1800_15g_06mm(641:672,:);
X1800_15g_06mm_novo22=X1800_15g_06mm(673:704,:);
X1800_15g_06mm_novo23=X1800_15g_06mm(705:736,:);
X1800_15g_06mm_novo24=X1800_15g_06mm(737:768,:);
X1800_15g_06mm_novo25=X1800_15g_06mm(769:800,:);
X1800_15g_06mm_novo26=X1800_15g_06mm(801:832,:);
X1800_15g_06mm_novo27=X1800_15g_06mm(833:864,:);
X1800_15g_06mm_novo28=X1800_15g_06mm(865:896,:);
X1800_15g_06mm_novo29=X1800_15g_06mm(897:928,:);
X1800_15g_06mm_novo30=X1800_15g_06mm(929:960,:);
X1800_15g_06mm_novo31=X1800_15g_06mm(961:992,:);
X1800_15g_06mm_novo32=X1800_15g_06mm(993:1024,:);
X1800_15g_06mm_novo33=X1800_15g_06mm(1025:1056,:);
X1800_15g_06mm_novo34=X1800_15g_06mm(1057:1088,:);
X1800_15g_06mm_novo35=X1800_15g_06mm(1089:1120,:);
X1800_15g_06mm_novo36=X1800_15g_06mm(1121:1152,:);
X1800_15g_06mm_novo37=X1800_15g_06mm(1153:1184,:);
X1800_15g_06mm_novo38=X1800_15g_06mm(1185:1216,:);
X1800_15g_06mm_novo39=X1800_15g_06mm(1217:1248,:);
X1800_15g_06mm_novo40=X1800_15g_06mm(1249:1280,:);
X1800_15g_06mm_novo41=X1800_15g_06mm(1281:1312,:);
X1800_15g_06mm_novo42=X1800_15g_06mm(1313:1344,:);
X1800_15g_06mm_novo43=X1800_15g_06mm(1345:1376,:);
X1800_15g_06mm_novo44=X1800_15g_06mm(1377:1408,:);
X1800_15g_06mm_novo45=X1800_15g_06mm(1409:1440,:);
X1800_15g_06mm_novo46=X1800_15g_06mm(1441:1472,:);
X1800_15g_06mm_novo47=X1800_15g_06mm(1473:1504,:);
X1800_15g_06mm_novo48=X1800_15g_06mm(1505:1536,:);
X1800_15g_06mm_novo49=X1800_15g_06mm(1537:1568,:);
X1800_15g_06mm_novo50=X1800_15g_06mm(1569:1600,:);
X1800_15g_06mm_novo51=X1800_15g_06mm(1601:1632,:);
X1800_15g_06mm_novo52=X1800_15g_06mm(1633:1664,:);
X1800_15g_06mm_novo53=X1800_15g_06mm(1665:1696,:);
X1800_15g_06mm_novo54=X1800_15g_06mm(1697:1728,:);
X1800_15g_06mm_novo55=X1800_15g_06mm(1729:1760,:);
X1800_15g_06mm_novo56=X1800_15g_06mm(1761:1792,:);
X1800_15g_06mm_novo57=X1800_15g_06mm(1793:1824,:);
X1800_15g_06mm_novo58=X1800_15g_06mm(1825:1856,:);
X1800_15g_06mm_novo59=X1800_15g_06mm(1857:1888,:);
X1800_15g_06mm_novo60=X1800_15g_06mm(1889:1920,:);
X1800_15g_06mm_novo61=X1800_15g_06mm(1921:1952,:);
X1800_15g_06mm_novo62=X1800_15g_06mm(1953:1984,:);
X1800_15g_06mm_novo63=X1800_15g_06mm(1985:2016,:);
X1800_15g_06mm_novo64=X1800_15g_06mm(2017:2048,:);

```

```

X_1800_15g_06mm_novo=cat(2,X1800_15g_06mm_novo1,X1800_15g_06mm_novo2,X1800_15g_06mm_novo3,X1800_15g_06mm_novo4,X1800_15g_06mm_novo5,X1800_15g_06mm_novo6,X1800_15g_06mm_novo7,X1800_15g_06mm_novo8,X1800_15g_06mm_novo9,X1800_15g_06mm_novo10,X1800_15g_06mm_novo11,X1800_15g_06mm_novo12,X1800_15g_06mm_novo13,X1800_15g_06mm_novo14,X1800_15g_06mm_novo15,X1800_15g_06mm_novo16,X1800_15g_06mm_novo17,X1800_15g_06mm_novo18,X1800_15g_06mm_novo19,X1800_15g_06mm_novo20,X1800_15g_06mm_novo21,X1800_15g_06mm_novo22,X1800_15g_06mm_novo23,X1800_15g_06mm_novo24,X1800_15g_06mm_novo25,X1800_15g_06mm_novo26,X1800_15g_06mm_novo27,X1800_15g_06mm_novo28,X1800_15g_06mm_novo29,X1800_15g_06mm_novo30,X1800_15g_06mm_novo31,X1800_15g_06mm_novo32,X1800_15g_06mm_novo33,X1800_15g_06mm_novo34,X1800_15g_06mm_novo35,X1800_15g_06mm_novo36,X1800_15g_06mm_novo37,X1800_15g_06mm_novo38,X1800_15g_06mm_novo39,X1800_15g_06mm_novo40,X1800_15g_06mm_novo41,X1800_15g_06mm_novo42,X1800_15g_06mm_novo43,X1800_15g_06mm_novo44,X1800_15g_06mm_novo45,X1800_15g_06mm_novo46,X1800_15g_06mm_novo47,X1800_15g_06mm_novo48,X1800_15g_06mm_novo49,X1800_15g_06mm_novo50,X1800_15g_06mm_novo51,X1800_15g_06mm_novo52,X1800_15g_06mm_novo53,X1800_15g_06mm_n

```



```
X1800_30g_1mm=cat(2,(A_3(:,2)),(A_3(:,11)),(A_3(:,20))),(A_3(:,39)));
Alvo_novo=cat(2,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo);
X1800_30g_1mm_novo1=X1800_30g_1mm(1:32,:);
X1800_30g_1mm_novo2=X1800_30g_1mm(33:64,:);
X1800_30g_1mm_novo3=X1800_30g_1mm(65:96,:);
X1800_30g_1mm_novo4=X1800_30g_1mm(97:128,:);
X1800_30g_1mm_novo5=X1800_30g_1mm(129:160,:);
X1800_30g_1mm_novo6=X1800_30g_1mm(161:192,:);
X1800_30g_1mm_novo7=X1800_30g_1mm(193:224,:);
X1800_30g_1mm_novo8=X1800_30g_1mm(225:256,:);
X1800_30g_1mm_novo9=X1800_30g_1mm(257:288,:);
X1800_30g_1mm_novo10=X1800_30g_1mm(289:320,:);
X1800_30g_1mm_novo11=X1800_30g_1mm(321:352,:);
X1800_30g_1mm_novo12=X1800_30g_1mm(353:384,:);
X1800_30g_1mm_novo13=X1800_30g_1mm(385:416,:);
X1800_30g_1mm_novo14=X1800_30g_1mm(417:448,:);
X1800_30g_1mm_novo15=X1800_30g_1mm(449:480,:);
X1800_30g_1mm_novo16=X1800_30g_1mm(481:512,:);
X1800_30g_1mm_novo17=X1800_30g_1mm(513:544,:);
X1800_30g_1mm_novo18=X1800_30g_1mm(545:576,:);
```

```

X1800_30g_1mm_novo19=X1800_30g_1mm(577:608,:);
X1800_30g_1mm_novo20=X1800_30g_1mm(609:640,:);
X1800_30g_1mm_novo21=X1800_30g_1mm(641:672,:);
X1800_30g_1mm_novo22=X1800_30g_1mm(673:704,:);
X1800_30g_1mm_novo23=X1800_30g_1mm(705:736,:);
X1800_30g_1mm_novo24=X1800_30g_1mm(737:768,:);
X1800_30g_1mm_novo25=X1800_30g_1mm(769:800,:);
X1800_30g_1mm_novo26=X1800_30g_1mm(801:832,:);
X1800_30g_1mm_novo27=X1800_30g_1mm(833:864,:);
X1800_30g_1mm_novo28=X1800_30g_1mm(865:896,:);
X1800_30g_1mm_novo29=X1800_30g_1mm(897:928,:);
X1800_30g_1mm_novo30=X1800_30g_1mm(929:960,:);
X1800_30g_1mm_novo31=X1800_30g_1mm(961:992,:);
X1800_30g_1mm_novo32=X1800_30g_1mm(993:1024,:);
X1800_30g_1mm_novo33=X1800_30g_1mm(1025:1056,:);
X1800_30g_1mm_novo34=X1800_30g_1mm(1057:1088,:);
X1800_30g_1mm_novo35=X1800_30g_1mm(1089:1120,:);
X1800_30g_1mm_novo36=X1800_30g_1mm(1121:1152,:);
X1800_30g_1mm_novo37=X1800_30g_1mm(1153:1184,:);
X1800_30g_1mm_novo38=X1800_30g_1mm(1185:1216,:);
X1800_30g_1mm_novo39=X1800_30g_1mm(1217:1248,:);
X1800_30g_1mm_novo40=X1800_30g_1mm(1249:1280,:);
X1800_30g_1mm_novo41=X1800_30g_1mm(1281:1312,:);
X1800_30g_1mm_novo42=X1800_30g_1mm(1313:1344,:);
X1800_30g_1mm_novo43=X1800_30g_1mm(1345:1376,:);
X1800_30g_1mm_novo44=X1800_30g_1mm(1377:1408,:);
X1800_30g_1mm_novo45=X1800_30g_1mm(1409:1440,:);
X1800_30g_1mm_novo46=X1800_30g_1mm(1441:1472,:);
X1800_30g_1mm_novo47=X1800_30g_1mm(1473:1504,:);
X1800_30g_1mm_novo48=X1800_30g_1mm(1505:1536,:);
X1800_30g_1mm_novo49=X1800_30g_1mm(1537:1568,:);
X1800_30g_1mm_novo50=X1800_30g_1mm(1569:1600,:);
X1800_30g_1mm_novo51=X1800_30g_1mm(1601:1632,:);
X1800_30g_1mm_novo52=X1800_30g_1mm(1633:1664,:);
X1800_30g_1mm_novo53=X1800_30g_1mm(1665:1696,:);
X1800_30g_1mm_novo54=X1800_30g_1mm(1697:1728,:);
X1800_30g_1mm_novo55=X1800_30g_1mm(1729:1760,:);
X1800_30g_1mm_novo56=X1800_30g_1mm(1761:1792,:);
X1800_30g_1mm_novo57=X1800_30g_1mm(1793:1824,:);
X1800_30g_1mm_novo58=X1800_30g_1mm(1825:1856,:);
X1800_30g_1mm_novo59=X1800_30g_1mm(1857:1888,:);
X1800_30g_1mm_novo60=X1800_30g_1mm(1889:1920,:);
X1800_30g_1mm_novo61=X1800_30g_1mm(1921:1952,:);
X1800_30g_1mm_novo62=X1800_30g_1mm(1953:1984,:);
X1800_30g_1mm_novo63=X1800_30g_1mm(1985:2016,:);
X1800_30g_1mm_novo64=X1800_30g_1mm(2017:2048,:);

```

```

X_1800_30g_1mm_novo=cat(2,X1800_30g_1mm_novo1,X1800_30g_1mm_novo2,X1800_30g_1mm_novo3,X1800_30g_1mm_novo4,X1800_30g_1mm_novo5,X1800_30g_1mm_novo6,X1800_30g_1mm_novo7,X1800_30g_1mm_novo8,X1800_30g_1mm_novo9,X1800_30g_1mm_novo10,X1800_30g_1mm_novo11,X1800_30g_1mm_novo12,X1800_30g_1mm_novo13,X1800_30g_1mm_novo14,X1800_30g_1mm_novo15,X1800_30g_1mm_novo16,X1800_30g_1mm_novo17,X1800_30g_1mm_novo18,X1800_30g_1mm_novo19,X1800_30g_1mm_novo20,X1800_30g_1mm_novo21,X1800_30g_1mm_novo22,X1800_30g_1mm_novo23,X1800_30g_1mm_novo24,X1800_30g_1mm_novo25,X1800_30g_1mm_novo26,X1800_30g_1mm_novo27,X1800_30g_1mm_novo28,X1800_30g_1mm_novo29,X1800_30g_1mm_novo30,X1800_30g_1mm_novo31,X1800_30g_1mm_novo32,X1800_30g_1mm_novo33,X1800_30g_1mm_novo34,X1800_30g_1mm_novo35,X1800_30g_1mm_novo36,X1800_30g_1mm_novo37,X1800_30g_1mm_novo38,X1800_30g_1mm_novo39,X1800_30g_1mm_novo40,X1800_30g_1mm_novo41,X1800_30g_1mm_novo42,X1800_30g_1mm_novo43,X1800_30g_1mm_novo44,X1800_30g_1mm_novo45,X1800_30g_1mm_novo46,X1800_30g_1mm_novo47,X1800_30g_1mm_novo48,X1800_30g_1mm_novo49,X1800_30g_1mm_novo50,X1800_30g_1mm_novo51,X1800_30g_1mm_novo52,X1800_30g_1mm_novo53,X1800_30g_1mm_novo54,X1800_30g_1mm_novo55,X1800_30g_1mm_novo56,X1800_30g_1mm_novo57,X1800_30g_1mm_novo58,X1800_30g_1mm_novo59,X1800_30g_1mm_novo60,X1800_30g_1mm_novo61,X1800_30g_1mm_novo62,X1800_30g_1mm_novo63,X1800_30g_1mm_novo64);

```

[illegible]

```

X3600_7g_03mm_novo15=X3600_7g_03mm(449:480,:);
X3600_7g_03mm_novo16=X3600_7g_03mm(481:512,:);
X3600_7g_03mm_novo17=X3600_7g_03mm(513:544,:);
X3600_7g_03mm_novo18=X3600_7g_03mm(545:576,:);
X3600_7g_03mm_novo19=X3600_7g_03mm(577:608,:);
X3600_7g_03mm_novo20=X3600_7g_03mm(609:640,:);
X3600_7g_03mm_novo21=X3600_7g_03mm(641:672,:);
X3600_7g_03mm_novo22=X3600_7g_03mm(673:704,:);
X3600_7g_03mm_novo23=X3600_7g_03mm(705:736,:);
X3600_7g_03mm_novo24=X3600_7g_03mm(737:768,:);
X3600_7g_03mm_novo25=X3600_7g_03mm(769:800,:);
X3600_7g_03mm_novo26=X3600_7g_03mm(801:832,:);
X3600_7g_03mm_novo27=X3600_7g_03mm(833:864,:);
X3600_7g_03mm_novo28=X3600_7g_03mm(865:896,:);
X3600_7g_03mm_novo29=X3600_7g_03mm(897:928,:);
X3600_7g_03mm_novo30=X3600_7g_03mm(929:960,:);
X3600_7g_03mm_novo31=X3600_7g_03mm(961:992,:);
X3600_7g_03mm_novo32=X3600_7g_03mm(993:1024,:);
X3600_7g_03mm_novo33=X3600_7g_03mm(1025:1056,:);
X3600_7g_03mm_novo34=X3600_7g_03mm(1057:1088,:);
X3600_7g_03mm_novo35=X3600_7g_03mm(1089:1120,:);
X3600_7g_03mm_novo36=X3600_7g_03mm(1121:1152,:);
X3600_7g_03mm_novo37=X3600_7g_03mm(1153:1184,:);
X3600_7g_03mm_novo38=X3600_7g_03mm(1185:1216,:);
X3600_7g_03mm_novo39=X3600_7g_03mm(1217:1248,:);
X3600_7g_03mm_novo40=X3600_7g_03mm(1249:1280,:);
X3600_7g_03mm_novo41=X3600_7g_03mm(1281:1312,:);
X3600_7g_03mm_novo42=X3600_7g_03mm(1313:1344,:);
X3600_7g_03mm_novo43=X3600_7g_03mm(1345:1376,:);
X3600_7g_03mm_novo44=X3600_7g_03mm(1377:1408,:);
X3600_7g_03mm_novo45=X3600_7g_03mm(1409:1440,:);
X3600_7g_03mm_novo46=X3600_7g_03mm(1441:1472,:);
X3600_7g_03mm_novo47=X3600_7g_03mm(1473:1504,:);
X3600_7g_03mm_novo48=X3600_7g_03mm(1505:1536,:);
X3600_7g_03mm_novo49=X3600_7g_03mm(1537:1568,:);
X3600_7g_03mm_novo50=X3600_7g_03mm(1569:1600,:);
X3600_7g_03mm_novo51=X3600_7g_03mm(1601:1632,:);
X3600_7g_03mm_novo52=X3600_7g_03mm(1633:1664,:);
X3600_7g_03mm_novo53=X3600_7g_03mm(1665:1696,:);
X3600_7g_03mm_novo54=X3600_7g_03mm(1697:1728,:);
X3600_7g_03mm_novo55=X3600_7g_03mm(1729:1760,:);
X3600_7g_03mm_novo56=X3600_7g_03mm(1761:1792,:);
X3600_7g_03mm_novo57=X3600_7g_03mm(1793:1824,:);
X3600_7g_03mm_novo58=X3600_7g_03mm(1825:1856,:);
X3600_7g_03mm_novo59=X3600_7g_03mm(1857:1888,:);
X3600_7g_03mm_novo60=X3600_7g_03mm(1889:1920,:);
X3600_7g_03mm_novo61=X3600_7g_03mm(1921:1952,:);
X3600_7g_03mm_novo62=X3600_7g_03mm(1953:1984,:);
X3600_7g_03mm_novo63=X3600_7g_03mm(1985:2016,:);
X3600_7g_03mm_novo64=X3600_7g_03mm(2017:2048,:);

```

```

X_3600_7g_03mm_novo=cat(2,X3600_7g_03mm_novo1,X3600_7g_03mm_novo2,X3600_7g_03mm_novo3,X3600_7g_03mm_novo4,X3600_7g_03mm_novo5,X3600_7g_03mm_novo6,X3600_7g_03mm_novo7,X3600_7g_03mm_novo8,X3600_7g_03mm_novo9,X3600_7g_03mm_novo10,X3600_7g_03mm_novo11,X3600_7g_03mm_novo12,X3600_7g_03mm_novo13,X3600_7g_03mm_novo14,X3600_7g_03mm_novo15,X3600_7g_03mm_novo16,X3600_7g_03mm_novo17,X3600_7g_03mm_novo18,X3600_7g_03mm_novo19,X3600_7g_03mm_novo20,X3600_7g_03mm_novo21,X3600_7g_03mm_novo22,X3600_7g_03mm_novo23,X3600_7g_03mm_novo24,X3600_7g_03mm_novo25,X3600_7g_03mm_novo26,X3600_7g_03mm_novo27,X3600_7g_03mm_novo28,X3600_7g_03mm_novo29,X3600_7g_03mm_novo30,X3600_7g_03mm_novo31,X3600_7g_03mm_novo32,X3600_7g_03mm_novo33,X3600_7g_03mm_novo34,X3600_7g_03mm_novo35,X3600_7g_03mm_novo36,X3600_7g_03mm_novo37,X3600_7g_03mm_novo38,X3600_7g_03mm_novo39,X3600_7g_03mm_novo40,X3600_7g_03mm_novo41,X3600_7g_03mm_novo42,X3600_7g_03mm_novo43,X3600_7g_03mm_novo44,X3600_7g_03mm_novo45,X3600_7g_03mm_novo46,X3600_7g_03mm_novo47,X3600_7g_03mm_novo48,X3600_7g_03mm_novo49,X3600_7g_03mm_novo50,X3600_7g_03mm_novo51,X3600_7g_03mm_novo52,X3600_7g_03mm_novo53,X3600_7g_03mm_novo54,X3600_7g_03mm_novo55,X3600_7g_03mm_novo56,X3600_7g_03mm_novo57,X3600_7g_03mm_novo58,X3600_7g_03mm_novo59,X3600_7g_03mm_novo60,X3600_7g_03mm_novo61,X3600_7g_03mm_novo62,X3600_7g_03mm_novo63,X3600_7g_03mm_novo64);

```

```
hiddenLayerSize = neuronios;
% Create a Pattern Recognition Network
net7 = patternnet(hiddenLayerSize);
% Set up Division of Data for Training, Validation, Testing
net7.divideParam.trainRatio = 70/100;
net7.divideParam.valRatio   = 15/100;
net7.divideParam.testRatio  = 15/100;
% Train the Network
[net7,tr] = train(net7,inputs7,targets7);
% Test the Network
outputs7 = round(net7(inputs7));
errors7 = gsubtract(targets7,outputs7);
performance7 = perform(net7,targets7,outputs7);
tInd7 = tr.testInd;
tstOutputs7 = net7(inputs7(:,tInd7));
tstPerform7 = perform(net7,targets7(:,tInd7),tstOutputs7);
% View the Network
view(net7)
figure, plotperform(tr); title('Melhor performance para a condição: 3600
rpm / 7g / 0,3mm')
figure, plotconfusion(targets7,outputs7); title('Matriz confusão - 3600
rpm/ 7g/ 0,3mm')
```

```
X3600_15g_06mm=cat(2,(A_3(:,3)),(A_3(:,9)),(A_3(:,18))),(A_3(:,44)));  
Alvo_novo=cat(2,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,  
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,  
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,  
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,  
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo);  
X3600_15g_06mm_novo1=X3600_15g_06mm(1:32,:);  
X3600_15g_06mm_novo2=X3600_15g_06mm(33:64,:);  
X3600_15g_06mm_novo3=X3600_15g_06mm(65:96,:);  
X3600_15g_06mm_novo4=X3600_15g_06mm(97:128,:);  
X3600_15g_06mm_novo5=X3600_15g_06mm(129:160,:);  
X3600_15g_06mm_novo6=X3600_15g_06mm(161:192,:);  
X3600_15g_06mm_novo7=X3600_15g_06mm(193:224,:);  
X3600_15g_06mm_novo8=X3600_15g_06mm(225:256,:);  
X3600_15g_06mm_novo9=X3600_15g_06mm(257:288,:);  
X3600_15g_06mm_novo10=X3600_15g_06mm(289:320,:);  
X3600_15g_06mm_novo11=X3600_15g_06mm(321:352,:);  
X3600_15g_06mm_novo12=X3600_15g_06mm(353:384,:);  
X3600_15g_06mm_novo13=X3600_15g_06mm(385:416,:);  
X3600_15g_06mm_novo14=X3600_15g_06mm(417:448,:);
```

```

X3600_15g_06mm_novo15=X3600_15g_06mm(449:480,:);
X3600_15g_06mm_novo16=X3600_15g_06mm(481:512,:);
X3600_15g_06mm_novo17=X3600_15g_06mm(513:544,:);
X3600_15g_06mm_novo18=X3600_15g_06mm(545:576,:);
X3600_15g_06mm_novo19=X3600_15g_06mm(577:608,:);
X3600_15g_06mm_novo20=X3600_15g_06mm(609:640,:);
X3600_15g_06mm_novo21=X3600_15g_06mm(641:672,:);
X3600_15g_06mm_novo22=X3600_15g_06mm(673:704,:);
X3600_15g_06mm_novo23=X3600_15g_06mm(705:736,:);
X3600_15g_06mm_novo24=X3600_15g_06mm(737:768,:);
X3600_15g_06mm_novo25=X3600_15g_06mm(769:800,:);
X3600_15g_06mm_novo26=X3600_15g_06mm(801:832,:);
X3600_15g_06mm_novo27=X3600_15g_06mm(833:864,:);
X3600_15g_06mm_novo28=X3600_15g_06mm(865:896,:);
X3600_15g_06mm_novo29=X3600_15g_06mm(897:928,:);
X3600_15g_06mm_novo30=X3600_15g_06mm(929:960,:);
X3600_15g_06mm_novo31=X3600_15g_06mm(961:992,:);
X3600_15g_06mm_novo32=X3600_15g_06mm(993:1024,:);
X3600_15g_06mm_novo33=X3600_15g_06mm(1025:1056,:);
X3600_15g_06mm_novo34=X3600_15g_06mm(1057:1088,:);
X3600_15g_06mm_novo35=X3600_15g_06mm(1089:1120,:);
X3600_15g_06mm_novo36=X3600_15g_06mm(1121:1152,:);
X3600_15g_06mm_novo37=X3600_15g_06mm(1153:1184,:);
X3600_15g_06mm_novo38=X3600_15g_06mm(1185:1216,:);
X3600_15g_06mm_novo39=X3600_15g_06mm(1217:1248,:);
X3600_15g_06mm_novo40=X3600_15g_06mm(1249:1280,:);
X3600_15g_06mm_novo41=X3600_15g_06mm(1281:1312,:);
X3600_15g_06mm_novo42=X3600_15g_06mm(1313:1344,:);
X3600_15g_06mm_novo43=X3600_15g_06mm(1345:1376,:);
X3600_15g_06mm_novo44=X3600_15g_06mm(1377:1408,:);
X3600_15g_06mm_novo45=X3600_15g_06mm(1409:1440,:);
X3600_15g_06mm_novo46=X3600_15g_06mm(1441:1472,:);
X3600_15g_06mm_novo47=X3600_15g_06mm(1473:1504,:);
X3600_15g_06mm_novo48=X3600_15g_06mm(1505:1536,:);
X3600_15g_06mm_novo49=X3600_15g_06mm(1537:1568,:);
X3600_15g_06mm_novo50=X3600_15g_06mm(1569:1600,:);
X3600_15g_06mm_novo51=X3600_15g_06mm(1601:1632,:);
X3600_15g_06mm_novo52=X3600_15g_06mm(1633:1664,:);
X3600_15g_06mm_novo53=X3600_15g_06mm(1665:1696,:);
X3600_15g_06mm_novo54=X3600_15g_06mm(1697:1728,:);
X3600_15g_06mm_novo55=X3600_15g_06mm(1729:1760,:);
X3600_15g_06mm_novo56=X3600_15g_06mm(1761:1792,:);
X3600_15g_06mm_novo57=X3600_15g_06mm(1793:1824,:);
X3600_15g_06mm_novo58=X3600_15g_06mm(1825:1856,:);
X3600_15g_06mm_novo59=X3600_15g_06mm(1857:1888,:);
X3600_15g_06mm_novo60=X3600_15g_06mm(1889:1920,:);
X3600_15g_06mm_novo61=X3600_15g_06mm(1921:1952,:);
X3600_15g_06mm_novo62=X3600_15g_06mm(1953:1984,:);
X3600_15g_06mm_novo63=X3600_15g_06mm(1985:2016,:);
X3600_15g_06mm_novo64=X3600_15g_06mm(2017:2048,:);

```

```

X_3600_15g_06mm_novo=cat(2,X3600_15g_06mm_novo1,X3600_15g_06mm_novo2,X3600_15g_06mm_novo3,X3600_15g_06mm_novo4,X3600_15g_06mm_novo5,X3600_15g_06mm_novo6,X3600_15g_06mm_novo7,X3600_15g_06mm_novo8,X3600_15g_06mm_novo9,X3600_15g_06mm_novo10,X3600_15g_06mm_novo11,X3600_15g_06mm_novo12,X3600_15g_06mm_novo13,X3600_15g_06mm_novo14,X3600_15g_06mm_novo15,X3600_15g_06mm_novo16,X3600_15g_06mm_novo17,X3600_15g_06mm_novo18,X3600_15g_06mm_novo19,X3600_15g_06mm_novo20,X3600_15g_06mm_novo21,X3600_15g_06mm_novo22,X3600_15g_06mm_novo23,X3600_15g_06mm_novo24,X3600_15g_06mm_novo25,X3600_15g_06mm_novo26,X3600_15g_06mm_novo27,X3600_15g_06mm_novo28,X3600_15g_06mm_novo29,X3600_15g_06mm_novo30,X3600_15g_06mm_novo31,X3600_15g_06mm_novo32,X3600_15g_06mm_novo33,X3600_15g_06mm_novo34,X3600_15g_06mm_novo35,X3600_15g_06mm_novo36,X3600_15g_06mm_novo37,X3600_15g_06mm_novo38,X3600_15g_06mm_novo39,X3600_15g_06mm_novo40,X3600_15g_06mm_novo41,X3600_15g_06mm_novo42,X3600_15g_06mm_novo43,X3600_15g_06mm_novo44,X3600_15g_06mm_novo45,X3600_15g_06mm_novo46,X3600_15g_06mm_novo47,X3600_15g_06mm_novo48,X3600_15g_06mm_novo49,X3600_15g_06mm_novo50,X3600_15g_06mm_novo51,X3600_15g_06mm_novo52,X3600_15g_06mm_novo53,X3600_15g_06mm_novo54,X3600_15g_06mm_novo55,X3600_15g_06mm_novo56,X3600_15g_06mm_novo57,X3600_15g_06mm_novo58,X3600_15g_06mm_novo59,X3600_15g_06mm_novo60,X3600_15g_06mm_novo61,X3600_15g_06mm_novo62,X3600_15g_06mm_novo63,X3600_15g_06mm_novo64);

```

```

15g_06mm_novo34,X3600_15g_06mm_novo35,X3600_15g_06mm_novo36,X3600_15g_06mm_
novo37,X3600_15g_06mm_novo38,X3600_15g_06mm_novo39,X3600_15g_06mm_novo40,X3
600_15g_06mm_novo41,X3600_15g_06mm_novo42,X3600_15g_06mm_novo43,X3600_15g_0
6mm_novo44,X3600_15g_06mm_novo45,X3600_15g_06mm_novo46,X3600_15g_06mm_novo4
7,X3600_15g_06mm_novo48,X3600_15g_06mm_novo49,X3600_15g_06mm_novo50,X3600_1
5g_06mm_novo51,X3600_15g_06mm_novo52,X3600_15g_06mm_novo53,X3600_15g_06mm_n
ovo54,X3600_15g_06mm_novo55,X3600_15g_06mm_novo56,X3600_15g_06mm_novo57,X36
00_15g_06mm_novo58,X3600_15g_06mm_novo59,X3600_15g_06mm_novo60,X3600_15g_06
mm_novo61,X3600_15g_06mm_novo62,X3600_15g_06mm_novo63,X3600_15g_06mm_novo64
);
inputs8=X_3600_15g_06mm_novo;
targets8=Alvo_novo;

```

```

hiddenLayerSize = neuronios;
% Create a Pattern Recognition Network
net8 = patternnet(hiddenLayerSize);
% Set up Division of Data for Training, Validation, Testing
net8.divideParam.trainRatio = 70/100;
net8.divideParam.valRatio    = 15/100;
net8.divideParam.testRatio   = 15/100;
% Train the Network
[net8,tr] = train(net8,inputs8,targets8);
% Test the Network
outputs8 = round(net8(inputs8));
errors8 = gsubtract(targets8,outputs8);
performance8 = perform(net8,targets8,outputs8);
tInd8 = tr.testInd;
tstOutputs8 = net8(inputs8(:,tInd8));
tstPerform8 = perform(net8,targets8(:,tInd8),tstOutputs8);
% View the Network
view(net8)
figure, plotperform(tr); title('Melhor performance para a condição: 3600
rpm / 15g / 0,6mm')
figure, plotconfusion(targets8,outputs8); title('Matriz confusão - 3600
rpm/ 15g/ 0,6mm')

```

```

%Rede neural para reconhecimento de padrões de vibração - Velocidade 60Hz
%(3600rpm), Massa 30g e desalinhamento 1,0 mm

```

```

X3600_30g_1mm=cat(2,(A_3(:,3)),(A_3(:,12)),(A_3(:,21)),(A_3(:,48)));
Alvo_novo=cat(2,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo,
,Alvo,Alvo,Alvo,Alvo,Alvo,Alvo);
X3600_30g_1mm_novo1=X3600_30g_1mm(1:32,:);
X3600_30g_1mm_novo2=X3600_30g_1mm(33:64,:);
X3600_30g_1mm_novo3=X3600_30g_1mm(65:96,:);
X3600_30g_1mm_novo4=X3600_30g_1mm(97:128,:);
X3600_30g_1mm_novo5=X3600_30g_1mm(129:160,:);
X3600_30g_1mm_novo6=X3600_30g_1mm(161:192,:);
X3600_30g_1mm_novo7=X3600_30g_1mm(193:224,:);
X3600_30g_1mm_novo8=X3600_30g_1mm(225:256,:);
X3600_30g_1mm_novo9=X3600_30g_1mm(257:288,:);
X3600_30g_1mm_novo10=X3600_30g_1mm(289:320,:);
X3600_30g_1mm_novo11=X3600_30g_1mm(321:352,:);
X3600_30g_1mm_novo12=X3600_30g_1mm(353:384,:);
X3600_30g_1mm_novo13=X3600_30g_1mm(385:416,:);

```

```

X3600_30g_1mm_novo14=X3600_30g_1mm(417:448,:);
X3600_30g_1mm_novo15=X3600_30g_1mm(449:480,:);
X3600_30g_1mm_novo16=X3600_30g_1mm(481:512,:);
X3600_30g_1mm_novo17=X3600_30g_1mm(513:544,:);
X3600_30g_1mm_novo18=X3600_30g_1mm(545:576,:);
X3600_30g_1mm_novo19=X3600_30g_1mm(577:608,:);
X3600_30g_1mm_novo20=X3600_30g_1mm(609:640,:);
X3600_30g_1mm_novo21=X3600_30g_1mm(641:672,:);
X3600_30g_1mm_novo22=X3600_30g_1mm(673:704,:);
X3600_30g_1mm_novo23=X3600_30g_1mm(705:736,:);
X3600_30g_1mm_novo24=X3600_30g_1mm(737:768,:);
X3600_30g_1mm_novo25=X3600_30g_1mm(769:800,:);
X3600_30g_1mm_novo26=X3600_30g_1mm(801:832,:);
X3600_30g_1mm_novo27=X3600_30g_1mm(833:864,:);
X3600_30g_1mm_novo28=X3600_30g_1mm(865:896,:);
X3600_30g_1mm_novo29=X3600_30g_1mm(897:928,:);
X3600_30g_1mm_novo30=X3600_30g_1mm(929:960,:);
X3600_30g_1mm_novo31=X3600_30g_1mm(961:992,:);
X3600_30g_1mm_novo32=X3600_30g_1mm(993:1024,:);
X3600_30g_1mm_novo33=X3600_30g_1mm(1025:1056,:);
X3600_30g_1mm_novo34=X3600_30g_1mm(1057:1088,:);
X3600_30g_1mm_novo35=X3600_30g_1mm(1089:1120,:);
X3600_30g_1mm_novo36=X3600_30g_1mm(1121:1152,:);
X3600_30g_1mm_novo37=X3600_30g_1mm(1153:1184,:);
X3600_30g_1mm_novo38=X3600_30g_1mm(1185:1216,:);
X3600_30g_1mm_novo39=X3600_30g_1mm(1217:1248,:);
X3600_30g_1mm_novo40=X3600_30g_1mm(1249:1280,:);
X3600_30g_1mm_novo41=X3600_30g_1mm(1281:1312,:);
X3600_30g_1mm_novo42=X3600_30g_1mm(1313:1344,:);
X3600_30g_1mm_novo43=X3600_30g_1mm(1345:1376,:);
X3600_30g_1mm_novo44=X3600_30g_1mm(1377:1408,:);
X3600_30g_1mm_novo45=X3600_30g_1mm(1409:1440,:);
X3600_30g_1mm_novo46=X3600_30g_1mm(1441:1472,:);
X3600_30g_1mm_novo47=X3600_30g_1mm(1473:1504,:);
X3600_30g_1mm_novo48=X3600_30g_1mm(1505:1536,:);
X3600_30g_1mm_novo49=X3600_30g_1mm(1537:1568,:);
X3600_30g_1mm_novo50=X3600_30g_1mm(1569:1600,:);
X3600_30g_1mm_novo51=X3600_30g_1mm(1601:1632,:);
X3600_30g_1mm_novo52=X3600_30g_1mm(1633:1664,:);
X3600_30g_1mm_novo53=X3600_30g_1mm(1665:1696,:);
X3600_30g_1mm_novo54=X3600_30g_1mm(1697:1728,:);
X3600_30g_1mm_novo55=X3600_30g_1mm(1729:1760,:);
X3600_30g_1mm_novo56=X3600_30g_1mm(1761:1792,:);
X3600_30g_1mm_novo57=X3600_30g_1mm(1793:1824,:);
X3600_30g_1mm_novo58=X3600_30g_1mm(1825:1856,:);
X3600_30g_1mm_novo59=X3600_30g_1mm(1857:1888,:);
X3600_30g_1mm_novo60=X3600_30g_1mm(1889:1920,:);
X3600_30g_1mm_novo61=X3600_30g_1mm(1921:1952,:);
X3600_30g_1mm_novo62=X3600_30g_1mm(1953:1984,:);
X3600_30g_1mm_novo63=X3600_30g_1mm(1985:2016,:);
X3600_30g_1mm_novo64=X3600_30g_1mm(2017:2048,:);

```

```

X_3600_30g_1mm_novo=cat(2,X3600_30g_1mm_novo1,X3600_30g_1mm_novo2,X3600_30g_1mm_novo3,X3600_30g_1mm_novo4,X3600_30g_1mm_novo5,X3600_30g_1mm_novo6,X3600_30g_1mm_novo7,X3600_30g_1mm_novo8,X3600_30g_1mm_novo9,X3600_30g_1mm_novo10,X3600_30g_1mm_novo11,X3600_30g_1mm_novo12,X3600_30g_1mm_novo13,X3600_30g_1mm_novo14,X3600_30g_1mm_novo15,X3600_30g_1mm_novo16,X3600_30g_1mm_novo17,X3600_30g_1mm_novo18,X3600_30g_1mm_novo19,X3600_30g_1mm_novo20,X3600_30g_1mm_novo21,X3600_30g_1mm_novo22,X3600_30g_1mm_novo23,X3600_30g_1mm_novo24,X3600_30g_1mm_novo25,X3600_30g_1mm_novo26,X3600_30g_1mm_novo27,X3600_30g_1mm_novo28,X3600_30g_1mm_novo29,X3600_30g_1mm_novo30,X3600_30g_1mm_novo31,X3600_30g_1mm_novo32,X3600_30g_1mm_novo33,X3600_30g_1mm_novo34,X3600_30g_1mm_novo35,X3600_30g_1mm_novo36,X3600_30g_1mm_novo37,X3600_30g_1mm_novo38,X3600_30g_1mm_novo39,X3600_30g_1mm_novo40,X3600_30g_1mm_novo41,X3600_30g_1mm_novo42,X3600_30g_1mm_novo43,X3600_30g_1mm_novo44,X3600_30g_1mm_novo45,X3600_30g_1mm_novo46,X3600_30g_1mm_novo47,X3600_30g_1mm_novo48,X3600_30g_1mm_novo49,X3600_30g_1mm_novo50,X3600_30g_1mm_novo51,X3600_30g_1mm_novo52,X3600_30g_1mm_novo53,X3600_30g_1mm_novo54,X3600_30g_1mm_novo55,X3600_30g_1mm_novo56,X3600_30g_1mm_novo57,X3600_30g_1mm_novo58,X3600_30g_1mm_novo59,X3600_30g_1mm_novo60,X3600_30g_1mm_novo61,X3600_30g_1mm_novo62,X3600_30g_1mm_novo63,X3600_30g_1mm_novo64);

```



```

0g_1mm_novo32,X3600_30g_1mm_novo33,X3600_30g_1mm_novo34,X3600_30g_1mm_novo3
5,X3600_30g_1mm_novo36,X3600_30g_1mm_novo37,X3600_30g_1mm_novo38,X3600_30g_
1mm_novo39,X3600_30g_1mm_novo40,X3600_30g_1mm_novo41,X3600_30g_1mm_novo42,X
3600_30g_1mm_novo43,X3600_30g_1mm_novo44,X3600_30g_1mm_novo45,X3600_30g_1mm
_novo46,X3600_30g_1mm_novo47,X3600_30g_1mm_novo48,X3600_30g_1mm_novo49,X360
0_30g_1mm_novo50,X3600_30g_1mm_novo51,X3600_30g_1mm_novo52,X3600_30g_1mm_no
vo53,X3600_30g_1mm_novo54,X3600_30g_1mm_novo55,X3600_30g_1mm_novo56,X3600_3
0g_1mm_novo57,X3600_30g_1mm_novo58,X3600_30g_1mm_novo59,X3600_30g_1mm_novo6
0,X3600_30g_1mm_novo61,X3600_30g_1mm_novo62,X3600_30g_1mm_novo63,X3600_30g_
1mm_novo64);
inputs9=X_3600_30g_1mm_novo;
targets9=Alvo_novo;

hiddenLayerSize = neuronios;
% Create a Pattern Recognition Network
net9 = patternnet(hiddenLayerSize);
% Set up Division of Data for Training, Validation, Testing
net9.divideParam.trainRatio = 70/100;
net9.divideParam.valRatio    = 15/100;
net9.divideParam.testRatio   = 15/100;
% Train the Network
[net9,tr] = train(net9,inputs9,targets9);
% Test the Network
outputs9 = round(net9(inputs9));
errors9 = gsubtract(targets9,outputs9);
performance9 = perform(net9,targets9,outputs9);
tInd9 = tr.testInd;
tstOutputs9 = net9(inputs9(:,tInd9));
tstPerform9 = perform(net9,targets9(:,tInd9),tstOutputs9);
% View the Network
view(net9)
figure, plotperform(tr); title('Melhor performance para a condição: 3600
rpm / 30g / 1,0mm')
figure, plotconfusion(targets9,outputs9); title('Matriz confusão - 3600
rpm/ 30g/ 1,0mm')
%
```